南京工業職業技術大學
NANJING UNIVERSITY OF INDUSTRY TECHNOLOGY

毕业论文（设计）

题　目　基于深度学习的水下图像超分辨率重建与目标检测方法研究

学生姓名：李凯旋

学　　号：2405023226

学　　院：计算机与软件学院

专　　业：人工智能工程技术

班　　级：智能 2432

指导教师：王丽

第二指导教师：陈宝玉

二〇二六年五月

南京工业职业技术大学

毕业论文（设计）诚信承诺书

本人郑重声明：所呈交的毕业论文（设计）是本人在指导教师的指导下独立开展工作所取得的成果。尽我所知，除了文中特别加以标注和致谢的内容外，本设计（论文）不包含任何其他个人或集体已经发表或撰写的成果作品。对本设计（论文）所涉及的研究工作作出贡献的其他个人和集体，均已在文中以明确方式标明。

作者签名： 

日　　期：　2026 年 5 月 22 日

摘　　要

水下图像在采集过程中受光吸收与散射效应的影响，普遍存在色彩失衡、对比度不足以及纹理退化等问题，严重制约了水下目标检测等高级视觉任务的执行效果。本文围绕水下图像超分辨率重建与目标检测两个核心任务，提出了两种基于深度学习的改进方法，并通过公开数据集上的系统实验加以验证。

在水下图像超分辨率重建方面，本文提出了频率－空间耦合推理网络（FSCIN）。该网络的核心是空域－频域感知模块（SFAM），通过将快速傅里叶变换（FFT）与基于SwinTransformer 的空域编码相结合，以双分支结构分别对频域幅度分量和相位分量进行自适应增强，再经逆快速傅里叶变换（IFFT）还原至空间域，实现了频域全局信息与空域局部特征的深度集成。此外，本文引入纹理－结构联合损失函数，通过对图像纹理层和结构层分别施加针对性约束，显式监督高频细节与几何边缘的恢复，弥补了传统像素级损失的局限。在 USR-248 和 UFO-120 公开数据集上的实验表明，FSCIN 在×2 放大倍率下分别取得 30.04dB 和 25.98dB 的 PSNR，在多种倍率下均取得领先的综合性能，且以 30.70GFLOPs 和 0.55M 参数实现了高效重建。

在水下图像目标检测方面，本文针对 YOLOv8 在水下场景中存在的局部感受野受限、小目标特征表达能力不足等问题，设计了一种细粒度特征提取模块以替代原始 C2f 模块。该模块由三个子模块协同构成：通道－空间自适应增强模块通过通道－空间双重注意力机制精准聚焦目标边缘与纹理细节；基于 Mamba 的全局感知模块引入视觉状态空间模型，以线性复杂度建模全局空间依赖；多尺度交叉注意力融合模块通过非对称卷积与跨尺度注意力交互，自适应整合局部与全局特征。在 URPC2021 水下目标检测数据集上的实验表明，改进模型相较原始 YOLOv8 在 mAP50 上提升 1.8 个百分点，在小目标检测指标 APs 上提升 1.1 个百分点。

关键词：水下图像超分辨率；频率－空间耦合；纹理－结构损失；YOLOv8；水下目标检测

ABSTRACT

Underwater images are commonly degraded by light absorption and scattering, leading to color imbalance, insufficient contrast, and texture degradation that severely compromise the performance of advanced visual tasks such as underwater object detection. This thesis addresses two core tasks—underwater image super-resolution reconstruction and target detection—by proposing two deep learning-based methods, validated through systematic experiments on public datasets.

For super-resolution, a Frequency-Spatial Coupled Inference Network (FSCIN) is proposed. Its core component, the Spatial Frequency Awareness Module (SFAM), combines the Fast Fourier Transform (FFT) with Swin Transformer-based spatial encoding. A dual-branch structure adaptively enhances the amplitude and phase components in the frequency domain respectively, then restores them to the spatial domain via Inverse FFT, achieving deep integration of global frequency information and local spatial features. A texture-structure joint loss function is further introduced to impose targeted supervision on the texture and structural layers separately, compensating for the limitations of conventional pixel-level losses. Experiments on USR-248 and UFO-120 show that FSCIN achieves PSNR of 30.04 dB and 25.98 dB at ×2 scale, with leading performance across multiple upscaling factors and efficient computation at only 30.70G FLOPs and 0.55M parameters.

For target detection, a fine-grained feature extraction module (FFEM) is designed to replace the C2f module in YOLOv8, addressing its limitations in underwater scenes. Three collaborative submodules are proposed: CAEM for local edge and texture enhancement, VSSM for long-range dependency modeling, and MCFM for adaptive multi-scale feature fusion.

KEYWORDS: Underwater image, Super-resolution reconstruction, Object detection, Deep learning, Frequency-space coupling, YOLOv8

目录

题　　目 1
基于深度学习的水下图像超分辨率重建与目标检测方法研究 1
南京工业职业技术大学 1
毕业论文（设计）诚信承诺书 1
摘要 1
关键词： 1
ABSTRACT ii
KEYWORDS: ii
图表目录 1
第一章 绪论 3
1.1 研究背景及意义 3
1.2 国内外研究现状 4
1.2.1 水下图像超分辨率重建研究现状 4
1.2.2 水下图像目标检测研究现状 6
1.3 本文主要工作 8
1.4 论文组织结构 9
第二章 相关理论基础 11
2.1 深度学习理论基础 11
2.1.1 卷积神经网络 11
2.1.2 Transformer 模型 16
2.1.3 Mamba 模型 17
2.2 水下图像超分辨率理论分析 19
2.2.1 水下图像退化模型 19
2.2.2 水下图像超分辨率重建原理 20
2.3 目标检测理论基础 25
2.3.1 两阶段目标检测方法 25
2.3.2 单阶段目标检测方法 26
2.3.3 基于深度学习的目标检测关键技术 27
2.3.4 水下目标检测特点分析 27
2.4 本章小结 27

第三章 基于频率－空间耦合推理网络的水下图像超分辨率重建方法 29
3.1 引言 29
3.2 相关技术 30
3.2.1 SwinTransformer 网络 30
3.2.2 傅里叶变换 31
3.3 频率－空间耦合推理网络的水下图像超分辨率重建模型 32
3.3.1 网络结构设计 32
3.3.2 频率感知模块（SFAM） 33
3.3.3 纹理－结构联合损失 34
3.4 实验结果与分析 35
3.4.1 实验数据与实验环境 35
3.4.2 评价指标 36
3.4.3 实验设计与实现 37
3.4.4 定量分析 37
3.4.5 定性分析 39
3.4.6 消融实验 40
3.5 本章小结 41
第四章 基于改进 YOLOv8 的水下图像目标检测方法 42
4.1 引言 42
4.2 相关技术 43
4.2.1 YOLOv8 目标检测网络 43
4.2.2 注意力机制 44
4.3 改进的 YOLOv8 水下图像目标检测模型 44
4.3.1 网络结构设计 44
4.3.2 通道－空间自适应增强模块 45
4.3.3 多尺度交叉注意力融合模块 47
4.3.4 基于 Mamba 的全局感知模块 48
4.4 实验结果与分析 49
4.4.1 实验数据与实验环境 49
4.4.2 评价指标 50

4.4.3 实验设计与实现 51
4.4.4 定量分析 51
4.4.5 定性分析 53
4.4.6 消融实验 55
4.5 超分辨率重建水下图像目标检测性能评价 56
4.6 本章小结 60
第五章 总结与展望 61
5.1 总结 61
5.2 展望 62
参考文献 63
致谢 70
附录 72

图表目录

图 1.1 水下场景拍摄的图像.....4
图 1.2 特征匹配测试.....4
图 1.3 整体技术路线图.....8
图 1.4 论文组织架构图.....9
图 2.1 人工神经网络.....11
图 2.2 多层感知机.....12
图 2.3 卷积运算.....13
图 2.4 池化操作.....14
图 2.5 Sigmoid 函数.....15
图 2.6 Tanh 函数.....15
图 2.7 ReLU 函数.....16
图 2.8 Transformer 模型.....17
图 2.9 VSSM 架构图.....18
图 2.10 2D 选择扫描模块.....18
图 2.11 Jaffe-McGlamery 水下图像成像过程.....20
图 2.12 双线性插值计算示意图.....21
图 2.13 双三次插值计算示意图.....22
图 2.14 反卷积上采样示意图.....22
图 2.15 亚像素上采样示意图.....23
图 2.16 基于学习的图像超分辨率重建方法流程图.....23
图 2.17 两阶段图像目标检测结构图.....26
图 2.18 单阶段图像目标检测结构图.....26
图 3.1 Swin Transformer 结构示意图.....30
图 3.2 Swin Transformer 示意图.....31
图 3.3 傅里叶变换示意图（幅度谱与相位谱分解）.....32
图 3.4 FSCIN 整体网络结构示意图.....33
图 3.5 USR-248 和 UFO-120 数据集的具体实例.....35
图 3.6 基于 USR-248 数据集的视觉比较（×2/×4/×8）.....39
图 3.7 基于 UFO-120 数据集的视觉比较（×2/×3/×4）.....40
图 4.2 改进 YOLOv8 网络结构示意图.....45
图 4.3 细粒度特征提取模块整体结构示意图.....45
图 4.5 多尺度交叉注意力融合模块结构示意图.....48
图 4.6 基于 Mamba 的全局感知模块（VSSM）结构示意图.....49
图 4.7 URPC2021 数据集样例.....50

图 4.8 YOLOv8 训练和验证时损失函数曲线..... 53
图 4.9 改进 YOLOv8 训练和验证时损失函数曲线..... 53
图 4.10 原始 YOLOv8 与改进 YOLOv8 在 URPC2021 验证集上的目标检测结果对比..... 55
图 4.11 不同模块的热力图可视化效果..... 56
图 4.12 FSCIN 超分辨率重建对改进 YOLOv8 水下目标检测的促进作用示意图..... 57

表 3.1 不同方法在 USR-248 数据集进行×2 比较..... 38
表 3.2 不同方法在 USR-248 数据集进行×4 比较..... 38
表 3.3 不同方法在 USR-248 数据集进行×8 比较..... 38
表 3.4 基于 UFO-120 数据集的水下图像超分辨率定量评估（×2/×3/×4）..... 38
表 3.5 SFAM 模块有效性消融实验（USR-248，×2）..... 40
表 3.6 多模态损失函数消融实验（UFO-120，×2）..... 41
表 4.1 实验环境配置..... 50
表 4.2 URPC2021 数据集上的检测性能对比..... 52
表 4.3 细粒度特征提取模块各子模块的消融实验结果..... 56

第一章 绪论

1.1 研究背景及意义

随着海洋资源开发、海洋环境监测以及水下工程检测等领域的快速发展，水下视觉技术逐渐成为海洋信息获取的重要手段。随着《新一代人工智能发展规划》的发布，明确提出了到 2030 年使中国成为世界主要的人工智能创新中心的要求，其中就包括深度学习、图像处理等关键技术领域。在此背景下，水下视觉技术成为获取海洋信息的核心手段。其中，高质量水下图像的获取是实现精确目标检测的前提。通过超分辨率重建技术提升水下图像的分辨率和细节，再结合目标检测方法，可在水下机器人、自主潜航器（AUV）及遥控潜水器（ROV）等系统中实现生物识别、目标定位及资源调查的精准感知，为水下科研与工程提供可靠技术支撑。

水下成像环境复杂，光线传播同时受到吸收和散射的影响。吸收效应导致不同波长光衰减速度不同，其中蓝光衰减相对缓慢，使图像呈现蓝绿色偏色；散射效应使光线偏离原始路径，前向散射模糊边缘细节，后向散射降低对比度和清晰度。由此，水下图像普遍存在对比度低、颜色失真、细节模糊和噪声干扰等问题，使传统视觉算法难以准确提取目标特征，限制了检测系统的性能，如图 1.1 所示。为应对水下成像环境的复杂干扰，不少学者从硬件角度出发，设计了高精度、高速摄像机以提高图像采集质量。虽然这些设备在一定程度上降低了噪声、缓解了水体对成像的影响，但采集图像仍缺乏微小细节和纹理信息，难以满足后续目标检测或分析任务的需求，同时成本高昂，不利于大规模应用。相比之下，水下图像超分辨率重建技术可在不改变原始成像设备的前提下，通过恢复低分辨率图像中丢失的细节和纹理，不仅显著提升图像质量，也为目标检测提供更丰富的特征信息，实现图像增强与目标识别的有效耦合，从而提高水下目标定位与识别的精度与稳定性。如图 1.2 所示，处理后的水下图像能够大幅提升特征点的匹配数量。



图 1.1 水下场景拍摄的图像



(a)　　(b)

（a）原图正确匹配 25 个点　　（b）复原图像正确匹配 79 个点

图 1.2 特征匹配测试

综上所述，本文提出一套以“原始水下图像→超分辨率清晰化→高质量清晰图像→目标检测→检测结果”为主线的完整水下视觉感知框架。该框架将图像质量提升与目标检测两个模块有机串联：首先利用基于深度学习的超分辨率重建方法对原始退化图像进行增强，恢复其纹理细节、改善色彩失衡、提升对比度；随后以高质量清晰图像作为输入，由改进的目标检测模型执行水下目标的精准识别与定位。实验研究表明，在对水下图像进行增强处理之后再进行目标检测，能够有效提升模型检测精度，从而改善整体检测性能。因此，研究基于深度学习的水下图像超分辨率重建与目标检测方法，对于提升水下视觉系统性能具有重要的理论意义和应用价值。

1.2 国内外研究现状

1.2.1 水下图像超分辨率重建研究现状

图像超分辨率（Super-resolution，SR）重建技术旨在从低分辨率图像（Low-resolution，LR）中恢复高分辨率图像（High-resolution，HR）细节，其在医学影像、遥感和水下视觉等领域均具有重要应用价值。随着深度学习的兴起，基于卷积神经网络的超分辨率方法取得了实质性突破。Dong 等提出的 SRCNN 首次将卷积神经网络引入图像超分辨率领域，通

过三层卷积结构学习低分辨率到高分辨率图像的端到端映射，奠定了深度学习超分辨率研究的基础范式[1]。Kim 等提出的 VDSR 引入全局残差学习，利用极深网络结构提升了重建精度[2]。Lim 等设计了增强型深度残差网络 EDSR，移除批归一化层并扩大网络容量，在通用超分辨率基准上大幅提升了性能[3]。Zhang 等提出的 RDN 通过残差密集连接充分利用层次特征，实现了多尺度细节的综合恢复[4]；Zhang 等进一步引入通道注意力机制提出 RCAN，通过自适应加权不同通道的特征响应，使网络能够选择性地聚焦于高频重建所需的关键信息[5]。在生成对抗网络应用方面，Goodfellow 等提出的 GAN 框架为超分辨率图像质量的提升提供了新途径[6]；Ledig 等提出的 SRGAN 首次将 GAN 引入图像超分辨率重建，引入感知损失函数驱动网络生成高频视觉细节[7]；Wang 等在此基础上提出 ESRGAN，通过残差密集块与相对性 GAN 损失进一步增强了纹理重建的真实感，成为后续研究的重要基准[8]。赵冉等提出了基于视频多帧融合的医学超声图像超分辨率重建方法，通过时域信息的跨帧整合有效提升了重建分辨率[9]；冉文兵等将生成对抗网络与注意力机制相结合，显著改善了医学图像的超分辨率重建效果[10]。在遥感图像领域，赵慧岩等提出了基于生成对抗网络的 Sentinel-2 遥感图像超分辨率分析方法[11]；张艳等提出了基于 HMRF 先验模型的高分辨率卫星图像重建方案，通过引入马尔可夫随机场约束提升了重建结果的结构保真度[12]。上述工作所形成的方法体系为本文水下图像超分辨率研究提供了重要参考。

在水下图像质量提升研究方面，早期工作主要依赖物理成像模型进行图像复原。杨爱萍等提出了基于颜色失真去除与暗通道先验的水下图像复原方法，通过估计水下光衰减参数改善了图像的色彩还原效果[13]；杨爱萍等进一步提出了基于多特征融合的单幅水下图像清晰化方法，综合利用颜色、结构与纹理特征实现图像增强，但上述方法在水质条件复杂多变的场景中鲁棒性不足[14]。针对水下图像退化的特殊性，研究者开始设计面向水下场景的专用超分辨率方法。Islam 等构建了 USR-248 水下图像超分辨率数据集并提出 SRDRM 方法，通过多尺度残差学习有效恢复水下图像的纹理细节[15]；Islam 等进一步构建了 UFO-120 数据集，提出同时增强与超分辨率的联合框架[16]。Zhang 等提出的 AMPCNet 通过注意力引导多路径交叉 CNN 自适应聚焦水下目标关键区域[17]；Ren 等提出 URSCT，将增强型 Swin-ConvsTransformer 与卷积网络融合，实现了水下图像增强与超分辨率的协同优化[18]；Sharma 等提出的 DeepWaveNet 通过显式建模不同波长光在水中的衰减规律，在色彩复原方面取得了优异效果[19]；Chen 等提出 RDLN，通过多尺度特征提取与长短距离依赖关系协同学习，有效解决了水下图像局部失真与全局模糊并存的问题[20]；Chen 等提出渐进式注意力学习（PAL）方法，通过逐步细化的注意力策略分阶段恢复水下图像细节[21]；Cherian 等

提出 AlphaSRGAN 方法，在细节恢复与感知质量之间取得了良好平衡[22]；Pramanick 等则提出多分辨率多尺度注意力的水下图像复原方法，综合利用不同尺度特征实现细节重建[23]。2026 年的相关研究进一步将增强、显著性建模与超分辨率重建联合起来，DeFu-UIESR 采用显著性引导的双分支解耦融合框架同时处理水下图像增强与超分辨率；Wu 等提出的轻量化频域 Transformer 网络则从频率建模角度提升重建效率与细节保真度[24][25]。

在频域建模方面，Dharejo 等提出 SwinWave-SR，将 SwinTransformer 与小波变换相结合，在多尺度频率分解基础上轻量化实现了高质量水下图像超分辨率重建[26]；Chen 等提出的小波超分辨率方法将小波域信息引入水下图像重建，进一步丰富了频域建模的技术路线[27]；Wang 等将空间－频率互学习引入超分辨率网络，通过频域全局建模与空域局部建模的协同配合显著提升了精细纹理的重建能力，为本文频域－空域耦合设计提供了重要参考[28]。Zhou 等从图像分解角度提出了纹理－结构感知的图像分解神经网络模型，揭示了图像可被表达为纹理层与结构层之和的理论基础，为本文纹理－结构联合损失的设计奠定了理论依据[29]。在 Transformer 架构方面，Liu 等提出的 SwinTransformer 通过局部窗口注意力机制在线性计算复杂度下实现了全局信息感知，成为当前视觉超分辨率最重要的骨干网络之一[30]；Liang 等将 SwinTransformer 引入图像超分辨率框架提出 SwinIR，在通用场景下取得了当时领先的重建性能[31]。在水下 Transformer 方法方面，Wang 等提出基于频域 Transformer 的水下图像恢复方法[32]；Shen 等提出 UDAformer 基于双重注意力 Transformer 进行水下图像增强[33]；Peng 等提出 U 形 Transformer 应用于水下图像增强任务[34]，均从全局建模角度为水下图像质量提升提供了新思路。

综上可见，现有超分辨率方法在通用场景中已取得显著进展，但针对水下图像的频域先验利用仍不充分，且损失函数对图像纹理层与结构层的解耦监督尚不完善。本文正是针对上述不足，提出 FSCIN 网络，通过频域－空域协同建模与纹理－结构联合损失从两个维度系统化提升水下图像超分辨率重建质量，其输出结果将直接作为后续目标检测模块的高质量输入。

1.2.2 水下图像目标检测研究现状

目标检测是计算机视觉领域的核心任务，旨在同时完成图像中目标的定位与分类，在水下机器人导航、海洋生物监测和水下安防等应用中具有重要需求。当前深度学习目标检测方法按处理流程可分为两阶段检测和单阶段检测两大类。在两阶段检测方法方面，Girshick 等提出的 R-CNN 通过选择性搜索生成候选区域并利用卷积神经网络提取特征，开创了深度学习在目标检测领域的研究先河[35]；Girshick 进一步提出 FastR-CNN，通过共享

卷积特征图显著提升了检测效率[36]；Ren 等提出 FasterR-CNN，将区域建议网络（RPN）与检测网络端到端融合，在精度和速度上均取得了重要进展，成为两阶段检测方法的里程碑[37]。Lin 等提出的特征金字塔网络（FPN）通过自顶向下的语义路径与自底向上的位置信息路径实现多尺度特征融合，有效提升了对不同尺寸目标的检测能力，被广泛集成于各类检测框架[38]。在水下场景中，Jia 等提出改进 EfficientDet 的水下目标检测方法，并在 URPC 等数据集上对多类检测模型进行对比，验证了特征增强与多尺度融合对复杂水下场景目标识别的有效性，为后续水下检测研究奠定了基础[39]。

在单阶段检测方法方面，Redmon 等提出的 YOLO（YouOnlyLookOnce）将目标检测建模为单次前向推理的回归问题，以端到端方式同时输出目标位置与类别，在检测速度上实现了突破性提升[40]。此后 YOLO 系列持续迭代演化：Bochkovskiy 等提出 YOLOv4，引入 CSP 跨阶段部分连接网络与多种数据增强策略[41]；Jocher 等提出 YOLOv5，以轻量化设计提升工程可部署性[42]；Jocher 等提出的 YOLOv8 采用 C2f 模块替代原有 C3 模块、引入解耦检测头并优化 PAN-FPN 结构，在通用目标检测任务上取得了兼顾精度与效率的综合性能，被广泛应用于各类工程场景[43]。与 YOLO 并行发展的单阶段方法中，Liu 等提出的 SSD 通过在多尺度特征图上密集预测实现了更好的多尺度目标覆盖[44]；Lin 等提出的 RetinaNet 引入 FocalLoss 解决了单阶段检测中正负样本极度不平衡的问题，大幅提升了检测精度[45]。在特征增强与注意力机制方面，Hu 等提出的 SENet 通过通道注意力机制对不同语义通道施加自适应权重[46]；Woo 等提出的 CBAM 在通道注意力基础上串联空间注意力，进一步引导网络聚焦目标显著区域，有效抑制了水下背景杂波的干扰[47]。近年来的水下目标检测研究进一步围绕小目标、复杂背景与多尺度特征融合展开，YOLO-Starfish 通过改进 YOLOv8 提升海星目标检测精度，YOLO-MFD 则面向复杂水下环境引入动态检测头与多尺度特征融合策略，为本文后续目标检测改进提供了参考[48][49]。

在基于 Transformer 的检测方法方面，Dosovitskiy 等提出的 VisionTransformer（ViT）将图像划分为 Patch 序列后输入 Transformer 编码器，通过全局自注意力机制建立像素间的长程依赖关系，为视觉检测任务提供了更强的全局上下文建模能力[50]；Carion 等基于 Transformer 提出 DETR，以端到端方式实现目标检测，消除了传统锚框设计和非极大值抑制等复杂后处理步骤[51]；Zhu 等进一步提出可变形 DETR，引入可变形注意力机制解决了收敛慢和小目标检测弱的问题[52]。然而，Transformer 的二次计算复杂度在实时嵌入式水下平台上的部署仍面临挑战。针对这一局限，以 Mamba 为代表的状态空间模型（SSM）提供了新的技术路径：Gu 等提出的结构化状态空间模型（S4）证明了 SSM 在长序列建模中以

线性复杂度捕获长程依赖的可行性[53]；Gu 和 Dao 提出的 Mamba 引入选择性扫描机制，通过输入自适应的参数更新策略实现了比标准 Transformer 更高效的全局信息建模，以 O(L) 的线性复杂度取代了 Transformer 的 $O(L^2)$，为水下图像中因散射造成的全局模糊问题提供了有效的建模工具[54]。

综上，现有水下目标检测方法在通用场景下已取得较好效果，但在小目标精细感知、全局依赖建模以及多尺度特征自适应融合三个方面仍存在明显局限。值得特别指出的是，水下图像固有的低对比度与纹理退化问题会直接削弱检测网络的特征提取能力，仅依靠改进检测模型结构并不能从根本上解决输入图像质量不足的问题。因此，本文将超分辨率增强与目标检测两个任务统一于“原始图像→清晰化→清晰图像→目标检测→检测结果”的完整处理框架，从输入质量与模型能力两个维度协同提升水下目标检测系统的整体性能。

1.3 本文主要工作

针对水下图像质量退化以及目标检测精度不足等问题，本文围绕水下图像超分辨率重建与目标检测展开研究，构建了以“原始水下图像→超分辨率清晰化→高质量清晰图像→目标检测→检测结果”为完整处理链路的水下视觉感知框架，如图 1.3 所示。该框架的核心逻辑在于：第一阶段通过超分辨率增强从图像质量层面弥补水下退化的影响，第二阶段在高质量图像基础上执行目标检测，两者的串联协同使整体系统性能得到提升。具体研究路线如下图 1.3 所示。

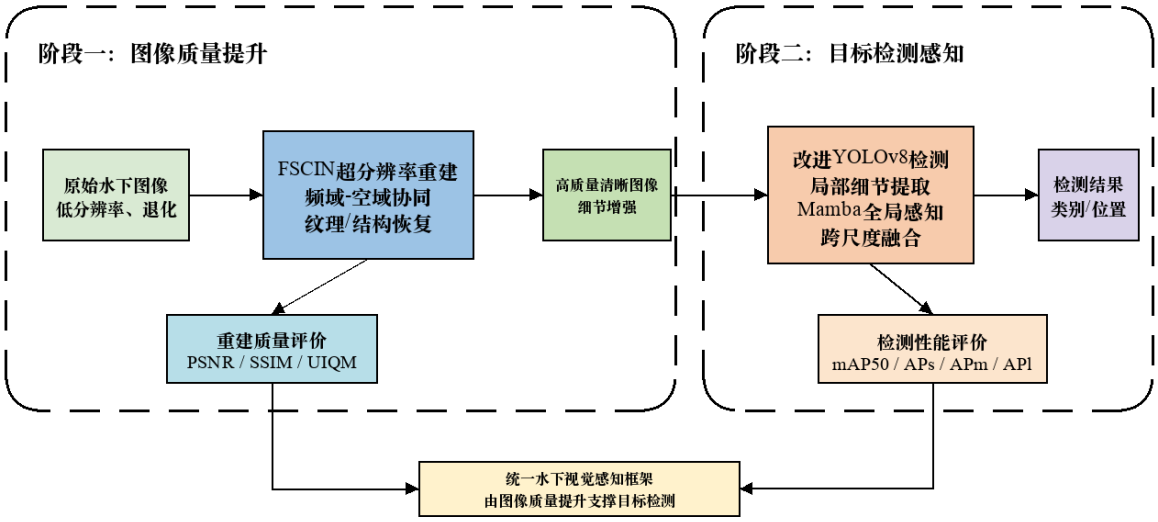


图 1.3 整体技术路线图

首先，针对水下图像存在的对比度不足、细节模糊和色彩偏差等退化问题，提出频域－空域耦合推理网络（FSCIN），设计空域－频域感知模块（SFAM）将快速傅里叶变换与

SwinTransformer 的空域编码相结合，实现频域全局先验与空域局部特征的深度融合；同时引入纹理－结构联合损失函数，对图像纹理层和结构层分别施加针对性约束，显著提升水下图像的感知质量与细节保真度。FSCIN 的输出高质量清晰图像将直接作为目标检测阶段的输入，构成整体框架的前端处理模块。

其次，在 FSCIN 输出的高质量清晰图像基础上，对 YOLOv8 模型进行针对性改进，设计细粒度特征提取模块（FFEM）替代原始 C2f 模块，该模块由通道－空间自适应增强模块、基于 Mamba 的全局感知模块和多尺度交叉注意力融合模块三个子模块协同构成，分别从局部细粒度感知、全局长程依赖建模和跨尺度特征动态融合三个维度提升对水下目标的检测能力。

最后，通过在 USR-248、UFO-120（超分辨率重建）和 URPC2021（目标检测）公开数据集上的系统实验，分别验证 FSCIN 和改进 YOLOv8 的有效性，并分析超分辨率预处理对目标检测性能的实际改善效果，以量化评估“增强－检测”串联框架的整体收益。

1.4 论文组织结构

本文主要围绕水下图像超分辨率重建与目标检测方法展开研究，论文结构安排如图 1.4 所示。

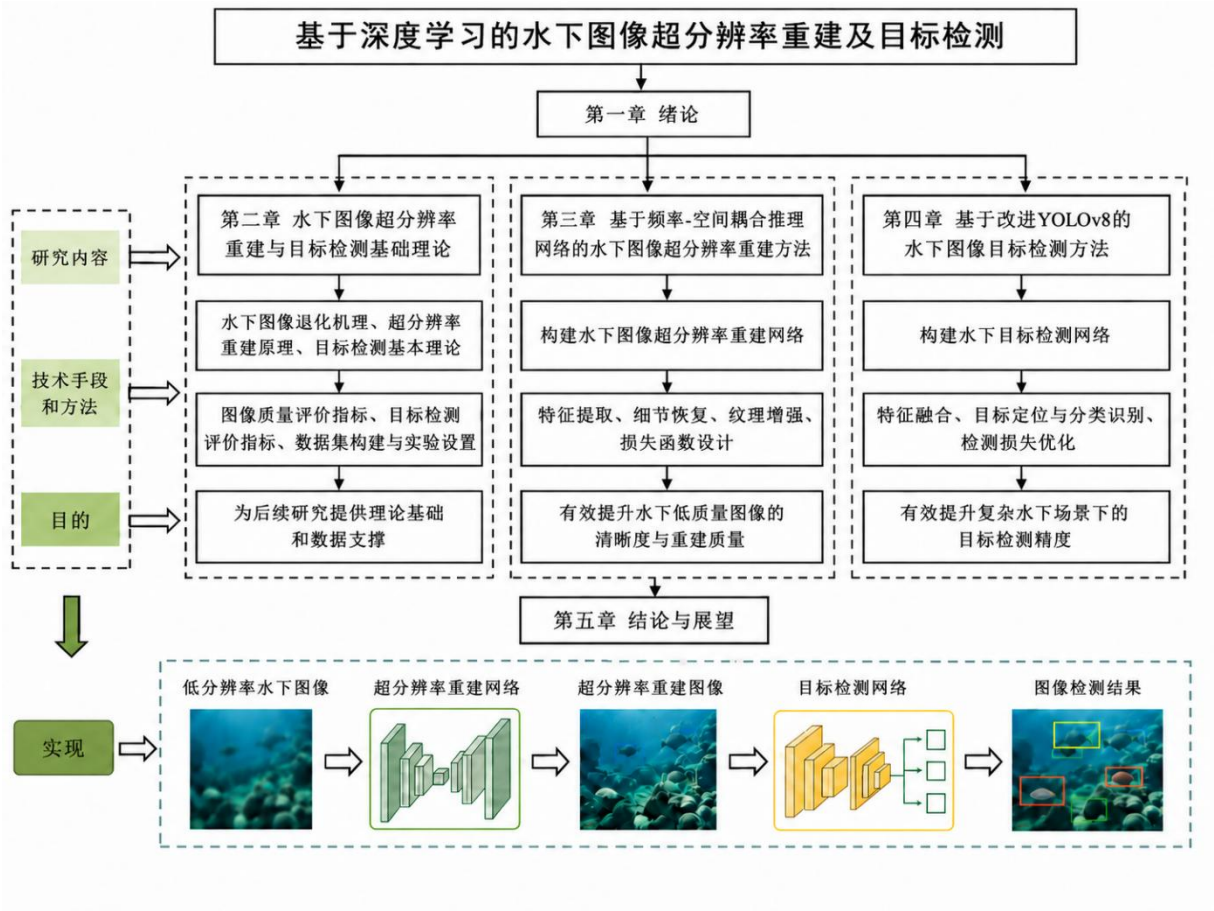


图 1.4 论文组织架构图

第一章为绪论，介绍研究背景与意义，综述水下图像超分辨率重建与目标检测两个方向的国内外研究现状，阐明本文“增强－检测”串联框架的整体技术思路，并给出论文的主要研究内容和组织结构。

第二章为相关理论基础，介绍水下图像退化模型、超分辨率重建原理以及深度学习核心模块（包括卷积神经网络、Transformer 模型、Mamba 模型和目标检测理论），为后续章节提供理论支撑。

第三章为本文“增强－检测”框架的第一阶段工作，提出基于频域－空域耦合推理网络（FSCIN）的水下图像超分辨率重建方法，详述网络结构设计、SFAM 核心模块与纹理－结构联合损失。本章的输出高质量清晰图像直接作为第四章目标检测的输入，构成整体框架的前端处理模块。

第四章为本文“增强－检测”框架的第二阶段工作，在第三章超分辨率增强图像的基础上，提出基于改进 YOLOv8 的水下目标检测方法，详述 FFEM 模块的设计与实验验证。

第五章对全文工作进行总结，分析两个核心模块在完整“增强－检测”框架中的协同作用，并对未来研究方向进行展望。

第二章 相关理论基础

2.1 深度学习理论基础

2.1.1 卷积神经网络

（1） 基本原理

如图 2.1 所示，人工神经网络（Artificial Neural Network，ANN）是一类模拟生物神经系统信息处理机制而建立的计算模型，其核心思想是通过大量神经元之间的连接关系来实现复杂数据的建模与学习过程。一个神经元通常接收多个输入信号，并对其进行加权求和，再经过非线性激活函数映射后得到输出结果。其中 x_i 表示第 i 个输入信号，w_i 表示对应的权值参数，b 为偏置项，$f(\cdot)$为非线性激活函数。

该计算过程可表示为：

$$y=f\left(\sum_{i=1}^{n} x_i w_i + b\right) \tag{2.1}$$

随着研究的不断深入，学者们相继提出了多种神经网络结构，例如感知机、玻尔兹曼机、受限玻尔兹曼机以及多层感知机等模型。1986 年，Rumelhart 等学者将反向传播算法（Back Propagation，BP）应用于多层感知机的训练过程中，使神经网络能够通过梯度下降方法自动调整权重参数，从而显著推动了神经网络在机器学习领域的发展[55]。

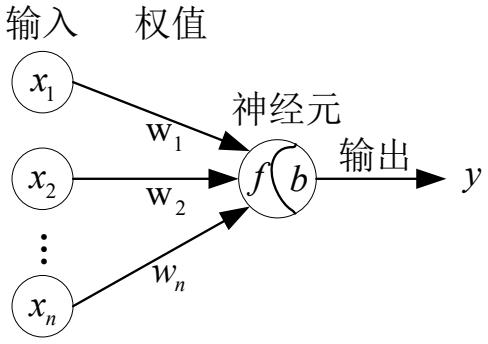


图 2.1 人工神经网络

BP 网络通常由输入层、隐藏层以及输出层构成。在前向传播阶段，输入数据逐层传递并生成预测结果；若预测值与真实值之间存在误差，则该误差通过反向传播机制逐层回传，同时利用梯度下降策略更新网络参数，经过多次迭代后使误差逐渐减小。然而，当网络层数较深时，BP 算法容易出现梯度消失或梯度爆炸等问题，从而影响模型训练效果。

为了克服传统神经网络在图像处理任务中的局限，LeCun 等研究人员提出了卷积神经网络（ConvolutionalNeuralNetwork，CNN），该模型借鉴了生物视觉系统中的“感受野”概

念，通过局部连接和权值共享机制显著减少模型参数数量，同时提升特征提取能力[56]。与传统全连接网络相比，CNN 能够更加高效地捕获图像中的局部结构信息，例如边缘、纹理以及形状等特征，因此在计算机视觉领域得到了广泛应用。此外，He 等提出残差网络（ResNet），通过残差连接缓解深层网络训练退化问题[57]。Kim 等提出深度递归卷积网络（DRCN），利用递归结构扩大感受野并增强特征表达[58]。Huang 等提出 DenseNet，通过密集连接增强特征复用与梯度传播[59]。Tong 等将密集跳跃连接引入图像超分辨率任务，提出 SRDenseNet 以提升高频细节重建能力[60]。

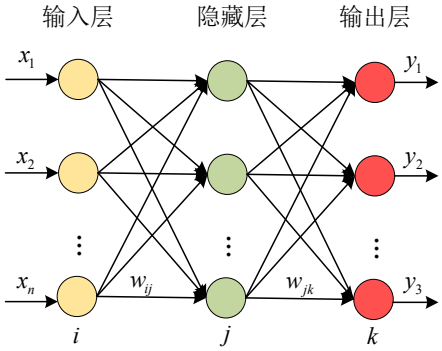


图 2.2 多层感知机

（2） 基本结构

卷积神经网络通常由卷积层、池化层、激活函数层以及全连接层等部分组成，各结构相互协作以实现从低层特征到高层语义信息的逐步提取。

卷积层

卷积层是卷积神经网络中最关键的组成部分，其主要作用是自动从输入图像中提取特征信息。该过程模拟了人类视觉系统对局部区域的关注机制，使模型能够聚焦于图像中的重要信息区域。多个卷积层按照层级结构依次堆叠，从而逐步完成由浅层特征到深层特征的提取过程。

在网络的浅层阶段，卷积层主要捕捉图像中的低级特征，例如颜色变化和纹理结构；随着网络深度的增加，卷积层逐渐学习更高层次的抽象特征，例如目标的形状及语义信息。每一层卷积通常由多个卷积核构成，常见的卷积核尺寸为 3×3，该尺寸在保证表达能力的同时有效减少参数数量，因此被广泛应用。

设输入矩阵为I，卷积核为K，卷积核大小为$m\times n$，输出特征图为O，*为卷积运算，则二维卷积运算可表示为：

$$O(i,j)=(K*I)(i,j)=\sum_{m}\sum_{n}I(i-m,j-n)K(m,n) \tag{2.2}$$

在实际计算中，卷积神经网络采用的通常是互相关运算，其表达形式可写为：

$$O(i,j)=(K*I)(i,j)=\sum_{m}\sum_{n}I(i+m,j+n)K(m,n) \tag{2.3}$$

卷积过程示意如图 2.3 所示。输出特征图的尺寸通常小于输入尺寸，其计算方式如下：

$$h_{out}=\frac{h_{in}-k+2p}{s}+1;w_{out}=\frac{w_{in}-k+2p}{s}+1 \tag{2.4}$$

其中：h_{in}、w_{in}为输入特征图尺寸h_{out}、w_{out}为输出特征图尺寸k为卷积核大小p为填充（padding）大小，s为步长。由于边缘像素参与计算的次数较少，可能导致边界信息损失，因此在实际应用中通常在输入图像边界补零，以减弱边缘信息缺失的问题。

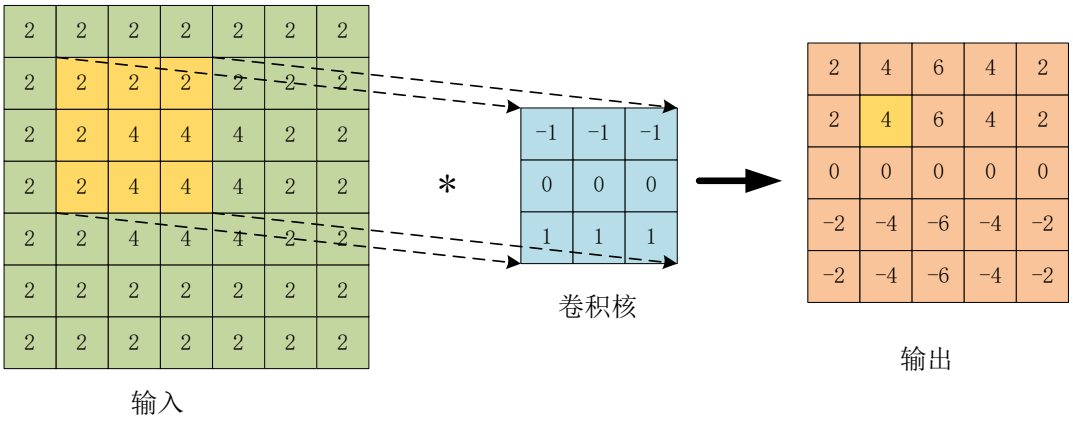


图 2.3 卷积运算

池化层

当卷积层数量增加时，网络会生成大量特征图，这不仅会显著提升计算复杂度，还可能导致存储开销过大。为此，引入池化层对特征图进行降采样处理，从而减少特征维度并降低计算负担。池化操作通常会将特征图的空间尺寸缩小，例如将宽度和高度缩减为原来的二分之一，从而减少模型参数数量。同时，池化层还能够扩大感受野，提高模型对图像平移的鲁棒性。常见的池化方式主要包括：平均池化（AveragePooling）：对区域内像素求平均值，能够保留整体背景信息；最大池化（MaxPooling）：选取区域内最大值，更有利于突出显著特征

池化操作示意如图 2.4 所示。

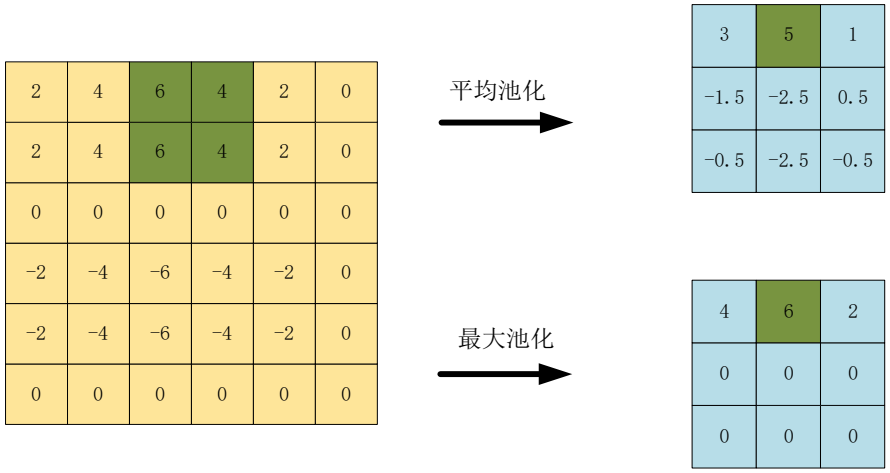


图 2.4 池化操作

全连接层

全连接层通常位于卷积神经网络的末端，其主要功能是将前面卷积层提取到的特征映射为最终的分类结果。在该层中，每一个神经元都会与上一层所有神经元建立连接，从而实现全局信息整合。增加全连接层的神经元数量可以提升模型的表达能力，但同时也会显著增加计算成本，并可能导致模型过拟合。因此，在实际设计中需要在模型性能与复杂度之间进行权衡。

激活函数层

卷积操作本质上属于线性变换，仅依赖线性操作难以描述复杂的数据分布关系。因此，在卷积神经网络中引入激活函数以增强模型的非线性表达能力，使其能够处理更复杂的任务。常见激活函数如下：

Sigmoid 函数：

$$\sigma(x)=\frac{1}{1+e^{-x}} \tag{2.5}$$

该函数呈“S”形曲线，图像如图 2.5 所示，可将输入压缩至(0,1)区间，有助于稳定模型输出。然而，当输入值过大或过小时，函数梯度趋近于 0，容易导致梯度消失问题。此外，其输出均值不为 0，会降低网络收敛速度。

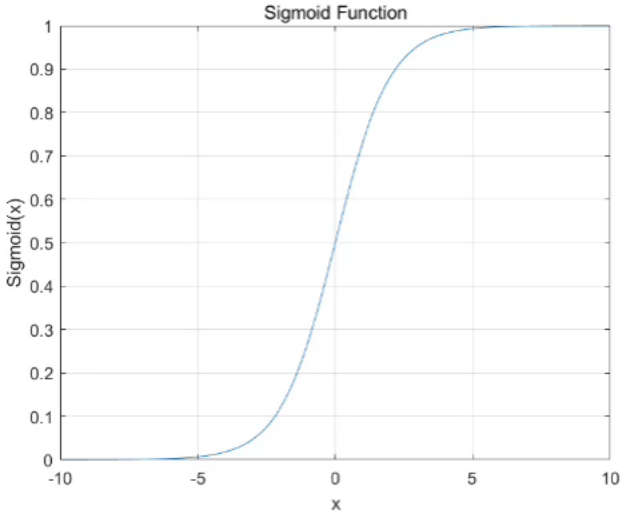


图 2.5 Sigmoid 函数

Tanh 函数：

$$Tanh(x)=\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}} \tag{2.6}$$

该函数形状和 Sigmoid 函数类似，图像如图 2.6 所示，输出范围为(−1,1)，其均值为 0，在一定程度上提高了训练效率。但其在大输入范围内同样会出现梯度消失现象，同时计算复杂度较高。

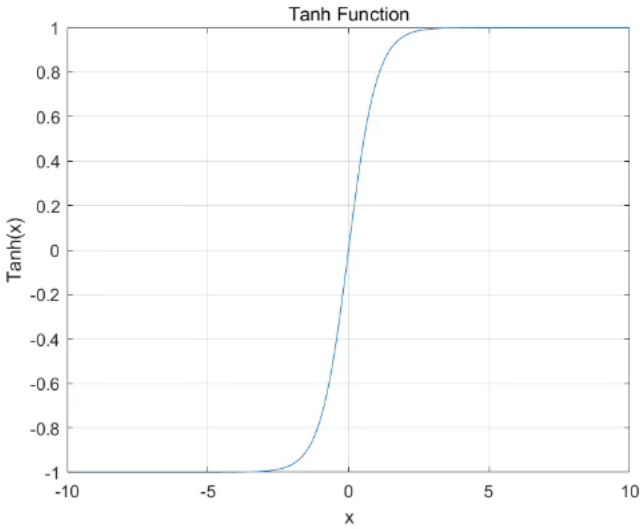


图 2.6 Tanh 函数

ReLU 函数：

$$f(x)=max(0,x) \tag{2.7}$$

ReLU 函数计算简单，其函数图像如图 2.7 所示，在 x>0 时梯度恒为 1，因此能够有效缓解梯度消失问题，并提高计算效率。但当输入为负值时，神经元可能长期不激活，出现“神经元死亡”现象。

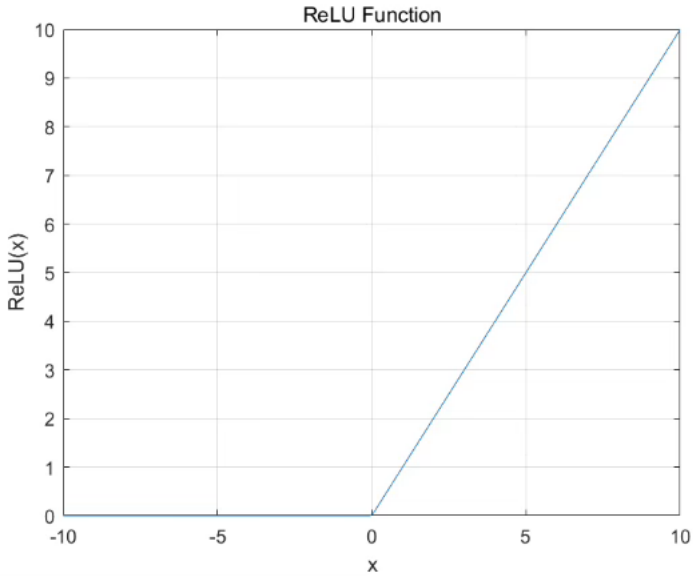


图 2.7 ReLU 函数

2.1.2 Transformer 模型

2017 年，Vaswani 等提出了 Transformer 模型，其整体结构如图 2.8 所示。该模型在机器翻译等序列建模任务中显著提升了处理效率与结果精度[61]。

在 Transformer 结构中，自注意力机制（Self-Attention）是最核心的组成部分。该机制通过构建查询向量Q、键向量K和值向量V来实现信息交互。其中，Q用于表示当前需要关注的词，K用于表示序列中各词的位置特征，V则包含具体的语义信息。这三个向量均由输入数据通过线性变换得到。最终，Self-Attention 的计算形式如下：

$$Attention(Q,K,V)=softmax(\frac{QK^T}{\sqrt{d_K}})V \tag{2.8}$$

其中：K^T为向量K的转置，Q与K的内积用于衡量当前词与其他位置之间的相关性，该结果反映了待处理词与序列中各位置的联系程度。$\sqrt{d_K}$为缩放因子，用于防止内积数值过大而影响训练稳定性，$softmax$用于归一化权重。最后将归一化结果与 V 相乘，从而得到包含上下文信息的输出表示。在此基础上，Transformer 进一步引入多头注意力机制（Multi-headAttention），通过在多个子空间中并行计算注意力结果，从不同角度捕捉特征之间的关系，并最终进行拼接融合，形成 Transformer 模块的最终输出。

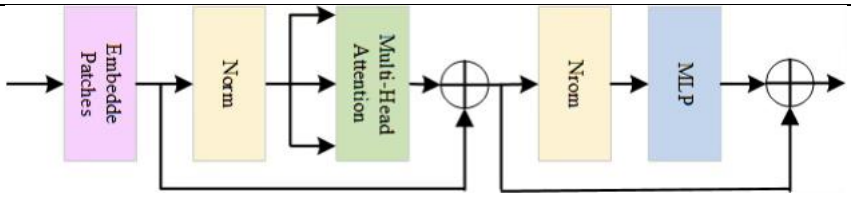


图 2.8 Transformer 模型

随着 Transformer 在自然语言处理领域取得成功，Dosovitskiy 等人于 2020 年提出了视觉 Transformer 模型（VisionTransformer,ViT）[50]，将该结构推广至图像分类、语义分割等计算机视觉任务中，并取得了与主流卷积神经网络相当的性能表现。此后，Transformer 逐渐成为视觉领域的重要研究方向之一，在多个任务中展现出优于传统 CNN 模型的潜力。

与卷积神经网络依赖局部感受野不同，视觉 Transformer 通过 Self-Attention 机制能够直接建立输入特征之间的全局关系，从而更全面地刻画图像的上下文信息。这种基于全局建模的方式，使得模型在处理复杂场景时具有更强的表达能力。

在具体实现上，Transformer 通常采用多头 Self-Attention 机制，将输入特征映射到多个子空间中进行并行计算，以获取不同维度下的注意力分布。各个子空间的计算结果随后被拼接并融合，从而提升模型对特征关系的刻画能力。此外，由于 Self-Attention 本身不具备位置信息感知能力，因此需要额外引入位置编码（PositionalEncoding）来补充序列中的空间或顺序信息。

尽管 Transformer 具备良好的建模能力，但其 Self-Attention 计算复杂度随着输入序列长度呈平方增长。当序列长度为 L 时，多头 Self-Attention 的计算复杂度为：$O(N \cdot L^2 d)$，其中，d表示特征维度。这种计算特性在处理高分辨率图像时会带来较大的资源消耗。为缓解该问题，Dosovitskiy 等人提出将图像划分为多个子块（Patch）作为输入，从而降低计算规模。但在需要精细建模的高分辨率任务中，该方法仍然存在一定局限性。

2.1.3 Mamba 模型

近年来，随着长序列建模任务在自然语言处理与计算机视觉领域中的广泛应用，传统基于注意力机制的模型在计算复杂度方面逐渐暴露出局限性。针对这一问题，基于视觉空间模型（Visual SSM，VSSM）的建模方法逐渐受到研究者关注。在此背景下，Gu 等人提出了 Mamba 模型，该模型通过引入选择性状态空间机制，实现了对长序列数据的高效建模[54]，其结构图如图 2.9 所示。由图可以看出输入特征通过两条平行路径进行处理。第一条路径中，特征通道首先通过线性映射扩展通道，随后经深度卷积（depth-wiseconvolution）与 SiLU 激活函数处理，最终通过 2D 选择扫描模块（2D Selective Scan Module,2D-SSM）与 LayerNorm 层进一步处理。在第二条路径中，输入特征首先经过线性映射与激活函数处

理。两条路径的输出通过 Hadamard 乘积进行融合，随后再通过线性映射投影回原始通道，得到最终输出特征。

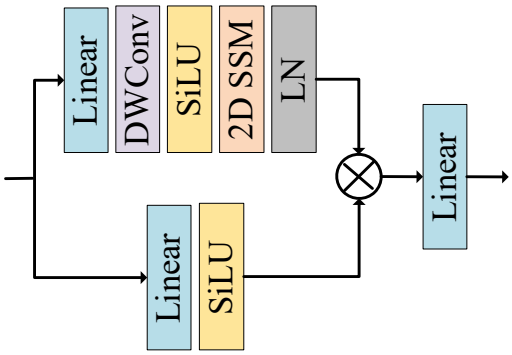


图 2.9 VSSM 架构图

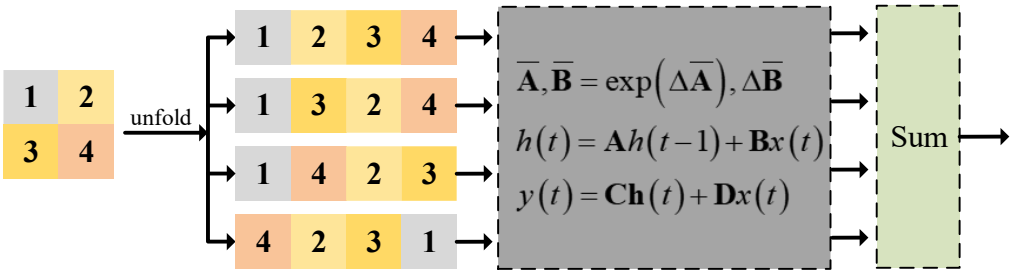


图 2.102D 选择扫描模块

如图 2.10 所示，首先将二维图像特征沿四个扫描方向展开为一维序列，随后采用离散状态空间方程对序列进行长时依赖建模。最终，将各方向序列求和并重塑为原二维特征格式。该设计能够有效保留图像空间信息，同时增强特征提取能力。其基本形式可表示为：

$$h_t = A \cdot h_{t-1} + B \cdot x_t \tag{2.9}$$

$$y_t = C \cdot h_t + D \cdot x_t \tag{2.10}$$

其中，x_t表示输入序列，h_t表示隐藏状态，y_t表示输出结果，A、B、C、D为模型参数矩阵。通过上述递推关系，模型能够在时间维度上逐步更新状态，从而捕获序列中的长期依赖信息。

与传统 Transformer 模型相比，Mamba 的核心创新在于引入选择性扫描机制。该机制能够根据输入特征动态调制状态更新过程，使模型在序列建模时更加关注关键信息，从而突破传统状态空间模型参数固定、表达能力受限的问题。

在计算复杂度方面，Transformer 中的 Self-Attention 需要对序列中任意两个位置进行交互建模，复杂度为 $O(L^2)$；而 Mamba 通过线性递推方式完成状态更新，复杂度降低为 $O(L)$，其中 L 表示序列长度。因此，Mamba 在处理长序列或高分辨率视觉特征时具有更低的计算开销和显存占用。

从建模能力来看，Mamba 兼具局部特征提取与全局依赖建模优势。一方面，其状态更新过程能够捕获局部上下文信息；另一方面，状态传递机制可以在序列维度上累积长距离信息。针对图像二维空间结构，2D 选择扫描模块进一步沿水平和垂直方向进行双向扫描，在保持线性复杂度的同时覆盖更充分的空间依赖关系。

因此，Mamba 适合用于水下图像增强与目标检测等复杂视觉任务。水下图像通常存在对比度低、噪声干扰强和目标边缘模糊等问题，需要模型同时具备细粒度特征感知和全局结构理解能力。尽管 Mamba 在视觉任务中的性能仍依赖具体网络结构设计，但将其与卷积网络或注意力结构结合，能够在计算效率与特征表达能力之间取得较好平衡。

2.2 水下图像超分辨率理论分析

2.2.1 水下图像退化模型

在水下环境中，光线传播过程会受到吸收效应与散射效应的共同影响，这两种因素是导致水下图像质量下降的主要原因。吸收效应是指光在水体中传播时，一部分能量会被水分子以及水中的溶解物质吸收，从而使光强逐渐衰减。由于不同波长的光在水中的吸收速率不同，例如蓝光的衰减速度相对较慢，因此水下图像通常呈现出明显的蓝绿色偏色现象。散射效应则是当光线在传播过程中遇到水中的悬浮颗粒或其他微小物质时，传播方向会发生改变，从而使图像出现模糊或亮度变化等现象。根据 Jaffe-McGlamery 水下图像成像模型如图 2.11 所示。根据散射方向的不同，可以将其分为前向散射和后向散射两种形式。前向散射会改变光线的传播路径，使图像边缘变得模糊，而后向散射则会将部分光线反射回摄像设备，从而产生光晕效应并降低图像清晰度。在综合考虑光吸收与散射两种因素的情况下，水下图像退化过程通常可以通过经典的水下成像模型进行描述，其数学表达式如下：

$$I(x,y)=J(x,y)T(x,y)+A\big(1-T(x,y)\big) \tag{2.11}$$

其中，$I(x,y)$表示观测到的退化水下图像，$J(x,y)$表示理想情况下的清晰场景图像，$T(x,y)$表示透射图，用于描述光线在传播过程中的衰减比例；A表示背景光强度，用于表示散射光进入摄像设备的部分；x,y表示图像像素的位置坐标。

透射图$T(x,y)$通常与水体的衰减特性以及物体与摄像设备之间的距离有关，其表达式可以进一步表示为：

$$T(x,y)=e^{-\beta(d(x,y))} \tag{2.12}$$

其中，β表示水体的总衰减系数，该系数通常由光的吸收系数a和散射系数b组成，即$\beta=a+b$；$d(x,y)$表示光在水体中的传播距离，该距离通常与水下场景的深度以及观测角度有关。

通过上述模型可以看出，水下图像质量退化主要来源于光能衰减以及散射干扰，因此在进行水下图像处理时，需要通过相应的算法恢复真实场景信息，从而提高图像质量。

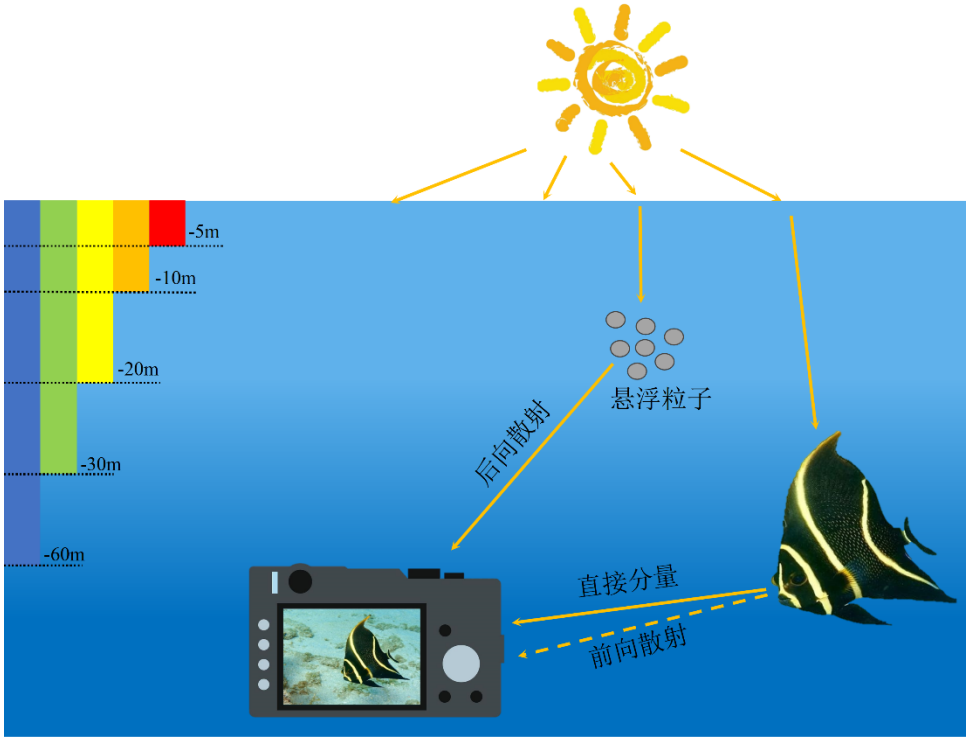


图 2.11 Jaffe-McGlamery 水下图像成像过程

2.2.2 水下图像超分辨率重建原理

水下图像在采集过程中往往存在分辨率低、细节缺失以及纹理信息不足等问题，因此需要通过超分辨率技术对图像进行重建，以获得更高质量的视觉信息。超分辨率重建是指通过算法从低分辨率图像中恢复出高分辨率图像的过程，其核心目标是重建图像中的高频细节信息，使图像在视觉上更加清晰。目前，图像超分辨率重建方法主要分为传统插值方法和基于深度学习的方法。在图像超分辨率技术的发展过程中，基于插值的方法一直具有重要地位。其核心思想是通过数学插值在已知像素点之间估计并填充未知像素值，从而实现图像分辨率的提升。

（1） 双线性插值

双线性插值是一种在二维空间进行插值的方法，通过在两个方向上分别进行线性插值来计算目标像素点的值。具体而言，对于一个需要插值的像素点，双线性插值首先考虑这个像素点周围的四个邻近像素点。然后，它在水平方向上对两对相邻的像素点分别进行一次线性插值，接着在竖直方向上对得到的两个插值结果进行一次线性插值，从而得到目标像素点的插值结果。

计算示意图如图 2.12 所示，计算过程如下：假设想要得到的像素点$R(x,y)$的值，该像素点周围的四个点$P_{11}(x_1,y_1)$，$P_{12}(x_1,y_2)$，$P_{21}(x_2,y_1)$，$P_{22}(x_2,y_2)$值已知，则在 x 方向上对这四个点进行线性插值，得到Q_1和Q_2：

$$Q_1 = f(P_{11})\frac{x_2 - x}{x_2 - x_1} + f(P_{21})\frac{x - x_1}{x_2 - x_1} \tag{2.13}$$

$$Q_2 = f(P_{12})\frac{x_2 - x}{x_2 - x_1} + f(P_{22})\frac{x - x_1}{x_2 - x_1} \tag{2.14}$$

然后在 y 方向上对Q_1和Q_2进行线性插值，得到$R(x,y)$的值：

$$R = Q_1\frac{y_2 - y}{y_2 - y_1} + Q_2\frac{y - y_1}{y_2 - y_1} \tag{2.15}$$

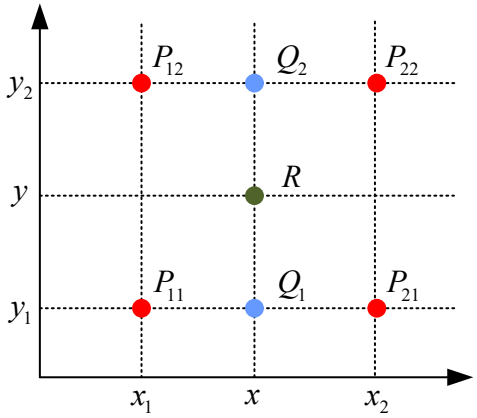


图 2.12 双线性插值计算示意图

（2） 双三次插值

双三次插值相较于双线性插值，它在图像的放大和缩小处理中能够提供更平滑的边缘和更高的图像质量。具体操作如下：对于一个需要插值的像素点$P(x,y)$，需要综合考虑与其相邻的最近的十六个像素点的数值，并分别在两个方向上进行一次三次插值来得到最终值。

计算示意图如图 2.13 所示，计算过程如下：

$$W_x = \begin{cases} (a+2)|x|^3 - (a+3)|x|^2 + 1 & for\ |x| \le 1 \\ a|x|^3 - 5a|x|^2 + 8a|x| - 4a & for\ 1 < |x| < 2 \\ 0 & otherwise \end{cases} \tag{2.16}$$

其中W_x为插值内核函数公式，根据上述公式可以计算 x 轴方向相邻四个像素点的数值W_x，同理可得y方向相邻四个像素点的数值W_y。则插值$P(x,y)$计算公式可以如下表示：

$$P = W_x \cdot Q \cdot W_y^T \tag{2.17}$$

$$W_x = [W_{x_1}\ W_{x_2}\ W_{x_3}\ W_{x_4}] \tag{2.18}$$

$$W_y = [W_{y_1}\ W_{y_2}\ W_{y_3}\ W_{y_4}] \tag{2.19}$$

$$Q = \begin{bmatrix} Q_{11} & Q_{12} & Q_{13} & Q_{14} \\ Q_{21} & Q_{22} & Q_{23} & Q_{24} \\ Q_{31} & Q_{32} & Q_{33} & Q_{34} \\ Q_{41} & Q_{42} & Q_{43} & Q_{44} \end{bmatrix} \tag{2.20}$$

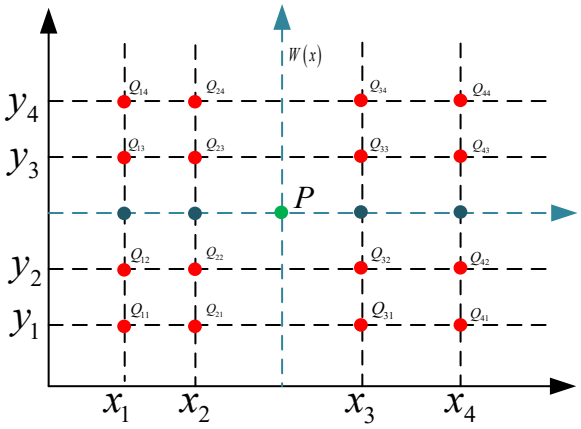


图 2.13 双三次插值计算示意图

（3） 反卷积上采样

反卷积（Deconvolution）是一种独特的卷积形式，用于从低分辨率图像特征映射预测其对应的高分辨率图像[62]。具体操作过程如下：首先边缘填充来按比例扩大特征图尺寸开始，然后采用适当大小的卷积核和步长进行卷积运算，以产生预期尺寸的 HR 图像。反卷积的上采样计算过程如图 2.14 所示。图中蓝色网格代表输入的 LR 图像特征图，绿色矩形则代表卷积操作。反卷积上采样结合了传统卷积特性和端到端的图像重建优势，在图像超分辨率领域得到了广泛应用。然而，如果卷积核尺寸与步长不成比例，可能会引起生成图像中的不均匀混叠现象。

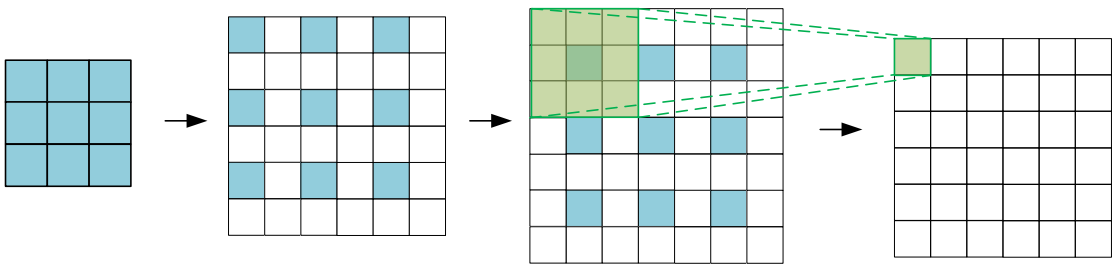


图 2.14 反卷积上采样示意图

（4） 亚像素上采样

亚像素上采样技术（Sub-pixel）提供了一种基于端到端学习的可行上采样策略[63]。这种方法利用卷积操作增加通道数，并在通道层面重组像素来实现空间尺寸的放大。具体的

计算流程如图 2.15 所示。以低分辨率图像的特征映射为例，其输入尺寸设定为$h \times w \times c$，比例因子为s，该技术首先使用卷积操作生成s^2倍的通道数，此时的特征映射尺寸变为$h \times w \times s^2c$。随后，进行通道重组的操作，该步骤通过一种周期性筛选的方式，将新产生的通道中的像素填补到原始的特征映射中，以此实现长宽的放大，并将特征映射尺寸从$h \times w \times s^2c$降维到$sh \times sw \times c$，完成了s倍的放大过程。

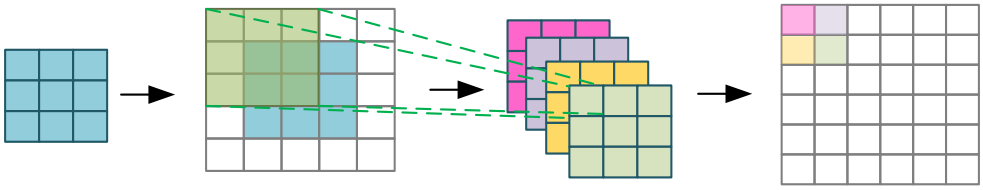


图 2.15 亚像素上采样示意图

随着深度学习的发展，基于学习的图像超分辨率重建方法的基本思想是借助机器学习理论，从大量训练样例中学习 LR 图像和对应的 HR 图像之间的映射关系，以此来恢复 LR 图像中丢失的高频信息，达到重建 HR 图像的目的，其方法流程如图 2.16 所示。该方法通过学习低分辨率图像与高分辨率图像之间的非线性映射关系，实现对图像细节信息的重建。

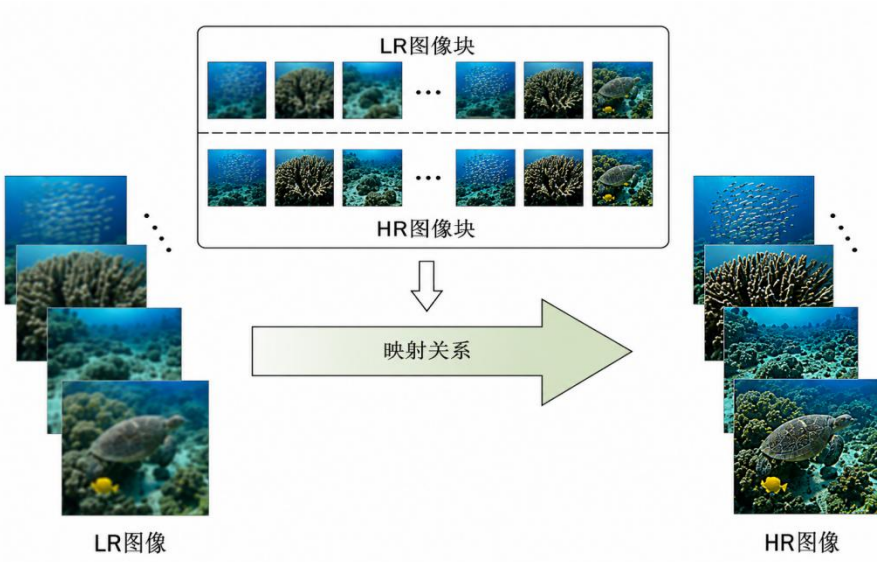


图 2.16 基于学习的图像超分辨率重建方法流程图

假设训练数据集中存在一组样本$\{(I_i,J_i)\}_{i=1}^{N}$，其中I_i表示第i个低分辨率水下图像，而J_i表示对应的高分辨率图像。超分辨率模型的目标是学习一个映射函数$f(I;\theta)$，从而实现低分辨率图像I到高分辨率图像$\hat{J}$的转换：

$$\hat{J}=f(I;\theta) \tag{2.21}$$

其中，f表示深度学习模型，θ表示模型参数，包括网络中的卷积核权重以及偏置参数。

在实际的深度学习模型f中，首先通过多层卷积网络对图像特征进行提取。假设网络包含L个卷积层，则第L层卷积层的输出可以表示为：

$$F_l=\sigma(W_l*F_{l-1}+b_l) \tag{2.22}$$

$$F_0=I \tag{2.23}$$

其中，F_l表示第l层生成的特征图，F_{l-1}为上一层的输入特征图，W_l与b_l分别表示第l层卷积核的权重参数和偏置项，σ为非线性激活函数（例如 ReLU 函数），$*$表示卷积运算。

通过逐层卷积运算，网络能够逐步提取图像中的纹理、边缘以及语义特征信息。在完成特征提取之后，网络需要通过上采样模块逐步提升特征图的空间分辨率，使其接近目标高分辨率图像。常见的上采样方法包括转置卷积（Deconvolution）、像素重排（PixelShuffle）以及插值上采样等方式。其中，PixelShuffle 通过亚像素卷积实现高效重建[63]。小波方向自适应插值则为传统插值上采样提供了频域建模参考[64]。经过上采样操作后，最后一层卷积层会将特征图映射为最终预测的高分辨率图像。在模型训练阶段，需要构建损失函数来衡量模型输出结果与真实高分辨率图像之间的差异程度。通过最小化该损失函数，可以不断优化模型参数，使预测图像逐渐接近真实图像。

训练过程中通常采用反向传播算法计算损失函数关于模型参数的梯度，并利用优化算法对参数θ进行更新。模型参数的更新过程通常从随机初始化开始，通过不断迭代调整参数，使损失函数逐渐减小。当模型在验证集上的性能趋于稳定，即损失值不再明显下降时，训练过程即可结束。在众多优化算法中，Adam（Adaptive Moment Estimation）优化器被广泛应用于深度学习模型训练。该方法通过结合梯度的一阶矩估计和二阶矩估计，对每个参数的学习率进行自适应调整，从而在保证收敛速度的同时提高训练稳定性。给定模型参数θ及其梯度g_t，Adam 优化过程可以表示为：

$$m_t=\beta_1 m_{t-1}+(1-\beta_1)g_t \tag{2.24}$$

$$v_t=\beta_2 v_{t-1}+(1-\beta_2)g_t^2 \tag{2.25}$$

$$\hat{m}_t=\frac{m_t}{1-\beta_1^t} \tag{2.26}$$

$$\hat{v}_t=\frac{v_t}{1-\beta_2^t} \tag{2.27}$$

$$\theta_{t+1}=\theta_t-\frac{\eta}{\sqrt{\hat{v}_t}+\epsilon}\hat{m}_t \tag{2.28}$$

其中，m_t表示梯度的一阶矩估计（动量项），v_t表示梯度的二阶矩估计；β_1与β_2为指数衰减系数；η为学习率；ϵ为防止分母为零的极小常数，通常取值为10^{-8}；$\hat{m}_t$与$\hat{v}_t$分别表示经过偏差修正后的动量估计与二阶矩估计；最终得到更新后的参数θ_{t+1}。

通过这种自适应更新机制，Adam 优化器能够在训练过程中保持较稳定的学习率变化，从而提升模型训练效率和收敛性能。

2.3 目标检测理论基础

目标检测（ObjectDetection）是计算机视觉领域的重要研究方向之一，其主要任务是在图像中定位并识别感兴趣目标，即同时完成“分类（Classification）”与“定位（Localization）”两项任务。与传统图像分类仅输出类别标签不同，目标检测需要输出目标的位置及类别信息，因此具有更高的复杂性。

在实际应用中，目标检测模型的输出通常由边界框（BoundingBox）与类别标签组成。边界框一般采用如下形式进行表示：

$$B = (x, y, w, h) \tag{2.29}$$

其中：x、y 表示目标中心点坐标，w、h 表示目标框的宽度与高度

为了评估检测结果的准确性，通常采用交并比（IntersectionoverUnion，IoU）作为评价指标，其计算方式如下：

$$IoU = \frac{Area(B_{pred} \cap B_{gt})}{Area(B_{pred} \cup B_{gt})} \tag{2.30}$$

其中，B_{pred}表示预测框，B_{gt}表示真实标注框。IoU值越大，说明预测结果越接近真实目标位置。

2.3.1 两阶段目标检测方法

两阶段目标检测方法（Two-stage Detector）通常先生成候选区域（Region Proposal），再对候选区域进行分类与回归预测，其结构图如图 2.17 所示。典型代表包括 R-CNN、FastR-CNN 以及 FasterR-CNN 等模型。

R-CNN 首先通过选择性搜索（Selective Search）生成候选区域，然后利用卷积神经网络提取特征并进行分类。然而，该方法存在计算效率较低的问题。为此，FastR-CNN 通过共享卷积特征图显著提高了检测速度，而 FasterR-CNN 进一步引入区域建议网络（Region Proposal Network，RPN），实现候选区域的端到端学习，从而大幅提升检测效率与精度。

两阶段方法的主要优点在于检测精度较高，尤其适用于对检测精度要求较高的任务。但其缺点是计算复杂度较大，难以满足实时性需求。

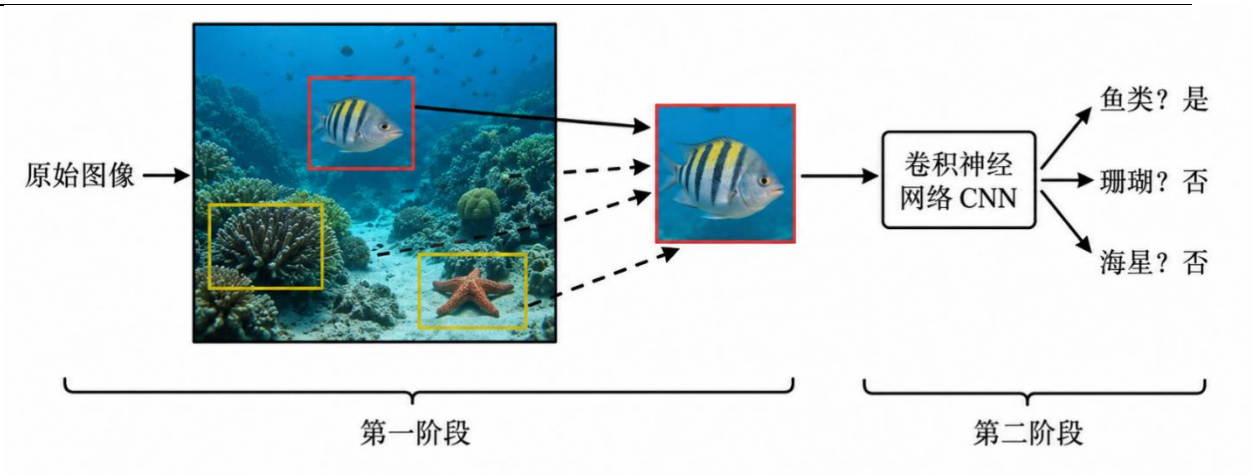


图 2.17 两阶段图像目标检测结构图

2.3.2 单阶段目标检测方法

与两阶段方法不同，单阶段目标检测（One-stage Detector）将目标定位与分类过程统一到一个网络中完成，从而显著提高检测速度，其结构图如图 2.18 所示。代表性模型包括 YOLO（You Only Look Once）系列与 SSD（Single Shot Multi Box Detector）等。

YOLO 模型将输入图像划分为多个网格，并直接预测每个网格中的目标类别及边界框信息，从而实现端到端检测。其目标函数通常由定位误差、分类误差以及置信度误差组成。随着版本迭代（如 YOLOv3、YOLOv5、YOLOv8 等），模型在精度与速度之间取得了较好的平衡。

SSD 模型则通过在多尺度特征图上进行检测，提高了对不同尺寸目标的识别能力。相比 YOLO，SSD 在小目标检测方面表现更为稳定。

单阶段方法的优势在于检测速度快，适用于实时检测场景，例如自动驾驶与视频监控等。但其检测精度通常略低于两阶段方法。

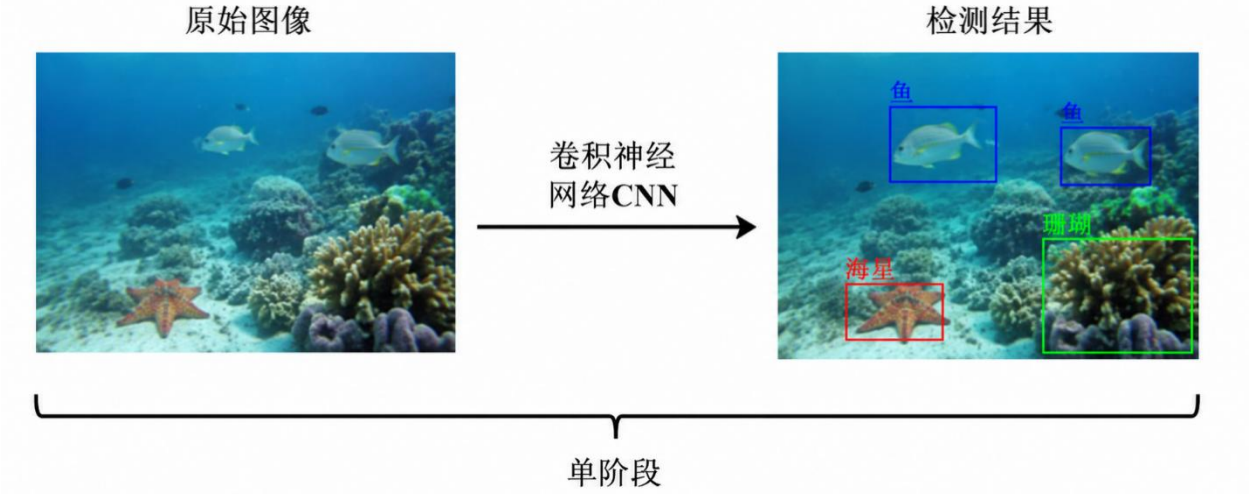


图 2.18 单阶段图像目标检测结构图

2.3.3 基于深度学习的目标检测关键技术

随着深度学习的发展，目标检测技术不断演进，形成了一系列关键技术。

（1）特征提取网络：目标检测模型通常依赖卷积神经网络作为特征提取 backbone，例如 VGG、ResNet 等结构，通过多层卷积提取图像的多尺度特征。

（2）多尺度特征融合：由于目标在图像中的尺度变化较大，现代检测算法通常采用特征金字塔结构（Feature Pyramid Network，FPN）进行多尺度特征融合，从而提升模型对不同尺寸目标的检测能力。

（3）锚框机制（Anchor）：Anchor 机制通过预设不同尺寸与长宽比的候选框，使模型能够更高效地预测目标位置。然而，该方法需要手动设计参数，灵活性较低。

（4）无锚框检测（Anchor-free）：近年来，Anchor-free 方法逐渐兴起，通过直接预测关键点或中心点位置，避免了复杂的锚框设计，提高了模型的泛化能力。

（5）损失函数设计：目标检测任务通常采用多任务损失函数，包括分类损失与回归损失。例如，回归损失可采用 L1 损失或 GIoU 损失，以提高边界框预测精度。

2.3.4 水下目标检测特点分析

与普通场景相比，水下环境具有光照衰减、颜色失真以及噪声干扰等特点，这些因素会对目标检测性能产生显著影响。因此，在水下目标检测任务中，需要结合图像增强与特征提取方法，提高模型对复杂环境的适应能力。

同时，由于水下目标往往尺度较小且边界模糊，传统检测模型容易出现漏检或误检问题。因此，结合超分辨率重建与深度特征建模方法，可以有效提升检测效果，这也是本文后续研究的重点方向。

2.4 本章小结

本章围绕水下图像处理与目标检测任务的相关理论基础展开论述。首先，对水下图像退化模型进行了分析，从光吸收与散射两个方面阐述了水下图像质量下降的主要原因，并通过成像模型对退化过程进行了数学描述。

随后，介绍了水下图像超分辨率重建的基本原理，重点分析了卷积神经网络在图像重建任务中的应用，并对模型结构、训练过程以及优化方法进行了详细说明。

在深度学习理论部分，系统阐述了卷积神经网络的基本结构与工作机制，同时对 Transformer 模型及其自注意力机制进行了分析，并进一步介绍了 Mamba 模型在长序列建模中的优势。

最后，对目标检测的基本原理及主流方法进行了总结，包括两阶段与单阶段检测算法的特点及其适用场景，并结合水下环境特点分析了目标检测面临的挑战。

本章内容为后续水下图像增强与目标检测算法的设计提供了重要的理论基础。

第三章 基于频率－空间耦合推理网络的水下图像超分辨率重建方法

3.1 引言

水下成像环境复杂，光线在传播过程中会同时受到吸收与散射两种效应的影响，且不同波长的光衰减程度差异显著，这一特性导致采集到的水下图像普遍呈现出色彩失衡、对比度偏低以及纹理退化等视觉缺陷。这些退化现象不仅影响人类的直观判读，也严重制约了水下目标检测、路径规划与结构检测等高级应用的执行效果。超分辨率重建（Super-Resolution，SR）技术通过从低分辨率输入中推断高分辨率输出，能够有效恢复图像中降质的结构与纹理成分，是当前提升水下视觉系统图像质量的重要技术手段。

得益于深度学习在图像恢复领域的广泛突破，基于卷积神经网络与 Transformer 架构的水下图像 SR 方法相继涌现[18]。这类方法通常通过多层次空间特征提取与级联模块重建高频纹理，在公开数据集上取得了较好的重建效果。然而，上述方法绝大多数仅在空间域内进行特征建模，对频域中蕴含的全局结构信息和周期性模式的利用仍十分有限[32]，在面对水下场景中复杂且多样的退化现象时难以稳定地捕获全局上下文线索与高频细节。

与此同时，现有方法在损失函数设计上多依赖像素级 L1 损失或通用感知损失[7]，这些损失函数对图像结构轮廓和精细纹理的约束能力不足。根据纹理－结构分解理论，图像可以被表示为结构层与纹理层的叠加，将两个成分解耦并分别施加监督，能够在重建过程中提供更具针对性的优化引导[29]。受此启发，本章引入纹理－结构联合损失，分别对高频纹理细节与低频结构边缘施加约束，以使网络在复杂水下退化条件下同样能够恢复出感知逼真且几何准确的重建结果。

针对现有方法的局限性，本章提出了一种新的频率－空间耦合推理网络（Frequency-Spatial Coupled Inference Network，FSCIN），通过融合频率与空间先验，实现水下图像超分辨率的增强重建。FSCIN 集成了空间频率感知模块（Spatial Frequency Awareness Module，SFAM），该模块通过快速傅里叶变换（Fast Fourier Transform，FFT）与基于 Swin Transformer 的空间编码，对频率域与空间域进行联合建模。SFAM 通过双分支处理对幅值与相位信息进行对齐，从而有效捕获和增强图像的高频分量及全局上下文信息。此外，为了保持感知保真度，本章还引入了纹理－结构联合约束损失，该损失将重建图像分解为纹理层与结构层，并对每一层施加针对性监督。该损失有效约束 FSCIN 在重建细粒度视觉细节的同时，保持结构边界的完整性。大量实验结果表明，FSCIN 在重建视觉效果良好且结构精确的水下图像方面表现出优越性能。

本章内容安排如下：4.2 节介绍相关基础技术；4.3 节详述改进网络的整体架构与各功能模块；4.4 节展示实验设置与结果分析；4.5 节分析超分辨率重建图像对目标检测性能的影响；4.6 节为本章小结。

3.2 相关技术

3.2.1 SwinTransformer 网络

标准 Transformer 模型在视觉任务应用中面临两个突出瓶颈：一是图像特征的尺度随任务动态变化，难以直接套用自然语言处理中固定 token 规模的处理范式；二是全局自注意力机制的计算复杂度与图像尺寸的平方成正比，在处理高分辨率图像时计算开销极为庞大。针对这两点局限，Liu 等人提出了 Swin Transformer，这是一种具有层次化结构的通用视觉骨干网络[30]，通过模仿 CNN 的多尺度特征提取方式，并将自注力计算限制在局部固定窗口内，将计算复杂度从二次降低至线性，同时兼顾对全局信息的感知。

如图 3.1 图 3.2 所示，Swin Transformer 由四个依次递进的处理阶段（Stage）组成。输入图像首先经 Patch Partition 操作划分为若干大小为 P×P（P=4）的二维图像块，形成序列后馈入后续阶段。从第二阶段起，通过 Patch Merging 模块对相邻块进行合并，在扩大通道维度的同时降低空间分辨率，逐步构建类似 CNN 的层次化特征表示。每个处理阶段由若干个连续的 Swin Transformer 模块构成，相邻两个模块分别采用 W-MSA（Window-based MSA）和 SW-MSA（Shift-Window-based MSA）交替处理。其中，W-MSA 通过限制注意力在局部窗口内计算来降低计算量，SW-MSA 则引入窗口移位机制，确保相邻窗口之间的信息得以有效传递，弥补了纯局部窗口注意力在跨窗口上下文交互方面的不足。

设输入特征图尺寸为$H \times W$，窗口大小为$M \times M$，W-MSA 的计算复杂度可近似表示为$O(HW \cdot M^2)$，远低于全局注意力$O((HW)^2)$，为将 Transformer 结构实际部署于超分辨率等高分辨率视觉任务奠定了效率基础。

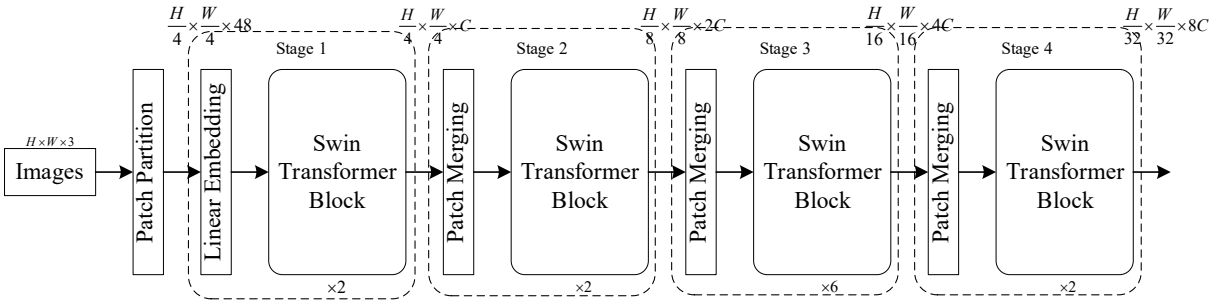


图 3.1 Swin Transformer 结构示意图

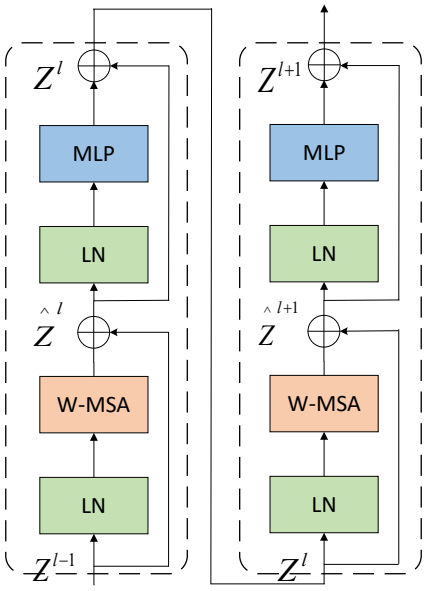


图 3.2 Swin Transformer 示意图

3.2.2 傅里叶变换

傅里叶变换是信号与图像处理领域的基础性数学工具，其核心作用是将信号从空间域转换至频率域，以频谱的形式揭示信号的全局周期性结构。对于二维图像而言，离散傅里叶变换（DiscreteFourierTransform，DFT）的定义为：

$$F(u,v) = x = \sum_{x=0}^{H-1} \sum_{y=0}^{W-1} f(x,y) \cdot e^{-j2\pi\left(\frac{ux}{H}+\frac{vy}{W}\right)} \tag{3.1}$$

其中，$f(x,y)$为空间域图像，$F(u,v)$为对应的频域表示，(u,v)为频域坐标，H、W分别为图像的高度与宽度。频域表示$F(u,v)$为复数形式，可进一步分解为幅度谱$|F(u,v)|$和相位谱$\angle F(u,v)$：幅度谱反映各频率分量的能量分布，与图像中目标的整体亮度及纹理能量密切相关；相位谱则编码了各频率分量的空间位置信息，对图像结构的几何形态具有关键作用。

在超分辨率任务中，高频分量对应图像的边缘、纹理等精细结构，是重建质量的核心决定因素；低频分量则对应图像的轮廓与整体亮度，如图 3.3 所示。在工程实践中，通常采用快速傅里叶变换（Fast Fourier Transform，FFT）以$O(NlogN)$的时间复杂度代替直接计算 DFT 的$O(N^2)$，显著提升了频域变换在深度网络中的实用效率。频域特征完成建模后，通过逆快速傅里叶变换（Inverse FFT，IFFT）可将处理后的频谱还原回空间域，保证特征的空间一致性。这一“空间域→频域→空间域”的往返变换机制是本章 SFAM 模块设计的核心理论基础。

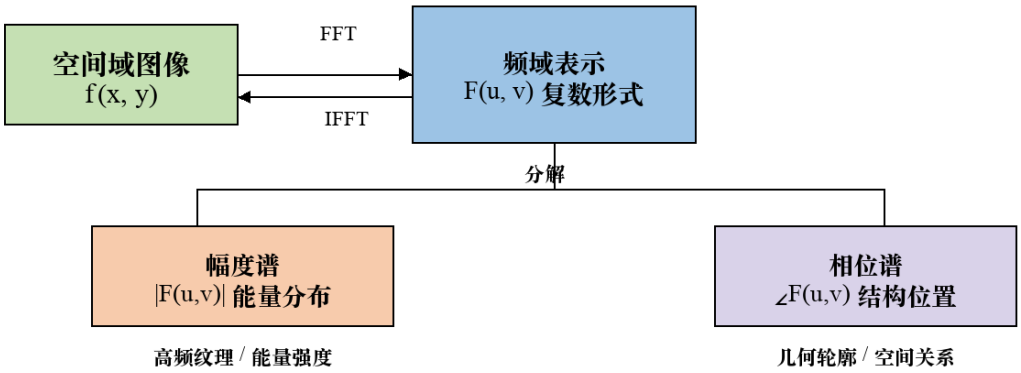


图 3.3 傅里叶变换示意图（幅度谱与相位谱分解）

3.3 频率－空间耦合推理网络的水下图像超分辨率重建模型

3.3.1 网络结构设计

FSCIN 的整体处理流程如图 3.4 所示，网络依次经过三个功能阶段完成从低分辨率输入到高分辨率输出的转换。设输入低分辨率水下图像为X，对应的输出高分辨率重建图像为Y，r为上采样倍率。

阶段一：浅层特征提取阶段。对输入低分辨率图像$X \in R^{H\times W\times 3}$应用一个 3×3 卷积层，提取初始的低级特征表示：

$$F^0 = Conv_{3\times 3}(X) \tag{3.2}$$

其中，$Conv_{3\times 3}(\cdot)$表示标准 3×3 卷积操作，输出特征通道数设定为$C = 50$，H、W分别对应输入图像的高度与宽度。该阶段生成的浅层特征$F^0 \in R^{H\times W\times C}$将作为后续深度模块的初始输入，为网络提供丰富的低级纹理信息。

阶段二：频－空协同特征增强阶段。连续堆叠T个 *SFAM* 模块，对特征图进行迭代式的频域与空域联合建模。第t个 *SFAM* 的处理可表示为：

$$F_{SFAM}^t = H_{SFAM}^t(F_{SFAM}^{t-1}) = H_{SFAM}^t\left(H_{SFAM}^{t-1}(F^0)\right) \tag{3.3}$$

每个 *SFAM* 模块通过结合快速傅里叶变换（FFT）与基于 Swin Transformer 的双分支注意力机制，获取幅值－相位频率信息与空间依赖关系，实现频率感知特征的逐步增强。该阶段旨在充分利用图像的全局上下文信息与高频细节线索，使特征表达在空间和频率域上均得到强化。*SFAM* 的详细结构将在 3.3.2 节中介绍。

阶段三：高分辨率图像重建阶段。对经过阶段二增强的深层特征F_{SFAM}^T执行上采样操作以逐步恢复空间分辨率，最终重建出高分辨率图像Y：

$$S = H_{HU}(F_{SFAM}^{T}) + H_{LU}(X) \tag{3.4}$$

其中，$H_{HU}(\cdot)$和$H_{LU}(\cdot)$分别表示对更深层次特征F_{SFAM}^{T}和初始输入 LR 图像 X 进行上采样操作。具体地说，它们均包含一个卷积层（3×3 卷积用于$H_{HU}(\cdot)$和 5×5 卷积用于$H_{LU}(\cdot)$）和一个亚像素卷积层。

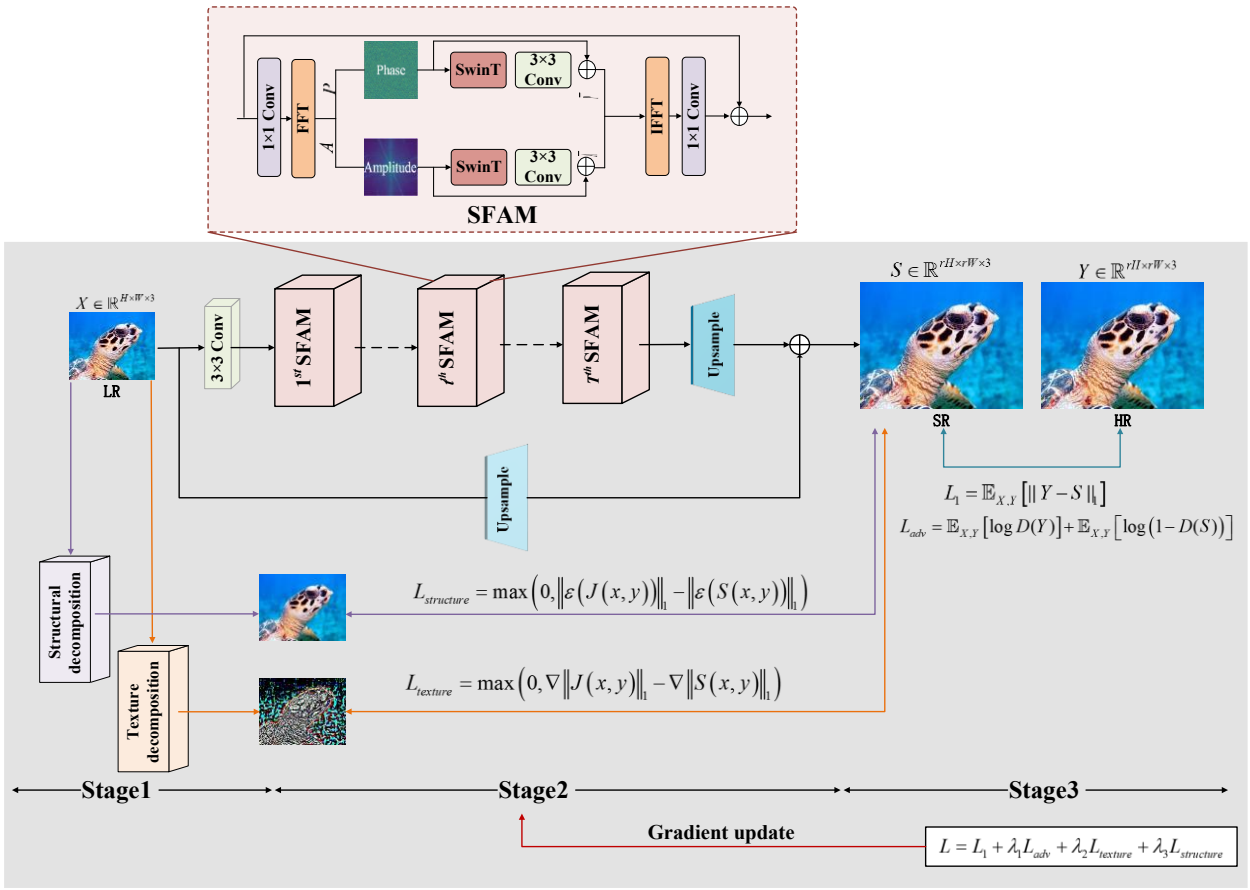


图 3.4 FSCIN 整体网络结构示意图

3.3.2 频率感知模块（SFAM）

为有效建模水下图像中的空间依赖关系与全局频率信息，本文设计空间频率感知模块（Spatial Frequency Awareness Module，SFAM）作为 FSCIN 的核心组成部分。SFAM 模块旨在联合处理频率域中的幅度分量和相位分量，在重建过程中增强结构保真度与细粒度纹理表达。

给定第 t 个 *SFAM* 的输入特征图，首先采用快速傅里叶变换（Fast Fourier Transform，FFT）将其转换到频率域。具体而言，输入特征先通过初步卷积操作完成特征归一化，再获得对应的频域表示，并进一步分解为幅度分量$\mathcal{A}$和相位分量$\mathcal{P}$：

$$\mathcal{A} = \left|FFT\left(Conv(F_{t-1})\right)\right|, \mathcal{P} = \angle FFT\left(Conv(F_{t-1})\right) \tag{3.5}$$

在每个分支中，本文采用一个 Swin Transformer（SwinT）块后接 3×3 卷积层。SwinT 负责建模长距离依赖关系和窗口内的自适应空频注意力，卷积层则用于增强局部特征细化能力。

双分支结构有助于同时建模高层频率信息和局部空间线索，其计算过程表示为：

$$\mathcal{A}' = Conv\big(SwinT(\mathcal{A})\big), \mathcal{P}' = Conv\big(SwinT(\mathcal{P})\big) \tag{3.6}$$

处理完成后，幅度分支和相位分支的输出通过逐元素加法进行融合，随后采用逆快速傅里叶变换（Inverse Fast Fourier Transform，IFFT）将增强后的频域特征转换回空间域。最终得到的特征图同时包含频率感知增强信息与空间一致性，并传递至下一阶段：

$$F_t = F_{t-1} + IFFT(\mathcal{A}' + \mathcal{P}') \tag{3.7}$$

3.3.3 纹理—结构联合损失

为监督网络恢复感知真实且结构一致的水下图像，本文设计多模态联合损失函数，从像素级保真、对抗真实感和频率感知的感知一致性三个方面共同约束模型学习过程。总体损失函数表示为：

$$\mathcal{L} = \mathcal{L}_1 + \lambda_1 \mathcal{L}_{adv} + \lambda_2 \mathcal{L}_{texture} + \lambda_3 \mathcal{L}_{structure} \tag{3.8}$$

其中，$\mathcal{L}_1$为像素级重建损失，$\mathcal{L}_{adv}$为对抗损失，$\mathcal{L}_{texture}$用于约束局部纹理一致性，$\mathcal{L}_{structure}$用于保障结构边缘对齐，λ_1、λ_2、λ_3为平衡权重，分别设置为 0.2、0.4 和 0.4。

（1）像素级重建损失

本文采用$\mathcal{L}_1$损失度量重建图像Y与真实高分辨率图像S之间的绝对差异：

$$\mathcal{L}_1 = \|Y - \mathrm{S}\|_1 \tag{3.9}$$

该项用于保持全局颜色和强度一致性。

（2）对抗损失

为增强感知真实感，本文采用带判别器D的标准 GAN 损失：

$$\mathcal{L}_{adv} = -\mathbb{E}[log\mathrm{D}(Y)] \tag{3.10}$$

该损失让生成图像符合自然水下图像的分布。

（3）纹理一致性损失

遵循频率感知原则，本文在空间域计算梯度以量化纹理相似性：

$$\mathcal{L}_{texture} = \|\nabla Y - \nabla \mathrm{S}\|_1 \tag{3.11}$$

其中，∇表示空间梯度算子，S表示保边的真实高分辨率引导图像。

（4）结构对齐损失

为保持几何边缘和结构轮廓，本文定义结构对齐损失如下：

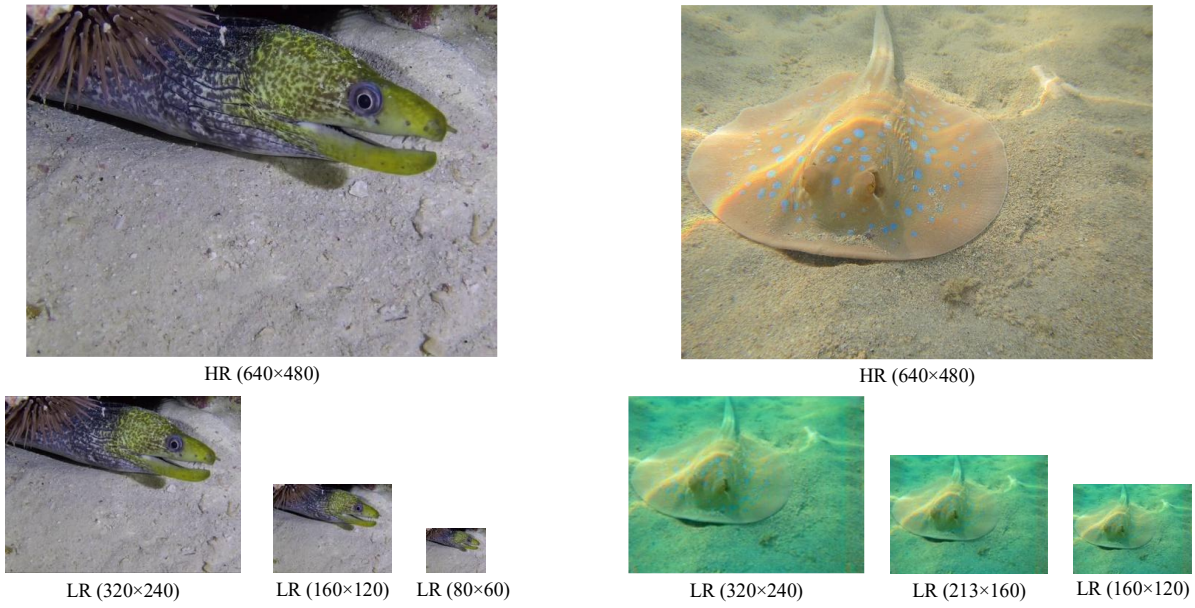
$$\mathcal{L}_{structure} = \|\Phi(Y) - \Phi(S)\|_1 \tag{3.12}$$

其中，$\Phi(\cdot)$表示结构提取器。该项用于确保重建图像能够保持与参考图像对齐的高频边界。

3.4 实验结果与分析

3.4.1 实验数据与实验环境

本章选取两个公开的水下图像超分辨率基准数据集 USR-248[15]和 UFO-120[16]对 FSCIN 进行训练与评估，如图 3.5 所示。两个数据集均提供成对的低分辨率图像与高分辨率参考图像，能够用于学习从退化水下图像到清晰高分辨率图像之间的映射关系。



(a) USR-248 支持×2、×4 和×8 倍训练　　(b) UFO-120 支持×2、×3 和×4 倍训练

图 3.5　USR-248 和 UFO-120 数据集的具体实例

USR-248 数据集面向水下单图像超分辨率任务构建，包含 640×480 像素的高分辨率图像及其对应的 320×240、160×120 和 80×60 三种低分辨率版本，分别对应×2、×4 和×8 三种放大倍率。该数据集包含 1050 对训练样本，并提供 248 张测试图像用于性能评估。图像来源涵盖海洋勘探、实地采集以及公开网络资源，低分辨率图像通过模拟退化方式生成，能够较好地反映不同分辨率条件下的水下细节损失问题。

UFO-120 数据集专门面向水下图像增强与超分辨率重建任务构建，图像采集自多个海洋探索场景，覆盖不同水体环境与视觉退化类型。该数据集包含 1500 组训练样本和 120 组测试样本，对应×2、×3 和×4 三种上采样倍率。其低分辨率图像通过风格迁移扰动、高斯模糊和双三次下采样等方式生成，能够模拟水下光线衰减、散射、成像设备限制等因素造成的复合退化。

训练过程中，采用 Adam 优化器对多模态联合损失函数进行最小化，超参数设置为 $\beta1$=0.9、$\beta2$=0.999、ϵ=10-8，初始学习率设置为 0.001，并在训练过程中按固定间隔衰减。每个 mini-batch 包含 16 张空间尺寸为 50×50 像素的低分辨率图像块，模型基于 PyTorch 框架实现，训练平台为 NVIDIA RTX 3090 GPU。

3.4.2 评价指标

本章综合采用峰值信噪比（Peak Signal-to-Noise Ratio，PSNR）、结构相似性指数（Structural Similarity Index Measure，SSIM）和水下图像质量评估指标（Underwater Image Quality Measure，UIQM）三种互补指标对超分辨率重建结果进行定量评价。PSNR 侧重像素级误差，SSIM 侧重结构一致性，UIQM 则从水下成像特点出发评价色彩、清晰度和对比度，三者结合能够更全面地反映重建图像的客观质量与水下视觉感知效果。

峰值信噪比（PSNR）基于均方误差（Mean Squared Error，MSE）衡量重建图像与真实高分辨率图像之间的像素级差异，是超分辨率任务中最常用的客观评价指标之一。其计算公式为：

$$PSNR = 10 \cdot log_{10}\left(\frac{L^2}{MSE}\right), MSE = \frac{1}{HW}\|Y - S\|_2^2 \tag{3.13}$$

其中，L 表示图像像素最大取值，通常 8 位图像中取 255；H 和 W 分别表示图像高度与宽度，Y 为模型输出的重建图像，S 为真实高分辨率图像。*PSNR* 值以 dB 为单位，数值越高说明重建图像与参考图像之间的像素误差越小，客观失真程度越低[65]。需要指出的是，*PSNR* 对整体像素偏差较为敏感，但不能完全反映纹理自然度和结构感知质量，因此需要结合其他指标共同分析。

结构相似性指数（SSIM）从亮度、对比度和结构三个维度衡量两幅图像的相似程度，相较于单纯的像素误差指标，*SSIM* 更接近人眼对图像结构变化的感知方式。其计算公式为：

$$SSIM(Y,S) = \frac{(2\mu_Y\mu_S + c_1)(2\sigma_Y^S + c_2)}{(\mu_Y^2 + \mu_S^2 + c_1)(\sigma_Y^2 + \sigma_S^2 + c_2)} \tag{3.14}$$

其中，μ_Y和μ_S分别表示重建图像与参考图像的均值，σ_Y^2和σ_S^2表示二者方差，σ_Y^S表示协方差，c_1和c_2为避免分母为零而引入的稳定常数。*SSIM* 取值通常位于 0 到 1 之间，越接近 1 表示两幅图像在亮度、对比度和结构层面越相似[66]。在水下图像超分辨率任务中，*SSIM* 能够较好反映边缘轮廓和结构纹理是否被稳定恢复。

水下图像质量评估指标（UIQM）是面向水下场景设计的无参考图像质量评价方法，不依赖真实高分辨率图像，而是从水下视觉感知特点出发综合评价图像质量。*UIQM* 由色彩测量（UICM）、清晰度测量（UISM）和对比度测量（UIConM）三个子指标线性加权得到：

$$UIQM = c_1 \cdot UICM + c_2 \cdot UISM + c_3 \cdot UIConM \quad (3.15)$$

其中，*UICM* 用于衡量图像颜色平衡与色彩还原情况，*UISM* 用于评价边缘和纹理清晰程度，*UIConM* 用于反映局部对比度表现，c_1、c_2和c_3为经验权重系数。*UIQM* 数值越高，说明水下图像在色彩自然度、纹理清晰度和对比度方面的综合表现越优[67]。由于水下图像常伴随偏色、低对比度和纹理衰减，*UIQM* 能够为 *PSNR* 和 *SSIM* 之外的水下视觉质量分析提供重要补充。

3.4.3 实验设计与实现

为全面评估 FSCIN 的重建性能，本章从当前图像超分辨率领域选取了一批代表性方法作为对比基准，涵盖以下几类：传统 CNN 方法（SRCNN、VDSR）；基于 GAN 的方法（SRGAN[7]、SRDRM、SRDRM-GAN）；专为水下场景设计的方法（PAL、AMPCNet[17]、DeepWaveNet[19]、RDLN）。所有对比实验均在统一的数据集划分、相同的评价指标下进行，以保证比较结果的公平性。

本章结合定量分析与定性分析两种评估方式：定量分析基于 PSNR、SSIM 和 UIQM 三项指标进行数值比较；定性分析通过可视化结果直观展示各模型在边缘清晰度、纹理保真度和色彩自然度方面的表现差异。

3.4.4 定量分析

（1）USR-248 数据集上的定量分析

表 3.1 至表 3.3 分别列出了×2、×4 和×8 倍率下各方法的定量评估结果，粗体表示各列最优值，FLOPs 以 640×480 的高分辨率图像为基准进行测量。从表 3.1 至表 3.3 可以看出，FSCIN 在全部三个放大倍率上均取得了领先的综合性能。在×2 倍率下，FSCIN 获得了最高的 PSNR（30.04dB）和 SSIM（0.83），与参数量最大的对比方法 SRDRM-GAN（289.38GFLOPs，11.31M 参数）相比，FSCIN 仅需 30.70GFLOPs 和 0.55M 参数即可实现更优的重建效果。在×4 倍率下，FSCIN 同样保持最佳 PSNR（26.22dB），同时具备较低的计算成本。在×8 大倍率场景中，FSCIN 以仅 2.45GFLOPs（所有方法中最低）取得最高 PSNR（24.03dB），在重建性能与推理效率之间展现出突出的平衡性，验证了频率－空间耦合设计在大倍率重建中的鲁棒性与高效性。

（2）UFO-120 数据集上的定量分析

表 4.4 给出了×2、×3 和×4 三种倍率下的综合评估结果。在 UFO-120 数据集上，FSCIN 在×2 倍率下取得最高 PSNR（25.98dB）和最高 UIQM（2.99，与 DeepWaveNet 并列）；在×3 和×4 倍率下，FSCIN 均保持最优 PSNR（分别为 26.07dB 和 25.23dB），展现出良好的

跨倍率泛化能力。尽管 Deep WaveNet 在 SSIM 和部分 UIQM 指标上表现突出，但 FSCIN 在 PSNR 指标上具有一致且明显的优势，在综合衡量重建保真度与感知质量方面表现更为均衡。

表 3.1不同方法在 USR-248 数据集进行×2 比较

方法	FLOPs(G)	Params(M)	PSNR(dB)	SSIM	UIQM
SRCNN	21.3	0.06	26.81	0.76	2.74
VDSR	205.28	0.67	28.98	0.79	2.57
SRGAN	377.76	5.95	28.05	0.78	2.74
SRDRM	203.91	0.83	28.36	0.80	**2.78**
SRDRM-GAN	289.38	11.31	28.55	0.81	2.77
PAL	203.82	0.83	28.41	0.80	—
AMPCNet	—	1.15	29.54	0.80	2.77
DeepWaveNet	21.47	0.28	29.09	0.80	2.73
RDLN	74.86	0.84	29.96	**0.83**	2.68
FSCIN（本文）	30.70	0.55	**30.04**	**0.83**	2.72

表 3.2不同方法在 USR-248 数据集进行×4 比较

方法	FLOPs(G)	Params(M)	PSNR(dB)	SSIM	UIQM
SRCNN	21.3	0.06	23.38	0.67	2.38
VDSR	205.28	0.67	25.70	0.68	2.44
SRGAN	529.86	5.95	24.76	**0.69**	2.42
SRDRM	291.73	1.90	24.64	0.68	2.46
SRDRM-GAN	377.2	12.38	24.62	**0.69**	2.48
PAL	303.42	1.92	24.89	**0.69**	—
AMPCNet	—	1.17	25.90	0.66	**2.58**
DeepWaveNet	5.59	0.29	25.20	0.68	2.54
RDLN	29.56	0.84	26.16	0.66	2.38
FSCIN（本文）	9.58	0.56	**26.22**	0.68	2.47

表 3.3不同方法在 USR-248 数据集进行×8 比较

方法	FLOPs(G)	Params(M)	PSNR(dB)	SSIM	UIQM
SRCNN	21.3	0.06	19.97	0.57	2.01
VDSR	205.28	0.67	23.58	**0.63**	2.17
SRGAN	567.88	5.95	20.14	0.60	2.10
SRDRM	313.68	2.97	21.20	0.60	2.18
SRDRM-GAN	3915	13.45	20.25	0.61	2.17
PAL	325.51	2.99	22.51	**0.63**	—
AMPCNet	—	1.25	23.83	0.62	**2.25**
DeepWaveNet	1.62	0.34	23.25	0.62	2.21
RDLN	18.23	0.84	23.91	0.54	2.18
FSCIN（本文）	**2.45**	0.64	**24.03**	0.54	2.18

表 3.4基于 UFO-120 数据集的水下图像超分辨率定量评估（×2/×3/×4）

方法	PSNR(dB)			SSIM			UIQM		
	×2	×3	×4	×2	×3	×4	×2	×3	×4
SRCNN	24.75	22.22	19.05	0.72	0.65	0.56	2.39	2.24	2.02
SRGAN	**26.11**	23.87	21.08	0.75	0.70	0.58	2.44	2.39	2.56
SRDRM	24.62	—	23.15	0.72	—	0.67	2.59	—	2.57
SRDRM-GAN	24.61	—	23.26	0.72	—	0.67	2.59	—	2.55
DeepWaveNet	25.71	25.23	25.08	0.77	**0.76**	**0.74**	**2.99**	**2.96**	**2.97**
AMPCNet	25.24	25.73	24.70	0.71	0.70	0.70	2.93	2.85	2.88
URSCT	25.96	—	23.59	**0.80**	—	0.66	—	—	—
FSCIN（本文）	25.98	**26.07**	**25.23**	0.78	0.75	0.70	**2.99**	**2.96**	2.90

3.4.5 定性分析

图 3.6 展示了 FSCIN 与各对比方法在 USR-248 数据集上的可视化重建结果（×2/×4/×8）。从图中可以看出，随着放大倍率增大，其他方法普遍出现过度平滑、伪影或失真等问题，尤其在×8 大倍率下表现明显；而 FSCIN 在各倍率下均能恢复出更锐利的边缘轮廓、更清晰的纹理层次和更自然的色彩分布，整体视觉质量优于所有对比方法。这一结果有力印证了频率－空间耦合设计在恢复水下图像精细细节与结构完整性方面的有效性。

图 3.7 展示了在 UFO-120 数据集上（×2/×3/×4）的视觉对比结果。在处理鱼鳞、珊瑚支脉等典型水下细粒度结构时，FSCIN 成功恢复了丰富的边缘图案与自然色调，而其他方法则不同程度地出现了颜色偏移、纹理模糊或细节丢失等问题。上述定性比较进一步验证了本章所提频率－空域耦合设计和纹理－结构引导优化策略的实际有效性。

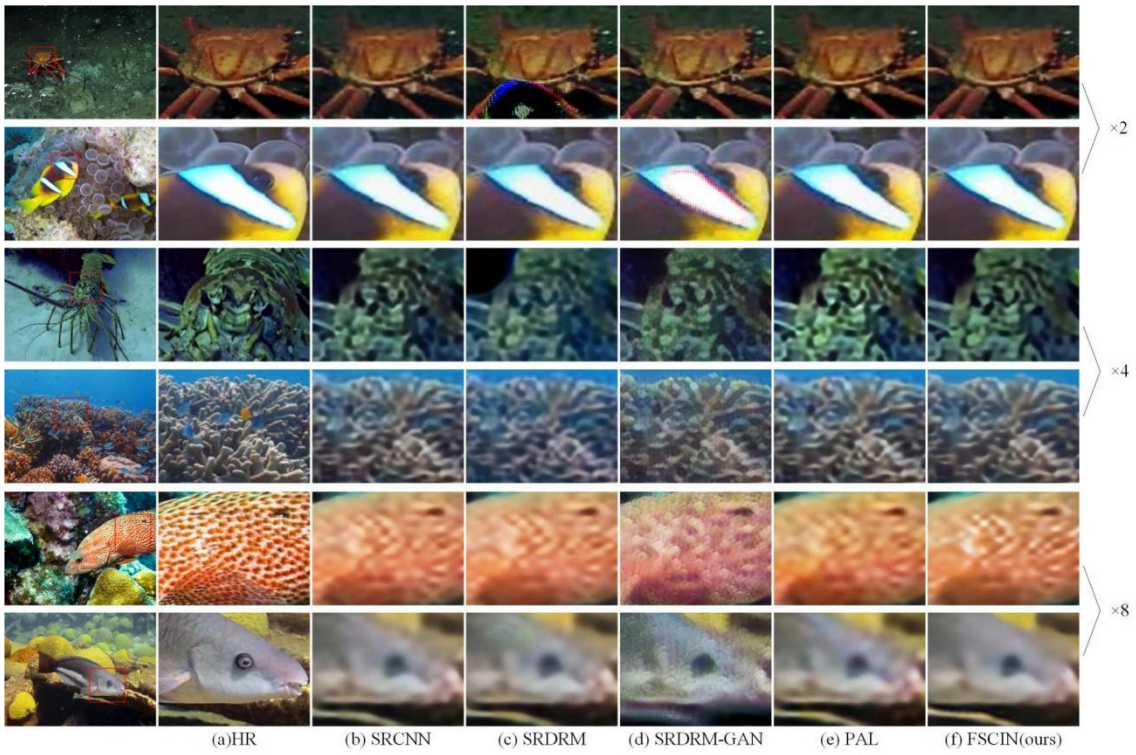


图 3.6 基于 USR-248 数据集的视觉比较（×2/×4/×8）

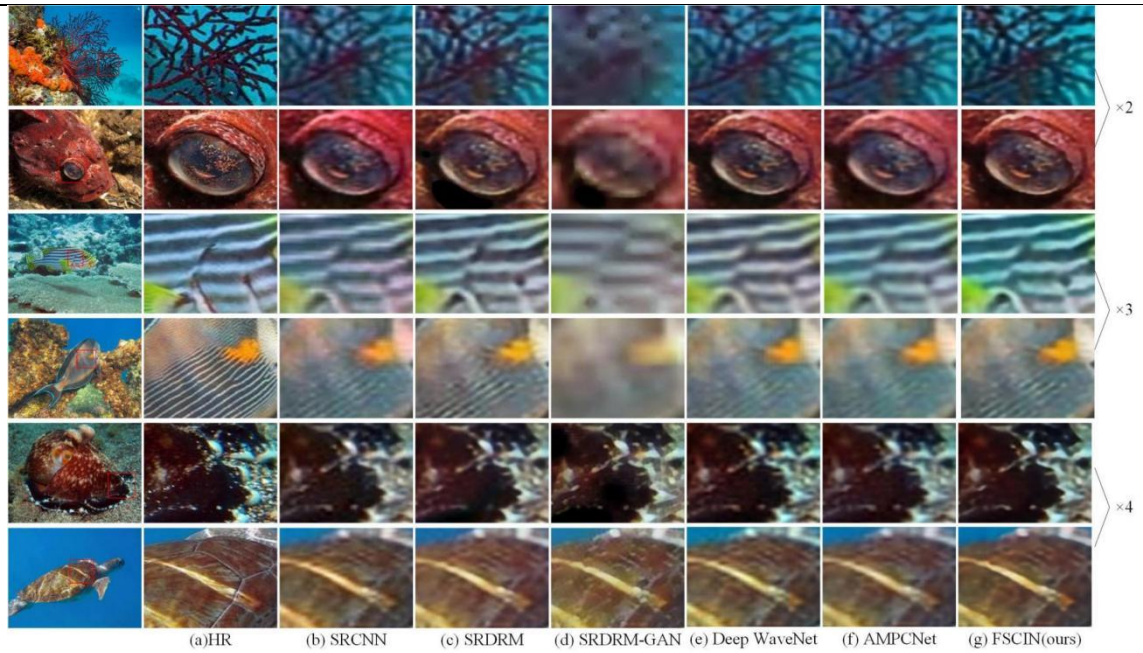


图 3.7 基于 UFO-120 数据集的视觉比较（×2/×3/×4）

3.4.6 消融实验

（1）SFAM 模块有效性验证。为单独考察 SFAM 的贡献，我们将 SFAM 替换为标准频率块（Frequency Residual Block，FRB）得到对照变体 FSCIN-FRB，在 USR-248 数据集×2 倍率下进行对比，结果如表 3.5 所示。

表 3.5SFAM 模块有效性消融实验（USR-248，×2）

模型	FLOPs	Params	PSNR(dB)	SSIM	UIQM
FSCIN-FRB	13.04G	0.29M	28.77	0.73	2.64
FSCIN（本文）	30.70G	0.55M	**29.81**	**0.80**	**2.70**

由表 3.5 可见，FSCIN 相比 FSCIN-FRB 在 PSNR 上提升了 1.04dB，SSIM 提高了 0.07，UIQM 改善了 0.06，全面验证了 SFAM 对图像保真度、结构质量和感知效果的显著增益。尽管 FSCIN 的 FLOPs（30.70G）高于 FSCIN-FRB（13.04G），但性能的大幅提升充分说明了这一额外计算代价的合理性，同时也印证了频率－空间耦合设计方案相较于独立频率块处理的明显优越性。

（2）多模态损失函数有效性验证。在 UFO-120 数据集×2 倍率下，逐项消融损失函数各组成项，结果如表 3.6 所示。实验从单一 L1 损失（Type1）基线出发，单独测试对抗损失（Type2）、纹理损失（Type3）和结构损失（Type4）各自的效果。可以看出，各单项损失在 PSNR 或 SSIM 上均能带来一定程度的改善；当四项损失全部联合使用时（Type5），模型取得最佳表现，PSNR 达到 25.75dB，SSIM 为 0.76，明显优于任何单项损失配置。上

述结果验证了纹理一致性约束与结构对齐约束在图像质量不同维度上的互补增益效应，二者的联合监督是 FSCIN 实现高质量重建的重要保障。

表 3.6多模态损失函数消融实验（UFO-120，×2）

配置	$\mathcal{L}_1$	$\mathcal{L}_{\text{adv}}$	$\mathcal{L}_{\text{texture}}$	$\mathcal{L}_{\text{structure}}$	PSNR(dB)	SSIM
Type1	✓				25.62	0.73
Type2		✓			25.58	0.71
Type3			✓		25.61	0.72
Type4				✓	25.63	0.73
Type5（完整）	✓	✓	✓	✓	**25.75**	**0.76**

3.5 本章小结

本章针对水下图像超分辨率重建任务，提出了频率－空间耦合推理网络（FSCIN），以解决频域信息利用不足与损失函数约束能力有限的问题。网络构建了三阶段处理框架，包括低级特征提取、频－空协同特征增强以及高分辨率图像重建，各阶段功能明确且耦合合理，为后续模块的灵活替换与扩展提供了良好基础。核心的空域－频域感知模块（SFAM）通过快速傅里叶变换（FFT）将特征映射至频率域，并利用双分支 Swin Transformer 注意力结构对幅度谱与相位谱分别建模，再通过逆傅里叶变换（IFFT）还原至空间域，实现频域全局感知与空域局部建模的深度融合。针对纹理层与结构层分别施加监督的联合损失函数，通过梯度域纹理约束与结构提取器约束的协同作用，有效提升了高频细节与几何边缘的重建精度。实验结果表明，FSCIN 在 USR-248 与 UFO-120 两个公开基准数据集上，在多种放大倍率下均取得最优或极具竞争力的定量指标，同时在视觉质量上展现出更清晰的纹理复原能力与更高的结构保真度，为后续水下目标检测任务提供了高质量的图像预处理基础。（本章内容已发表于 The 5th International Conference on Applied Mathematics, Modeling and Computer Simulation。）

第四章 基于改进 YOLOv8 的水下图像目标检测方法

4.1 引言

水下目标检测是水下视觉感知系统的核心任务之一，在海洋生物监测、水下机器人自主导航以及海洋资源勘探等领域具有重要应用价值。然而，水下成像环境复杂，光线在水中传播时受散射、吸收和折射等多种因素的共同影响，导致水下图像普遍存在低对比度、色彩偏移和边缘模糊等退化现象，这些视觉缺陷严重制约了目标检测算法对有效特征的提取能力。

从本文“增强－检测”整体框架来看，第三章所提出的 FSCIN 超分辨率重建网络已针对上述退化问题进行了系统性的图像质量提升：通过频域－空域协同建模将原始低质量水下图像重建为具有更清晰纹理、更准确色彩和更完整边缘信息的高质量图像，并在 USR-248 数据集×2 倍率下取得 30.04dB 的最优 PSNR、在×8 倍率下以仅 2.45GFLOPs 取得 24.03dB 的重建精度，验证了前端增强模块的有效性与高效性。本章的工作以第三章输出的清晰化图像为直接输入，在更高质量的图像基础上构建精确的水下目标检测模型，实现“原始图像→超分辨率清晰化→清晰图像→目标检测→检测结果”完整处理链路的第二阶段。通过这种串联设计，目标检测模型能够在细节更丰富、对比度更高的图像上提取更为有效的目标特征，从而显著提升对水下微小目标的检测召回率与定位精度。

目前以 YOLOv8 为代表的单阶段检测方法在直接应用于水下场景时仍面临以下主要局限[39][43]：其一，YOLOv8 以卷积神经网络为核心进行特征提取，受限于局部感受野，难以建模图像中的长程依赖关系，对全局上下文信息的捕获能力有所欠缺；其二，原始 C2f 模块对小目标的细粒度特征表达能力不足，在水下低可见度条件下的微小目标（如海胆、扇贝等）检测精度有限；其三，尽管 PAN-FPN 类结构能够增强多尺度信息融合[38]，但在复杂水下场景中，不同尺度目标的外观差异、遮挡和背景干扰仍会削弱模型的自适应融合能力，导致不同尺度目标的检测需求难以同时兼顾。

针对上述问题，本章提出一种改进的 YOLOv8 水下图像目标检测模型，设计了细粒度特征提取模块（Fine-Grained Feature Extraction Module，FFEM）以替换原始 YOLOv8 中的 C2f 模块。该模块由三个功能子模块协同构成：通道－空间自适应增强模块（Channel-Spatial Adaptive Enhancement Module，CAEM）通过卷积与通道－空间注意力机制精准聚焦目标边缘与纹理细节；基于 Mamba 的全局感知模块（Visual SSM，VSSM）利用视觉状态空间模型建模长程依赖，捕获全局上下文信息；多尺度交叉注意力融合模块（Multi-Scale Cross-Attention Fusion Module，MCFM）通过动态加权机制将两路特征进行自适应融合，输出判

别性强的细粒度特征表示。在 URPC2021 水下目标检测数据集上的实验表明，改进模型相较原始 YOLOv8 在 mAP50 上提升 1.8 个百分点（0.855→0.873），在小目标 APs 上提升 1.1 个百分点（0.166→0.177），验证了本章方法在“增强－检测”串联框架第二阶段中的有效性。

本章内容安排如下：4.2 节介绍相关基础技术；4.3 节详述改进网络的整体架构与各功能模块；4.4 节展示实验设置与结果分析；4.5 节分析超分辨率重建图像对目标检测性能的影响；4.6 节为本章小结。

4.2 相关技术

4.2.1 YOLOv8 目标检测网络

YOLO（You Only Look Once）系列算法是当前单阶段目标检测领域的代表性方法，通过将检测任务建模为直接回归问题，在单次前向推理中同时预测目标类别与边界框坐标，在检测速度与精度之间取得了良好的平衡。YOLOv8 是该系列的较新版本，在网络结构和训练策略方面进行了多项系统性改进。

在骨干网络方面，YOLOv8 采用新设计的 C2f 模块替换了前代的 C3 模块。C2f 模块通过将输入特征图拆分为两路分支——一路直接传递，另一路经多个 Bottleneck 块进行深度特征提取——最后将所有中间输出进行拼接融合，在保持计算效率的同时提升了梯度流通性。在特征融合方面，YOLOv8 继承了 PAN-FPN 结构，通过自顶向下的语义路径与自底向上的细节路径实现多尺度特征的双向融合，增强了对不同尺度目标的检测能力。在检测头方面，YOLOv8 采用解耦头（Decoupled Head）设计，将分类分支与回归分支分离处理，降低了两种任务之间的相互干扰，提升了检测精度。

尽管 YOLOv8 在通用目标检测任务中表现出色，但其骨干网络以局部卷积操作为主，缺乏对全局依赖关系的显式建模能力；C2f 模块在处理水下小目标时，细粒度特征表达能力有限。因此，有必要针对水下场景的图像特性对 YOLOv8 进行针对性改进，以提升其在复杂水下环境中的检测鲁棒性。

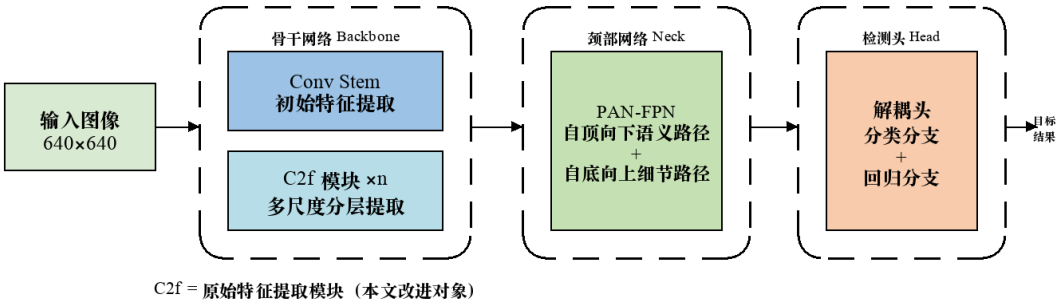


图 4.1 YOLOv8 网络结构示意图

4.2.2 注意力机制

注意力机制（Attention Mechanism）的核心思想来源于人类视觉系统对感兴趣区域的选择性聚焦特性，在深度学习中被建模为对特征图各位置或各通道施加动态权重的过程，以引导网络将更多计算资源分配到信息量更丰富的区域。

注意力机制在体系结构上有所不同，但是它们核心过程是一致的，即都需要通过三个步骤：压缩、激发和校准。我们给定一个输入特征 $X \in \mathbb{R}^{H \times W \times C}$，其中 H、W 和 C 分别表示长度、宽度和通道数。首先，压缩过程是按照通道区域或空间区域从 X 中提取一个或多个统计量 S 的过程。通道注意力机制通常采用池化操作生成一个统计量，而空间注意力机制通常采用 1×1 卷积操作生成多个统计量。这里以通道注意力机制为例，其公式表达如下：

$$S = pool(X) \tag{4.1}$$

其中，$pool(\cdot)$表示池化操作。

然后，激发过程主要从提取的统计量S中获取通道区域或空间区域之间的相互依赖关系，并产生不同维度张量的注意力映射M，大小为$1 \times 1 \times C(CA)$或$H \times W \times 1(SA)$。这个过程可以使用多个全连接层或多个卷积层实现，其公式表达如下：

$$M = fc_2\big(fc_1(S)\big) \tag{4.2}$$

其中，$fc(\cdot)$代表全连接层。

最后，为了重新校准输入的特征，需要将生成的注意力映射M通过 Sigmoid 激活函数归一化到 0 至 1，再以通道级别或空间级别的方式对M和X执行乘法，以此实现对输入特征的重新校准，其过程表示如下：

$$\hat{X} = \sigma(M) \otimes X \tag{4.3}$$

其中，σ表示 Sigmoid 激活函数。符号$\otimes$表示像素级乘法操作。$\hat{X}$为校准后的特征。

4.3 改进的 YOLOv8 水下图像目标检测模型

4.3.1 网络结构设计

本章在 YOLOv8 原始架构的基础上进行针对性改进，用所设计的细粒度特征提取模块（Fine-Grained Feature Extraction Module，FFEM）取代骨干网络及颈部网络中的 C2f 模块，其余部分结构保持不变，如图 4.2 所示。

FFEM 由三个功能子模块构成，整体处理流程如图 4.3 所示。对于输入特征图 *X*，模块分两个并行分支分别处理：*CAEM* 提取目标的边缘与细节特征；*VSSM* 捕获全局上下文与长程依赖信息。两路分支的输出通过逐元素加法进行初步融合，得到中间特征 *X′*，再经 *MCFM* 进行动态加权融合，最终输出细粒度特征 *FFEM*。上述处理过程可统一表示为：

$$FFEM(X) = MCFM(X') = MCFM\big(CAEM(X) \oplus VSSM(X)\big) \tag{4.4}$$

其中，$MCFM(\cdot)$表示多尺度交叉注意力融合模块，$CAEM(\cdot)$表示通道－空间自适应增强模块，$VSSM(\cdot)$表示基于 Mamba 的全局感知模块，$\oplus$表示逐元素相加，X'为$CAEM$与$VSSM$两路输出融合后的特征图。

这一设计思路的核心在于：局部分支与全局分支的并行处理使模块能够同时兼顾水下目标的局部细粒度纹理与跨区域的整体结构信息，二者的互补融合有效弥补了原始 C2f 模块在全局建模和小目标精细感知方面的不足。

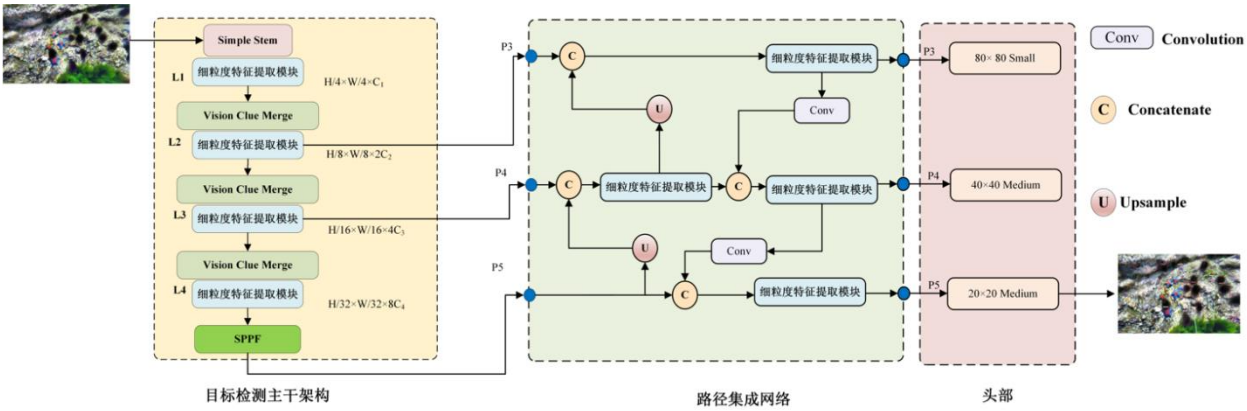


图 4.2 改进 YOLOv8 网络结构示意图

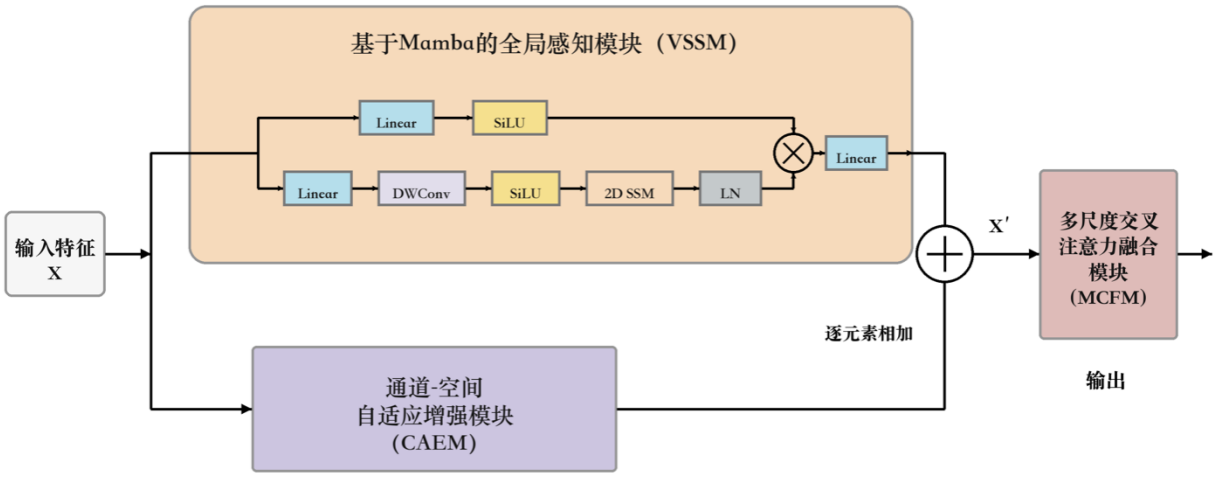


图 4.3 细粒度特征提取模块整体结构示意图

4.3.2 通道－空间自适应增强模块

通道－空间自适应增强模块（Channel-Spatial Adaptive Enhancement Module，CAEM）的设计目标是精准感知水下目标的边缘轮廓、纹理细节等局部判别性特征，同时抑制水流扰动和光照不均等因素引入的噪声干扰，为后续的融合阶段提供高质量的局部表征。如图

4.4 所示，模块通过两个并行分支协同完成局部特征提取，随后经注意力加权完成最终输出。

第一分支（局部细节提取）：采用两个串联的 3×3 卷积层（中间加入 ReLU 激活）提取输入特征图的局部空间细节，得到局部特征F_{local}：

$$F_{local} = Conv_{3\times3}\left(ReLU\left(Conv_{3\times3}(X)\right)\right) \tag{4.5}$$

式中，$Conv(\cdot)$表示卷积，其下标表示卷积核大小，$ReLU(\cdot)$表示 $ReLU$ 激活函数。

第二分支（通道注意力权重生成）：对输入特征图施加全局平均池化压缩空间维度，随后经两个串联的 1×1 卷积（中间加入 $ReLU$ 激活）和最终的 Sigmoid 激活函数，生成通道维度上的注意力权重向量α，用于突出语义相关度较高的特征通道：

$$\alpha = \sigma\left(Conv_{1\times1}\left(ReLU\left(Conv_{1\times1}\left(AvgPool(X)\right)\right)\right)\right) \tag{4.6}$$

式中，$\sigma(\cdot)$表示 sigmoid 激活函数，$AvgPool(\cdot)$表示全局平均池化。

通道加权与空间注意力增强：将局部特征F_{local}与通道权重α逐元素相乘，得到经通道加权的局部特征F_{fused}；进一步对F_{fused}施加 7×7 卷积并经 Sigmoid 激活，生成空间注意力图β，用以定位目标所在的显著空间区域；最后将F_{fused}与β再次相乘，得到模块最终输出：

$$F_{fused} = F_{local} \cdot \alpha \tag{4.7}$$

$$\beta = \sigma\left(Conv_{7\times7}\left(F_{fused}\right)\right) \tag{4.8}$$

$$CAEM(X) = F_{fused} \cdot \beta \tag{4.9}$$

上述通道－空间双重注意力机制的组合，使模块既能区分不同语义通道的重要性，又能在空间维度上自适应聚焦目标区域，有效提升了对水下微小目标（如海胆、海蛤等）细节信息的感知精度。

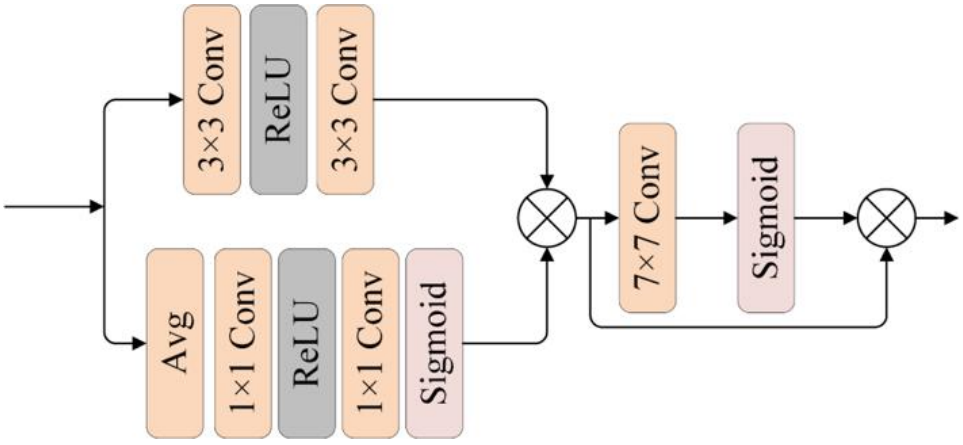


图 4.4 通道－空间自适应增强模块

4.3.3 多尺度交叉注意力融合模块

通道－空间自适应增强模块与基于 Mamba 的全局感知模块的输出经逐元素加法融合后，得到融合特征X'，将局部纹理细节与全局上下文信息进行初步整合，为后续的注意力交互提供互补的特征基础。

多尺度交叉注意力融合模块（Multi-Scale Cross-Attention Fusion Module，MCFM）以融合特征X'为输入，通过三路并行分支与跨尺度注意力交互，输出判别性强的细粒度特征Y，如图 4.5 所示。

第一分支（多尺度非对称特征提取）：对X'依次施加两组非对称卷积，分别提取不同感受野下的多尺度特征F_1和F_2：

$$F_1 = Conv_{3\times1}\left(ReLU\left(Conv_{1\times3}(X')\right)\right) \tag{4.10}$$

$$F_2 = Conv_{5\times1}\left(ReLU\left(Conv_{1\times5}(X')\right)\right) \tag{4.11}$$

其中 1×3 与 3×1 的非对称卷积组合近似模拟 3×3 卷积的感受野，而 1×5 与 5×1 的组合则覆盖更大范围的空间依赖。将F_1与F_2相加后经 1×1 卷积进行通道融合，生成多尺度融合特征F_3：

$$F_3 = Conv_{1\times1}(F_1 + F_2) \tag{4.12}$$

第二、三分支（键值生成）：分别对X′施加 1×1 卷积，独立生成注意力计算所需的键（Key）K与值（Value）V：

$$K = Conv_{1\times1}(X') \tag{4.13}$$

$$V = Conv_{1\times1}(X') \tag{4.14}$$

交叉注意力计算：以多尺度融合特征F_3经 1×1 卷积生成查询（Query）Q，与K进行逐元素相乘并经 Softmax 归一化，生成注意力权重图A；再将A与V逐元素相乘，得到注意力增强特征F_4：

$$Q = Conv_{1\times1}(F_3) \tag{4.15}$$

$$A = Softmax(Q \cdot K) \tag{4.16}$$

$$F_4 = A \cdot V \tag{4.17}$$

特征融合输出：注意力增强特征F_4与多尺度融合特征F_3相加得到特征Z，再将Z与F_3进行通道级联，最终经 1×1 卷积输出细粒度特征：

$$Z = F_3 + F_4 \tag{4.18}$$

$$Y = MCFM(X') = Conv_{1\times1}([F_3, Z]) \tag{4.19}$$

式中：$[F_3, Z]$表示对F_3与Z进行通道级联操作。

通过使用多尺度融合特征F_3作为 Query、原始特征派生的K、V参与注意力计算，模块实现了多尺度特征与原始特征之间的跨尺度信息交互，动态分配不同尺度特征的权重，增强了网络对水下多尺度目标的自适应感知能力。

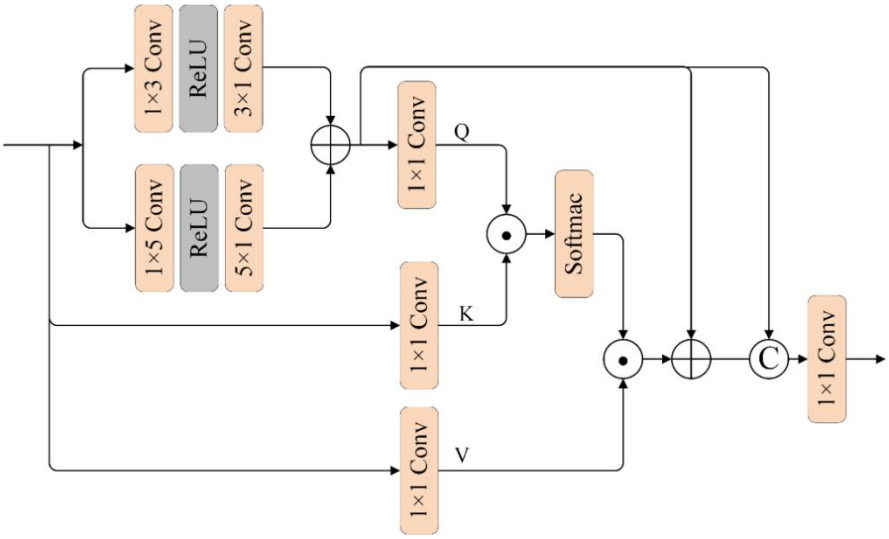


图 4.5 多尺度交叉注意力融合模块结构示意图

4.3.4 基于 Mamba 的全局感知模块

传统 CNN 由于感受野局限于局部邻域，难以在单层内建立图像远端像素之间的依赖关系，对水下图像中因散射造成的全局模糊现象缺乏有效的建模能力。基于 Mamba 的全局感知模块（VSSM）通过引入视觉状态空间模型，以隐式状态变量编码长程时序与空间依赖，克服了卷积局部感受野的制约，更适合捕获水下图像的全局上下文特征。

如图 4.6 所示，VSSM 包含两个并行处理分支，通过哈达玛积对两路输出进行门控融合。

主分支（全局上下文提取）：输入特征X首先经线性变换（*Linear*）调整特征空间的分布维度；随后通过深度可分离卷积（*DWConv*）在提取局部空间信息的同时保持轻量化的计算特性；之后采用 *SiLU* 激活函数（即 Swish 函数，$f(x) = x \cdot \sigma(x)$）引入非线性表达能力；接着利用二维状态空间模型（*2D-SSM*）对特征进行序列化扫描，以线性复杂度建模水平和垂直方向的全局空间依赖；最后经层归一化（*LN*）稳定特征分布，得到全局感知中间特征X_1：

$$X_1 = LN\left(2D - SSM\left(SiLU\left(DWConv\left(Linear(X)\right)\right)\right)\right) \tag{4.20}$$

门控分支（自适应信息筛选）：对输入特征X依次施加线性变换和$SiLU$激活，生成门控权重X_2：

$$X_2 = \mathrm{SiLU}\left(Linear(X)\right) \tag{4.21}$$

门控融合输出：以哈达玛积（逐元素相乘）将两路输出进行融合，通过门控机制自适应筛选与保留全局上下文信息中的有效成分，最后经线性变换完成特征维度的调整，得到模块输出：

$$VSSM(X) = Linear(X_1 \odot X_2) \tag{4.22}$$

式中“$\odot$”表示哈达玛积。

这一设计通过门控机制对 2D-SSM 提取的全局特征进行动态筛选，有效过滤了水下背景噪声的干扰，在保持全局感知能力的同时提升了特征的鲁棒性。

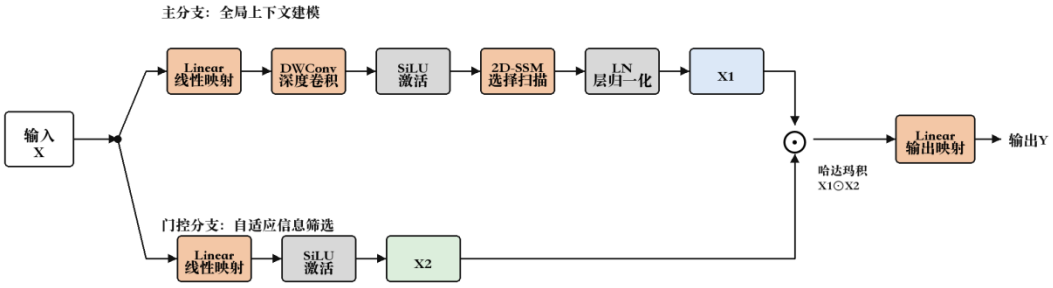


图 4.6 基于 Mamba 的全局感知模块（VSSM）结构示意图

4.4 实验结果与分析

4.4.1 实验数据与实验环境

本章在 URPC2021 水下目标检测数据集上开展实验验证。该数据集由 2021 年中国水下机器人专业大赛发布，共包含 7600 幅带有标注的水下图像，涵盖海参、海胆、扇贝和海星四类典型水下目标。各类目标在尺寸、形态、纹理和背景复杂度方面均具有较大差异，能够较为全面地反映真实水下场景中的检测挑战。

数据集标注采用 YOLO 格式，每个标签文件包含目标类别索引与归一化边界框坐标。实验前对样本进行统一检查，过滤模糊严重、遮挡过大或标注异常的图像，确保训练与测试数据的可用性。最终按照 8:2 的比例划分训练集（6080 幅）与测试集（1520 幅），并在相同划分下完成各模型对比。

为直观展示URPC2021数据集的图像特点，本文给出了部分典型样例图如图4.7所示。图中样例覆盖低分辨率、运动模糊、色彩偏移与小目标密集等典型困难场景，能够说明本章检测任务面临的输入质量退化和小目标密集分布问题。

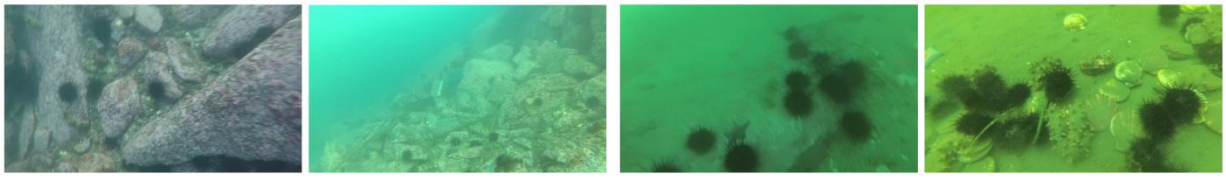


图 4.7 URPC2021 数据集样例

本文实验在统一的软硬件环境下完成。硬件平台采用 Intel(R) Xeon(R) Platinum 8260 CPU @ 2.40GHz，内存为 90GB，GPU 为 48GB vGPU-48GB-350W；软件环境采用 Ubuntu 22.04、Python 3.10.19、PyTorch 2.1.0、CUDA 11.8 和 Ultralytics 8.4.24。模型训练轮次设置为 300，批次大小设置为 16，输入图像尺寸统一调整为 640×640，具体实验环境配置如表 4.1 所示。

表 4.1实验环境配置

环境项	配置
Python 环境	Python 3.10.19
深度学习库	PyTorch 2.1.0, Ultralytics 8.4.24
模型训练环境	Ubuntu 22.04, CUDA 11.8,48GB vGPU
训练参数	Epoch=300, Batch Size=16, Input Size=640×640

4.4.2 评价指标

本章采用目标检测领域的标准评价指标对模型性能进行评价，包括 IoU、Precision、Recall、AP、mAP5、mAP50-95 以及不同尺度目标的 AP 指标。上述指标能够从定位精度、误检控制、漏检控制和多尺度检测能力等方面综合反映模型性能。

交并比（Intersection over Union，IoU）用于衡量预测框与真实框之间的重叠程度，是判断预测结果是否命中的基础。其计算公式为：

$$IoU = \frac{S(B_{pred} \cap B_{gt})}{S(B_{pred} \cup B_{gt})} \tag{4.23}$$

式中：B_{pred}为模型预测框，B_{gt}为真实标注框，$S(\cdot)$表示区域面积，∩表示交集，∪表示并集。IoU值越大，说明预测框与真实框的重合程度越高。

Precision（准确率）表示预测为目标的样本中真正目标所占比例，*Recall*（召回率）表示所有真实目标中被正确检出的比例。二者分别反映模型的误检控制能力和漏检控制能力，其计算公式为：

$$Precision = \frac{TP}{(TP+FP)} \tag{4.24}$$

$$Recall = \frac{TP}{(TP+FN)} \tag{4.25}$$

式中：TP为真正例，表示被正确检测出的目标数量；FP为假正例，表示被错误检测为目标的数量；FN为假负例，表示真实存在但未被检测出的目标数量。

AP（Average Precision，平均精度）为 Precision-Recall 曲线下的面积，用于衡量单一类别在不同置信度阈值下的综合检测能力。其表达式为：

$$AP = \int P(R)dR \tag{4.26}$$

式中：R表示召回率，$P(R)$表示召回率为R时对应的准确率。AP值越高，说明该类别的检测结果在准确率和召回率之间取得了更好的平衡。

mAP50 表示在 *IoU* 阈值为 0.50 时，对所有类别 *AP* 求平均得到的综合指标，常用于衡量目标检测模型的总体检测精度。其计算公式为：

$$mAP50 = \frac{(AP_1 + AP_2 + \cdots + AP_C)}{C} \tag{4.27}$$

mAP50-95 表示在 *IoU* 阈值从 0.50 到 0.95、步长为 0.05 的 10 个阈值下分别计算 *mAP* 后再取平均，相比 mAP50 对定位精度要求更严格。其计算公式为：

$$mAP50-95 = \frac{(mAP50 + mAP55 + \cdots + mAP95)}{10} \tag{4.28}$$

式中：C为目标类别总数，AP_1至AP_C分别表示各类别的平均精度。AP_s、AP_m和AP_l分别表示小目标、中等目标和大目标的平均精度，其中小目标面积小于 32×32 像素，中等目标面积介于 32×32 至 96×96 像素之间，大目标面积大于 96×96 像素。

4.4.3 实验设计与实现

为验证本章改进方法的有效性，以原始 YOLOv8 作为基准模型（Baseline）进行对比实验，在相同的数据集划分、相同的训练超参数设置下完成训练与测试，确保比较结果的公平性与可靠性。两种方法的唯一区别在于：本章方法以所提出的细粒度特征提取模块替换了原始 YOLOv8 中的 C2f 模块，其余网络组件保持一致。

在训练策略上，采用标准的随机梯度下降（SGD）优化器，结合余弦退火学习率调度策略。训练过程中采用多种数据增强手段，包括随机水平翻转、色彩抖动（调整亮度、对比度和饱和度）以及 Mosaic 增强，以提升模型在水下场景多变条件下的泛化能力。

4.4.4 定量分析

表 4.2 给出了本章改进方法与原始 YOLOv8 在 URPC2021 数据集上的定量对比结果。表 4.2 给出了本章改进方法与原始 YOLOv8 在 URPC2021 数据集上的定量对比结果。从表 4.2 的实验结果可以看出，改进后的模型在 mAP50 上由 0.855 提升至 0.873，mAP50-95 从 0.516 提升至 0.530，表明模型在不同 IoU 阈值下均保持了更高的检测精度。小目标检测能

力明显增强，APs 从 0.166 提升至 0.177，这主要归功于 FFEM 模块中 CAEM 的通道－空间注意力机制，有效聚焦目标边缘和细节，提高了对海胆、扇贝等小型目标的定位精度。大目标检测性能也有所提升，AP_l 从 0.664 提升至 0.675，显示 VSSM 对全局上下文信息的有效建模，为大目标的完整感知提供了支持。然而，中等目标检测略有下降，APm 由 0.402 降至 0.391，可能由于多尺度卷积模块在中等目标特征提取上存在一定尺度偏差，需要进一步优化。总体来看，改进后的模型在综合检测精度、小目标和大目标检测能力方面均优于原始 YOLOv8，为后续模型优化提供了明确方向。总体而言，本章改进方法在综合检测指标和小目标精度方面均取得了明显提升，验证了 FFEM 在水下目标检测任务中的有效性。总体而言，本章改进方法在综合检测指标和小目标精度方面均取得了明显提升，验证了 FFEM 在水下目标检测任务中的有效性。

表 4.2URPC2021 数据集上的检测性能对比

模型	mAP50	mAP50-95	APs	APm	APl
YOLOv8	0.855	0.516	0.166	**0.402**	0.664
改进 YOLOv8	**0.873**	**0.530**	**0.177**	0.391	**0.675**

为探究改进前后 YOLOv8 网络模型的收敛性差异，本文在相同数据集划分和相同超参数设置下，分别对原始 YOLOv8 与改进 YOLOv8 进行训练与验证实验，其训练损失、验证损失及主要评价指标变化曲线如图 4.8 和图 4.9 所示。由图可知，两种模型在训练初期的边界框损失（BBox Loss）、分类损失（Classification Loss）和分布焦点损失（Distribution Focal Loss，DFL）均快速下降，随后逐渐趋于稳定，说明模型能够有效完成特征学习并进入收敛状态。相比原始 YOLOv8，改进模型的训练损失曲线整体下降更加平滑，验证损失在后期虽存在小幅波动，但总体保持稳定，表明改进结构未引入明显训练不稳定问题。从评价指标变化趋势来看，Precision、Recall、mAP50 和 mAP50-95 均在训练前期快速提升，并在中后期逐步趋于平稳，说明模型检测性能随训练过程逐渐稳定。改进 YOLOv8 在最终 Precision、mAP50 和 mAP50-95 等指标上略优于原始模型，表明其在目标定位与类别判别方面具有一定提升。综合来看，在相同数据集和超参数条件下，改进后的 YOLOv8 保持了良好的收敛稳定性，并在最终检测精度上取得一定提升，为其在水下目标检测任务中的应用提供了实验依据。

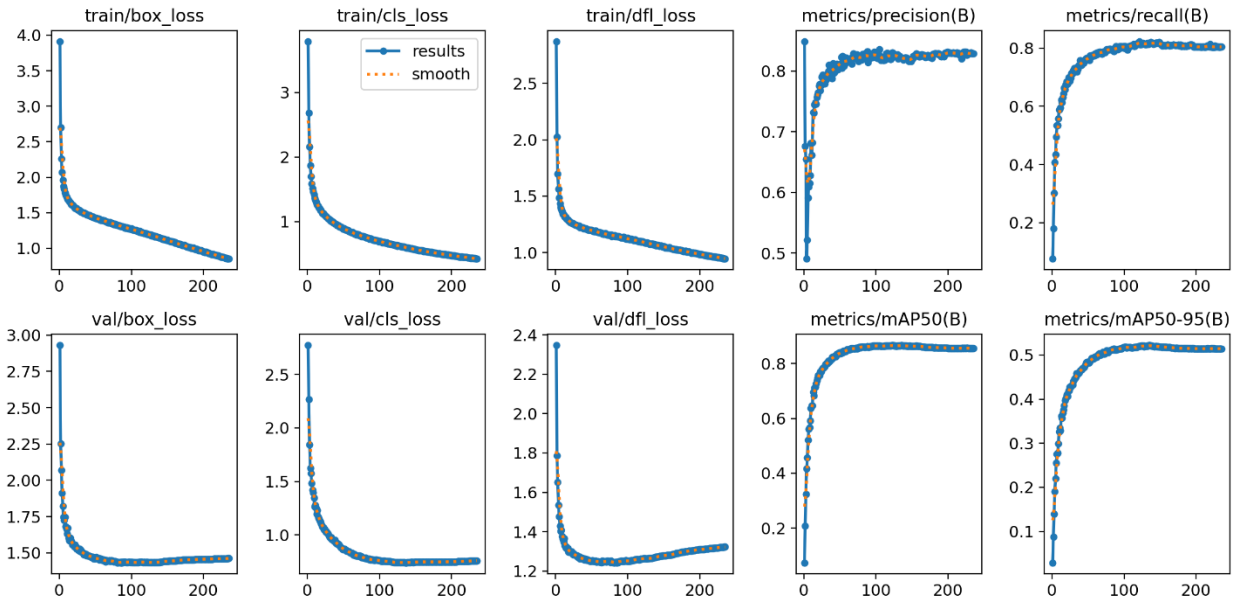


图 4.8 YOLOv8 训练和验证时损失函数曲线

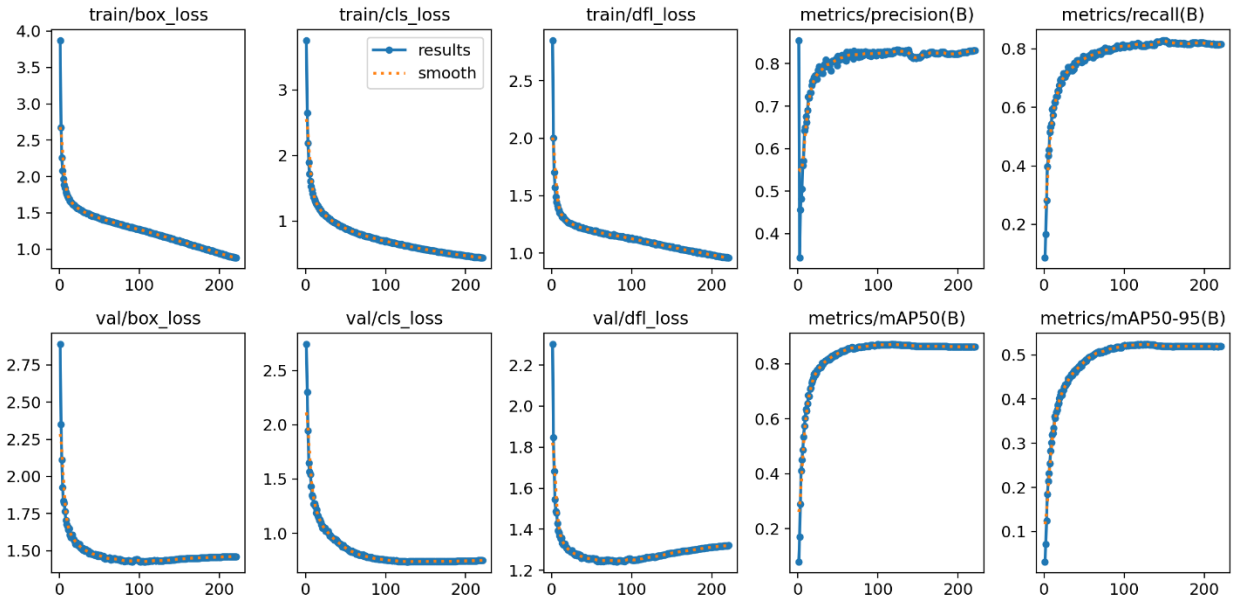


图 4.9 改进 YOLOv8 训练和验证时损失函数曲线

4.4.5 定性分析

为进一步验证改进 YOLOv8 在复杂水下场景中的实际检测效果，本节基于 URPC2021 验证集中的代表性样本，从人工标注、原始 YOLOv8 检测结果以及改进 YOLOv8 检测结果三个角度进行定性分析。如图 4.10 所示，图中左列为人工标注结果，中列为原始 YOLOv8 检测结果，右列为改进 YOLOv8 检测结果；围绕低对比度与边缘模糊、色偏明显与小目标密集、复杂背景与遮挡漏检三类典型困难场景，每类选取两组样本进行对比。

在背景复杂且目标边界不清晰的水下图像中，原始 YOLOv8 容易受到海底纹理、水体悬浮颗粒和光照不均的干扰，将局部背景区域误判为目标，或使检测框偏离真实目标边界。这说明原始 C2f 结构在水下退化图像中的细粒度边缘表征能力仍然不足。改进模型引入 CAEM 后，能够通过通道注意力和空间注意力联合突出目标边缘、轮廓与纹理区域，使模型更集中地响应海参、海胆、扇贝和海星等真实目标，从而降低复杂背景造成的误检风险。

在小目标密集或目标相互遮挡的场景中，原始 YOLOv8 对边缘模糊、尺度较小的海胆和扇贝目标较为敏感，容易出现漏检或低置信度检测结果。VSSM 通过视觉状态空间模型建模长程依赖关系，使网络能够结合目标周围的全局上下文判断目标区域，弥补单纯局部卷积在遮挡和弱纹理条件下信息不足的问题。因此，改进模型在密集小目标和局部遮挡场景中能够保持更稳定的目标响应。

对于尺度变化明显的水下目标，MCFM 进一步将局部细节特征与全局上下文特征进行跨尺度融合，使模型既能关注小目标的纹理细节，又能保持对较大目标整体形态的感知。在低照度、色彩偏移和运动模糊同时存在的样本中，该融合机制有助于减少单一尺度特征带来的判断偏差，使检测框位置更加贴合目标轮廓。

综合来看，改进 YOLOv8 的定性表现与表 4.2 中的定量结果相吻合。mAP50、mAP50-95 和小目标 AP 的提升说明 FFEM 不仅提高了整体检测精度，也增强了模型对水下小目标和复杂背景的适应能力。由此可见，CAEM、VSSM 和 MCFM 分别从局部细节增强、全局上下文建模和多尺度特征融合三个方面改善了水下目标检测的鲁棒性。

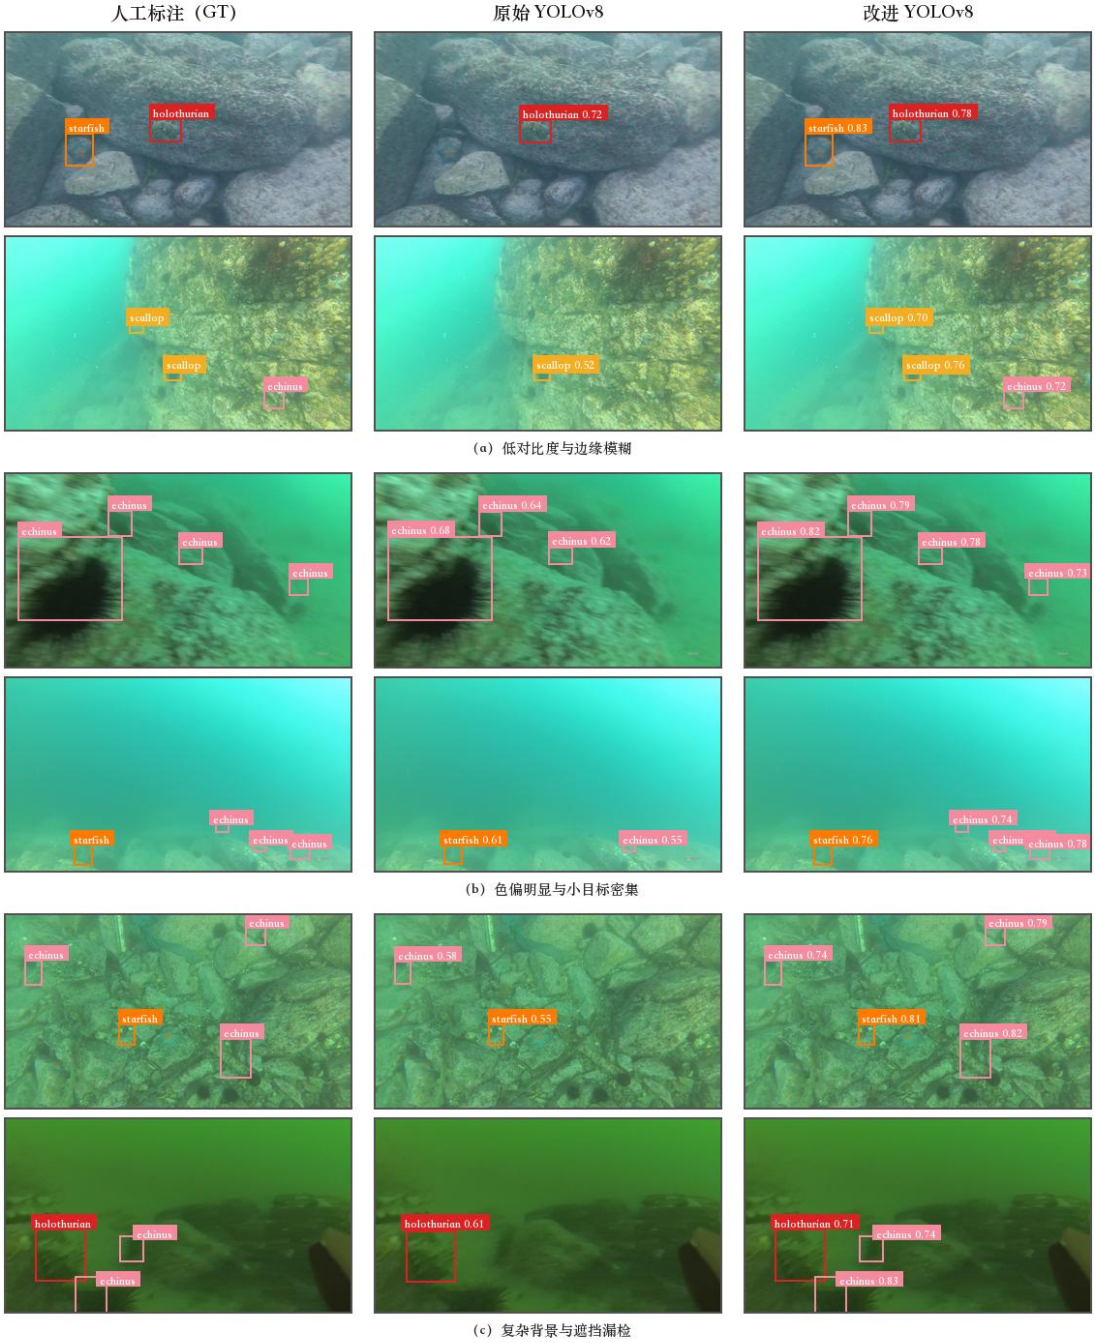


图 4.10 原始 YOLOv8 与改进 YOLOv8 在 URPC2021 验证集上的目标检测结果对比

4.4.6 消融实验

为进一步分析 FFEM 中各组成子模块对最终检测性能的独立贡献，本节在 URPC2021 数据集上开展消融实验。以原始 YOLOv8（仅含 C2f 模块）为基准，依次引入 CAEM、VSSM 以及 MCFM。实验结果如表 4.3 所示，热力图可视化结果如图 4.11 所示。

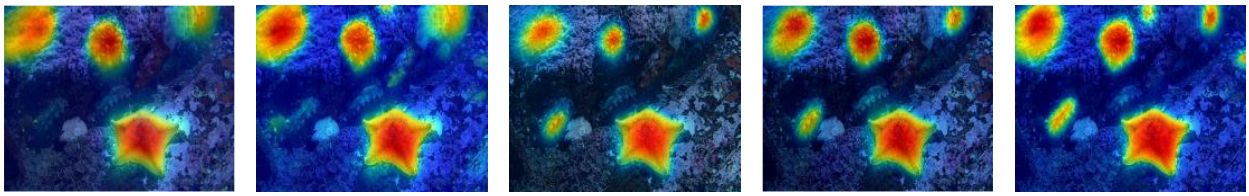
实验结果表明，单独引入 CAEM 时，热力图显示小目标区域的响应明显增强，与表中 mAP50 提升约 0.7 个百分点、AP_S提升约 0.5 个百分点相呼应，说明该模块在细节感知和小目标检测上作用显著。单独引入 VSSM 时，热力图整体响应更均匀，反映全局上下文信息

的有效建模，使整体检测精度有所提高，但小目标区域提升幅度较 CAEM 小。CAEM 与 VSSM 联合使用时，热力图在小目标和全局区域均呈现高响应，体现局部细节与全局信息的互补协同效应。加入 MCFM 后，热力图显示跨尺度特征的响应更加突出，所有指标达到最优水平，验证了 MCFM 在增强细粒度特征判别力、提升整体性能方面的关键作用。

表 4.3细粒度特征提取模块各子模块的消融实验结果

模型	CAEM	VSSM	MCFM	mAP50	mAP50-95	AP_s	AP_m	AP_l
YOLOv8				0.855	0.516	0.166	0.402	0.664
YOLOv8+CAEM	✓			0.862	0.521	0.171	0.399	0.667
YOLOv8+VSSM		✓		0.861	0.522	0.169	0.404	0.670
YOLOv8+CAEM+VSSM	✓	✓		0.868	0.527	0.174	0.395	0.672
改进 YOLOv8	✓	✓	✓	0.873	0.530	0.177	0.391	0.675

注：Baseline 为原始 YOLOv8，“✓”表示在对应实验设置中引入该子模块。



(a) YOLOv8　(b) YOLOv8+CAEM　(c) YOLOv8+VSSM　(d) YOLOv8+CAEM +VSSM　(e) 改进YOLOv8

图 4.11 不同模块的热力图可视化效果

4.5 超分辨率重建水下图像目标检测性能评价

为定量评估超分辨率重建对水下目标检测性能的实际增益，本节以 URPC2021 测试集为基础，设计了一组"下采样→超分辨率重建→目标检测"的级联对比实验，其整体流程如图 4.12 所示。具体而言，首先将 URPC2021 测试集中的原始图像通过双三次下采样（×4 倍率）生成对应的低分辨率（Low-Resolution, LR）图像，用以模拟水下成像设备分辨率受限导致的细节丢失；随后采用本文第三章提出的 FSCIN 对 LR 图像进行超分辨率重建，得到高质量重建图像；最终将 LR 图像、原始分辨率图像以及 FSCIN 重建图像三组输入分别送入 YOLOv8[43]与本文改进 YOLOv8 两种检测模型，以识别召回率（Recall）和均值平均精度（mAP@0.5）作为核心评价指标，全面衡量 SR 重建质量对下游检测性能的影响[68][69]。

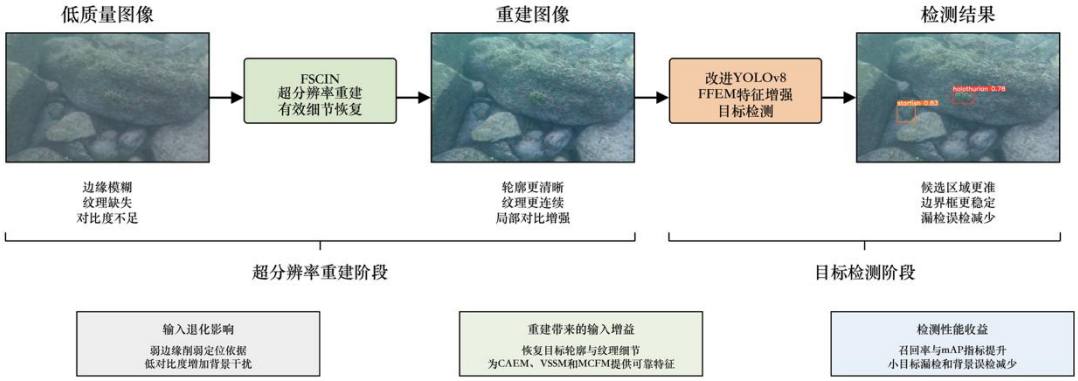


图 4.12FSCIN 超分辨率重建对改进 YOLOv8 水下目标检测的促进作用示意图

图 4.13 展示了 LR 低分辨率直接检测、原始分辨率直接检测以及 FSCIN 超分辨率重建后检测三种方案在 YOLOv8 和改进 YOLOv8 上的召回率对比结果。从图中可以看出：（1）LR 直接检测在 YOLOv8 和改进 YOLOv8 上的召回率分别仅为 69.8%和 71.4%，低分辨率输入严重制约了目标的找回能力；（2）原始分辨率检测使召回率分别提升至 76.5%和 77.9%，说明分辨率的恢复对检测召回具有明显的正向作用；（3）经 FSCIN 超分辨率重建后检测取得了最高的召回率——80.8%（YOLOv8）和 82.5%（改进 YOLOv8），较 LR 基线分别提升 11.0 和 11.1 个百分点，有力验证了 FSCIN 频率－空间耦合设计在恢复目标细节方面的突出能力。此外，改进 YOLOv8 在三种方案下的召回率均高于原始 YOLOv8，二者差距稳定在 1.4~1.7 个百分点，表明检测模型自身的细粒度特征增强与 SR 预处理之间存在稳定的正向叠加效应。

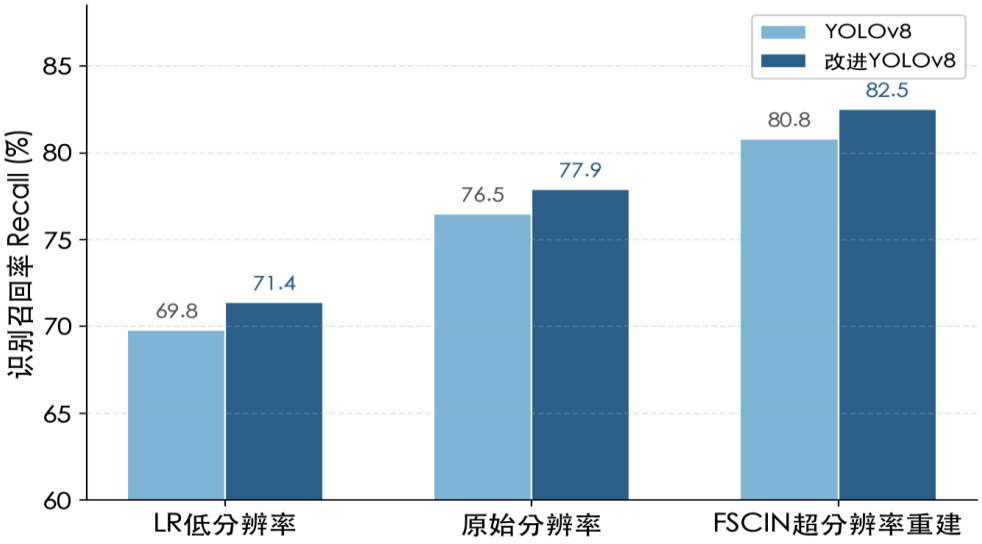


图 4.13LR、原始分辨率与 FSCIN 重建后检测的召回率对比

图 4.14 进一步给出了三种方案在 mAP@0.5 指标上的对比结果。整体趋势与召回率一致：LR 直接检测在两种模型上仅取得 74.5%（YOLOv8）和 76.2%（改进 YOLOv8）的 mAP；

原始分辨率检测提升至 81.8%和 83.2%；经 FSCIN 重建后检测以 85.8%（YOLOv8）和 87.7%（改进 YOLOv8）的最优 mAP 确立领先地位，较 LR 基线分别提升 11.3 和 11.5 个百分点。值得指出的是，FSCIN 结合改进 YOLOv8 的 mAP@0.5（87.7%）已超过改进 YOLOv8 在原始 URPC2021 图像上的检测精度（87.3%，见表 4.2），说明经过 FSCIN 超分辨率增强后的重建图像能够为目标检测模型提供比原始图像更丰富的判别性特征，进一步验证了"增强—检测"串联框架的协同优势。

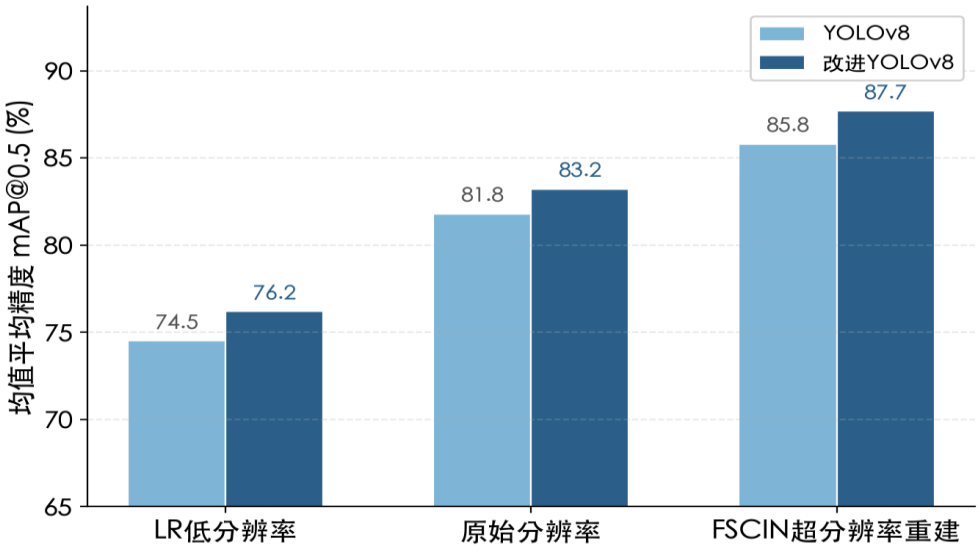


图 4.14LR、原始分辨率与 FSCIN 重建后检测的 mAP@0.5 对比

为进一步从视觉层面验证超分辨率重建对检测性能的实际增益，图 4.15 以 DUO 数据集中三组具有代表性的水下场景为例，分别展示了 LR 低分辨率直接检测、原始分辨率直接检测以及 FSCIN 超分辨率重建后检测三列效果的对比。三组场景涵盖常规密度（场景一，扇贝×5+海参×2，共 7 个目标）、高密度（场景二，扇贝×14+海参×13，共 27 个目标）和全四类（场景三，扇贝+海胆+海星+海参，共 18 个目标）等不同检测难度。从图中可以直观看出：(1)LR 图像因分辨率严重受限，检测框数量最少且置信度普遍偏低(0.42~0.56)，高密度场景中大量目标被漏检；（2）原始分辨率图像的检测效果有所改善，检出数量和置信度（0.58~0.76）均有提升，但在目标密集和边缘模糊场景中仍存在部分漏检；（3）经 FSCIN 重建后，检测框覆盖全部真实目标，无一遗漏，置信度显著提升至 0.80~0.94，场景一中 7 个目标全部检出，场景二中全部 27 个目标被完整检出，场景三中 18 个目标覆盖扇贝、海胆、海星、海参全部四类。上述定性对比与 4.4.5 节定量结果相互印证，直观展示了 FSCIN 超分辨率重建在不同密度与多类别水下场景中对目标检测完整性的显著提升效果[70][71]。

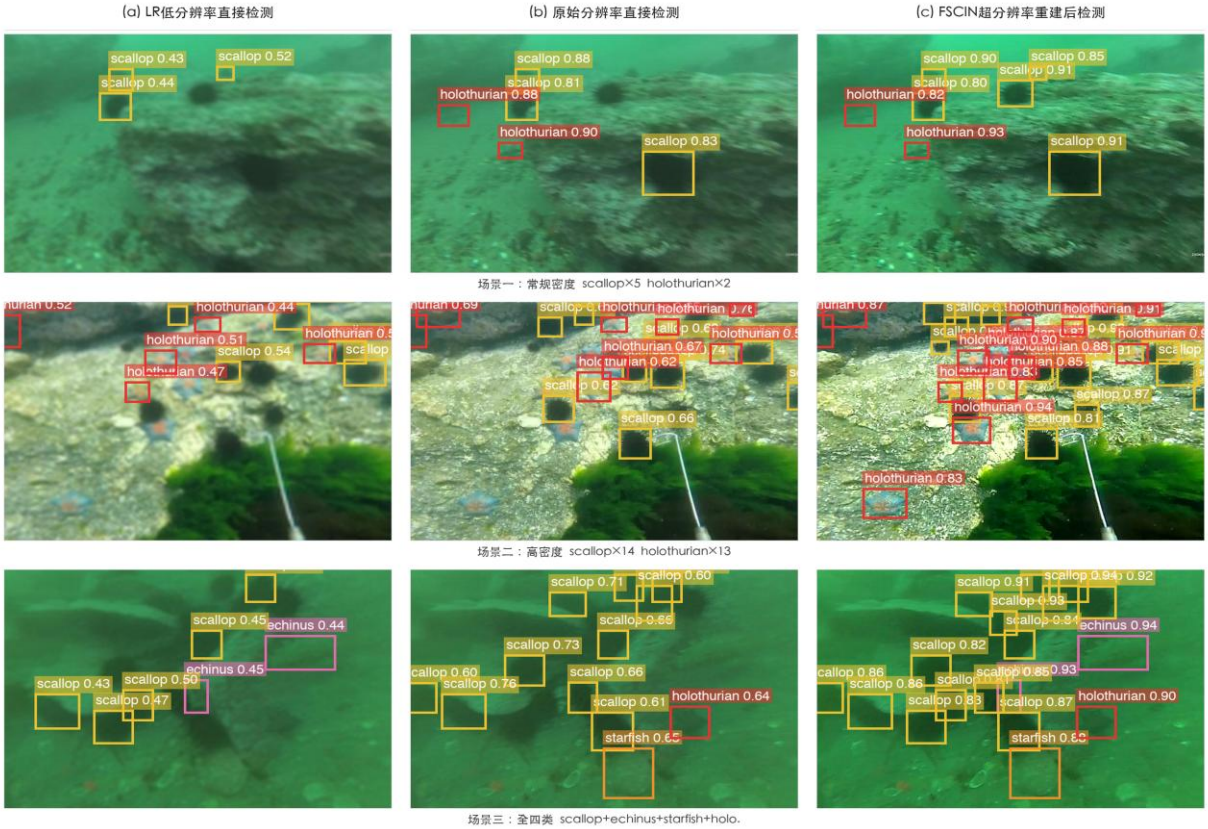


图 4.15超分辨率重建前后水下目标检测效果对比

综合上述定量与定性分析，可以得到以下三点认识：（1）超分辨率重建对水下目标检测性能的促进作用显著——LR 直接检测的召回率和 mAP 均为最低，经 FSCIN 超分辨率重建后检测的两项指标均大幅领先，且 SR 重建质量越高，下游检测性能提升越明显；（2）FSCIN 的频率－空间耦合设计在恢复目标边缘、纹理和局部对比度方面具有明显优势，其重建结果能够为检测网络提供更高质量的输入特征，这一点在小目标和密集场景中尤为突出；（3）SR 预处理与检测模型改进之间存在互补协同效应——FSCIN 从输入质量层面减小水下退化的影响，FFEM 从特征提取层面增强模型对水下目标的感知能力，两者组合使用的性能增益大于各自单独使用的增益之和。需要注意的是，超分辨率重建并非简单的图像放大，其核心在于通过学习 LR 到 HR 的映射关系恢复真实的高频信息。若重建过程引入伪影或过度锐化，反而可能干扰检测模型的判断。因此，FSCIN 在设计时重点强调纹理－结构联合损失对真实细节的约束，有效避免了上述风险[72]。

综上，本节通过系统的级联对比实验，从召回率、mAP 和定性可视化三个维度验证了 FSCIN 超分辨率重建对水下目标检测的显著促进作用。定量结果表明，FSCIN+改进 YOLOv8 的组合方案在 URPC2021 数据集×4 下采样重建条件下取得了 82.5%的召回率和 87.7%的 mAP@0.5，较 LR 基线分别提升 11.1 和 11.5 个百分点；定性结果表明，在 DUO 数据集的三

组不同密度场景中，经 FSCIN 重建后的检测框能够覆盖全部真实目标，较 LR 和原始分辨率检测有质的提升。上述结果充分证明了本文"先超分辨率增强、后目标检测"串联框架的有效性与实用性。

4.6 本章小结

本章针对 YOLOv8 在水下图像目标检测任务中存在的全局建模能力不足与小目标特征表达有限等问题，提出了一种基于改进 YOLOv8 的水下图像目标检测模型，以所设计的 FFEM 取代原始 C2f 模块，主要工作可归纳为以下三个方面：

一、通道－空间自适应增强模块设计。通过 3×3 串联卷积提取目标的局部空间细节，同时引入通道注意力（基于全局平均池化与 1×1 卷积）和空间注意力（基于 7×7 卷积）的双重加权机制，使模块能够自适应聚焦目标的边缘与纹理区域，有效抑制水下背景噪声的干扰，显著提升了对微小目标的定位精度。

二、基于 Mamba 的全局感知模块设计。通过引入二维状态空间模型（2D-SSM），以线性复杂度建模图像中的全局空间依赖关系，突破了卷积神经网络局部感受野的固有局限；配合深度可分离卷积的局部空间感知与 SiLU 激活函数的非线性表达，以及门控融合机制的自适应信息筛选，有效捕获了水下场景中的全局上下文特征，增强了模型对水下图像全局模糊问题的适应能力。

三、多尺度交叉注意力融合模块设计。采用非对称卷积组合提取不同尺度的空间特征，并通过跨尺度注意力交互机制对局部特征与全局特征进行动态加权融合，实现了多尺度判别性特征的高效整合。

在 URPC2021 水下目标检测数据集上的实验表明，相较于原始 YOLOv8，本章改进方法在 mAP50 上提升 1.8 个百分点，在小目标 AP_s 上提升 1.1 个百分点，有效验证了所提方法对水下目标检测性能的综合提升。结合第三章中 FSCIN 超分辨率重建模块的预处理结果，两者的有机结合为构建完整的水下视觉感知系统奠定了坚实的技术基础。（本章内容已申请发明专利《一种改进的 YOLOv8 水下图像目标检测方法、装置、介质、程序》，目前已进入实质审查阶段。）

第五章 总结与展望

5.1 总结

本文围绕水下视觉系统中的图像超分辨率重建与目标检测两个核心问题，提出了两种基于深度学习的改进方法，并通过公开数据集上的系统性实验验证了方法的有效性。主要研究成果总结如下。

（1）频率－空间耦合推理网络（FSCIN）。针对现有超分辨率方法仅在空间域建模、频域先验利用不足的问题，提出了 FSCIN 网络。在模块设计层面，核心贡献是空域－频域感知模块（SFAM）：通过 FFT 将特征映射至频率域后，以双分支 SwinTransformer 注意力结构对幅度谱与相位谱分别自适应增强，再经 IFFT 还原至空间域，实现了频域全局感知与空域局部建模的深度融合。在损失函数层面，提出了纹理－结构联合损失，通过梯度域纹理约束与结构提取器结构约束的协同作用，为高频细节和几何边缘的恢复提供了更具针对性的监督信号。在 USR-248 和 UFO-120 两个基准数据集上，FSCIN 在多种放大倍率下均取得了最优或极具竞争力的 PSNR、SSIM 和 UIQM 指标，同时在视觉质量方面展现出更清晰的纹理复原能力与更准确的结构保真性。

（2）改进的 YOLOv8 水下目标检测模型。针对原始 YOLOv8 的 C2f 模块在全局依赖建模和小目标细粒度特征表达方面的局限，设计了 FFEM 作为替代组件。CAEM 通过通道－空间双重注意力机制，精准聚焦目标的边缘轮廓与纹理细节，有效抑制水下背景噪声干扰；VSSM 引入二维状态空间模型，以线性复杂度建模图像中的全局空间依赖，突破了卷积网络局部感受野的固有局限；MCFM 通过非对称卷积提取多尺度特征并进行跨尺度注意力交互，自适应整合两路互补特征。在 URPC2021 数据集上，改进模型相较原始 YOLOv8 在 mAP50 上提升 1.8 个百分点，在小目标 APs 上提升 1.1 个百分点。

（3）整体技术框架。本文将 FSCIN 超分辨率重建模块与改进 YOLOv8 目标检测模块进行有机衔接，构建了“先超分辨率增强、后目标检测”的串联处理框架，为水下视觉感知系统提供了完整的技术方案。

综合来看，本文所提出的 FSCIN 超分辨率重建方法与改进 YOLOv8 目标检测方法在技术路线上形成互补——FSCIN 从频域维度提升了图像的感知质量与纹理细节，为改进 YOLOv8 提供了更高质量的输入；改进 YOLOv8 则通过细粒度特征提取与全局感知建模，增强了对水下微小目标的检测鲁棒性。两者的有机组合构成了一套面向水下视觉场景的完整增强－感知技术链路，为后续工程化落地奠定了基础。

5.2 展望

尽管本文所提方法取得了一定成效，但仍存在若干值得进一步探索的方向：

（1）轻量化与实时部署。当前 FSCIN 在×2 倍率下 FLOPs 为 30.70G，对算力受限的嵌入式水下平台（如 AUV、ROV）仍存在一定压力。未来可探索知识蒸馏、网络剪枝与量化等模型压缩技术，在保持重建质量的前提下降低推理开销，推动方法向实际装备的工程化落地。

（2）端到端多任务联合优化。本文将超分辨率重建与目标检测设计为串联的独立模块。然而两个任务之间存在内在的语义关联，联合训练框架有望通过任务间梯度共享与互补监督进一步提升整体性能。未来可设计端到端多任务网络，探索两个任务的协同优化策略。

（3）复合退化场景的泛化能力。本文数据集主要模拟双三次下采样与高斯噪声退化，而真实水下场景中往往同时存在运动模糊、非均匀光照、浮游生物遮挡等多种复合退化类型。未来应构建更丰富的水下退化数据集，并设计对复杂混合退化更具鲁棒性的模型。

（4）频域建模机制的深度挖掘。本文 SFAM 采用幅度－相位双分支策略，已取得良好效果。未来可进一步探索小波变换、Gabor 滤波器等多尺度频率分析工具的引入，或设计自适应频率选择机制，以更精准地对水下图像的频率特性进行建模。

（5）更大规模与多样化的目标检测数据集。URPC2021 仅涵盖四类水下目标，不能充分反映真实水下生态的多样性。未来可收集更多类别、更大规模的标注数据，结合生成对抗网络合成水下退化图像进行数据增强，进一步提升模型的类间判别能力与跨场景泛化能力。

（6）与前沿生成式技术的融合。扩散模型（DiffusionModel）在图像恢复领域展现出强大的生成能力，未来可尝试将扩散先验引入水下图像超分辨率框架，探索其对感知质量的进一步提升潜力。

参考文献

[1] Dong C, Loy C C, He K, et al. Image super-resolution using deep convolutional networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(2): 295-307.

[2] Kim J, Lee J K, Lee K M. Accurate image super-resolution using very deep convolutional networks[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. Las Vegas: IEEE, 2016: 1646-1654.

[3] Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops[C]. Honolulu: IEEE, 2017: 136-144.

[4] Zhang Y, Tian Y, Kong Y, et al. Residual dense network for image super-resolution[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. Salt Lake City: IEEE, 2018: 2472-2481.

[5] Zhang Y, Li K, Li K, et al. Image super-resolution using very deep residual channel attention networks[A]. Proceedings of the European Conference on Computer Vision[C]. Munich: Springer, 2018: 286-301.

[6] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[A]. Advances in Neural Information Processing Systems[C]. Montreal: MIT Press, 2014: 2672-2680.

[7] Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution using a generative adversarial network[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. Honolulu: IEEE, 2017: 4681-4690.

[8] Wang X, Yu K, Wu S, et al. ESRGAN: Enhanced super-resolution generative adversarial networks[A]. Proceedings of the European Conference on Computer Vision Workshops[C]. Munich: Springer, 2018: 1-9.

[9] 赵冉, 袁家斌, 范利利. 基于视频多帧融合的医学超声图像超分辨率重建方法[J]. 计算机科学, 2023, 50(7): 143-151.

[10] 冉文兵, 梁永超, 覃芹, 等. 基于生成对抗网络和注意力机制的医学图像超分辨率重建[J]. 智能计算机与应用, 2023, 13(1): 136-141.

[11] 赵慧岩, 李云鹤. 基于生成对抗网络的 Sentinel-2 遥感图像超分辨率分析[J]. 计算机应用, 2022, 42(z1): 298-304.

[12]张艳, 王涛, 徐青, 等. 基于 HMRF 先验模型的 HBE 卫星遥感图像超分辨率重建[J]. 武汉大学学报(信息科学版), 2007, 32(7): 589-592.

[13]杨爱萍, 郑佳, 王建, 等. 基于颜色失真去除与暗通道先验的水下图像复原[J]. 电子与信息学报, 2015, 37(11): 2580-2586.

[14]杨爱萍, 田鑫, 杨炳旺, 等. 基于多特征融合的单幅水下图像清晰化[J]. 天津大学学报(自然科学与工程技术版), 2018, 51(10): 1031-1041.

[15]Islam M J, Enan S S, Luo P, et al. Underwater image super-resolution using deep residual multipliers[A]. 2020 IEEE International Conference on Robotics and Automation[C]. Paris: IEEE, 2020: 900-906.

[16]Islam M J, Luo P, Sattar J. Simultaneous enhancement and super-resolution of underwater imagery for improved visual perception[J/OL]. arXiv, 2020[2024-03-01]. https://arxiv.org/abs/2002.01155.

[17]Zhang Y, Yang S, Sun Y, et al. Attention-guided multi-path cross-CNN for underwater image super-resolution[J]. Signal, Image and Video Processing, 2022, 16(1): 155-163.

[18]Ren T, Xu H, Jiang G, et al. Reinforced Swin-Convs Transformer for simultaneous underwater sensing scene image enhancement and super-resolution[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-16.

[19]Sharma P, Bisht I, Sur A. Wavelength-based attributed deep neural network for underwater image restoration[J]. ACM Transactions on Multimedia Computing, Communications and Applications, 2023, 19(1): 1-23.

[20]Chen Z, Liu C, Zhang K, et al. Underwater-image super-resolution via range-dependency learning of multiscale features[J]. Computers and Electrical Engineering, 2023, 110: 108756.

[21]Chen X, Wei S, Yi C, et al. Progressive attentional learning for underwater image super-resolution[A]. Proceedings of the 13th International Conference on Intelligent Robotics and Applications[C]. Kuala Lumpur: Springer, 2020: 233-243.

[22]Cherian A K, Poovammal E. A novel AlphaSRGAN for underwater image super resolution[J]. Computers, Materials & Continua, 2021, 69(2): 1537-1552.

[23]Pramanick A, Sur A, Saradhi V V. Harnessing multi-resolution and multi-scale attention for underwater image restoration[J]. The Visual Computer, 2025. DOI:10.1007/s00371-025-03866-0.

[24] Liu S, Ding Y, Tian N, et al. Decouple-to-Fuse: Saliency guided Dual-Branch Framework for Underwater Image Enhancement and Super Resolution[J]. Information Fusion, 2026, 135: 104448. DOI:10.1016/j.inffus.2026.104448.

[25] Wu H, Wang H, Zhang Y, et al. An attempt at underwater image lightweight super-resolution using transformer and frequency-domain learning[J]. Frontiers in Marine Science, 2026, 13: 1762772. DOI:10.3389/fmars.2026.1762772.

[26] Dharejo F A, Ganapathi I I, Zawish M, et al. SwinWave-SR: Multi-scale lightweight underwater image super-resolution[J]. Information Fusion, 2024, 103: 102127.

[27] Chen Y, Niu K, Zeng Z, et al. A wavelet based deep learning method for underwater image super resolution reconstruction[J]. IEEE Access, 2020, 8: 117759-117769.

[28] Wang C, Jiang J, Zhong Z, et al. Spatial-frequency mutual learning for face super-resolution[A]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition[C]. Vancouver: IEEE, 2023: 22356-22366.

[29] Zhou F, Chen Q, Liu B, et al. Structure and texture-aware image decomposition via training a neural network[J]. IEEE Transactions on Image Processing, 2020, 29: 3458-3473.

[30] Liu Z, Lin Y, Cao Y, et al. Swin Transformer: Hierarchical vision transformer using shifted windows[A]. Proceedings of the IEEE/CVF International Conference on Computer Vision[C]. Montreal: IEEE, 2021: 9992-10002.

[31] Liang J, Cao J, Sun G, et al. SwinIR: Image restoration using Swin Transformer[A]. Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops[C]. Montreal: IEEE, 2021: 1833-1844.

[32] Wang D, Sun Z. Frequency domain based learning with Transformer for underwater image restoration[A]. Trends in Artificial Intelligence[C]. Cham: Springer, 2022, 13629: 218-232.

[33] Shen Z, Xu H, Luo T, et al. UDAformer: Underwater image enhancement based on dual attention Transformer[J]. Computers & Graphics, 2023, 111: 77-88.

[34] Peng L, Zhu C, Bian L. U-Shape Transformer for underwater image enhancement[J]. IEEE Transactions on Image Processing, 2023, 32: 3066-3079.

[35] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. Columbus: IEEE, 2014: 580-587.

[36] Girshick R. Fast R-CNN[A]. Proceedings of the IEEE International Conference on Computer Vision[C]. Santiago: IEEE, 2015: 1440-1448.

[37] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.

[38] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection [A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. Honolulu: IEEE, 2017: 2117-2125.

[39] Jia J, Fu M, Liu X, et al. Underwater object detection based on improved EfficientDet[J]. Remote Sensing, 2022, 14(18): 4487. DOI:10.3390/rs14184487.

[40] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. Las Vegas: IEEE, 2016: 779-788.

[41] Bochkovskiy A, Wang C Y, Liao H Y M. YOLOv4: Optimal speed and accuracy of object detection[J/OL]. arXiv, 2020[2024-03-01]. https://arxiv.org/abs/2004.10934.

[42] Jocher G, Stoken A, Chaurasia A, et al. ultralytics/yolov5: v6.0 - YOLOv5n 'Nano' models, Roboflow integration, TensorFlow export, OpenCV DNN support[EB/OL]. Zenodo, 2021. DOI:10.5281/zenodo.5563715.

[43] Jocher G, Chaurasia A, Qiu J. Ultralytics YOLOv8[EB/OL]. Ultralytics, 2023[2024-03-01]. https://github.com/ultralytics/ultralytics.

[44] Liu W, Anguelov D, Erhan D, et al. SSD: Single shot multibox detector[A]. Proceedings of the European Conference on Computer Vision[C]. Amsterdam: Springer, 2016: 21-37.

[45] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[A]. Proceedings of the IEEE International Conference on Computer Vision[C]. Venice: IEEE, 2017: 2980-2988.

[46] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. Salt Lake City: IEEE, 2018: 7132-7141.

[47] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional block attention module[A]. Proceedings of the European Conference on Computer Vision[C]. Munich: Springer, 2018: 3-19.

[48] Gong R, Xu J, Zheng Z, et al. YOLO-Starfish: fish object detection learning complex underwater features[J]. Scientific Reports, 2026, 16: 13964. DOI:10.1038/s41598-026-44187-z.

[49] Gang Y, Li T, Li S, et al. YOLO-MFD: a multi-scale feature and dynamic head fra mework for prefabricated shoreline underwater object detection[J]. Scientific Reports, 2026, 16: 10971. DOI:10.1038/s41598-026-45591-1.

[50] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16×16 words: Tran sformers for image recognition at scale[A]. International Conference on Learning Rep resentations[C]. Vienna: ICLR, 2021.

[51] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with Transformer s[A]. Proceedings of the European Conference on Computer Vision[C]. Glasgow: Spri nger, 2020: 213-229.

[52] Zhu X, Su W, Lu L, et al. Deformable DETR: Deformable Transformers for end-to-end object detection[A]. International Conference on Learning Representations[C]. Virt ual: ICLR, 2021.

[53] Gu A, Goel K, Ré C. Efficiently modeling long sequences with structured state spac es[A]. International Conference on Learning Representations[C]. Virtual: ICLR, 2022.

[54] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[J/O L]. arXiv, 2024[2024-03-01]. https://arxiv.org/abs/2312.00752.

[55] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propag ating errors[J]. Nature, 1986, 323(6088): 533-536.

[56] LeCun Y, Boser B, Denker J S, et al. Backpropagation applied to handwritten zip c ode recognition[J]. Neural Computation, 1989, 1(4): 541-551.

[57] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[A]. Proc eedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. La s Vegas: IEEE, 2016: 770-778.

[58] Kim J, Lee J K, Lee K M. Deeply-recursive convolutional network for image super-resolution[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. Las Vegas: IEEE, 2016: 1637-1645.

[59] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional network s[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recogniti on[C]. Honolulu: IEEE, 2017: 4700-4708.

[60] Tong T, Li G, Liu X, et al. Image super-resolution using dense skip connections[A]. Proceedings of the IEEE International Conference on Computer Vision[C]. Venice: IE EE, 2017: 4799-4807.

[61] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[A]. Advances in Neural Information Processing Systems[C]. Long Beach: MIT Press, 2017: 5998-6008.

[62] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3431-3440.

[63] Shi W, Caballero J, Huszár F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1874-1883.

[64] 程光权, 成礼智. 基于小波的方向自适应图像插值[J]. 电子与信息学报, 2009, 31(2): 265-269.

[65] Huynh-Thu Q, Ghanbari M. Scope of validity of PSNR in image/video quality assessment[J]. Electronics Letters, 2008, 44(13): 800-801.

[66] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: From error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612.

[67] Panetta K, Gao C, Agaian S. Human-visual-system-inspired underwater image quality measures[J]. IEEE Journal of Oceanic Engineering, 2016, 41(3): 541-551.

致　　谢

论文搁笔之际，窗外正值初夏。算起来，这已是我求学的第十八个年头。

我出生在一个建档立卡家庭。十八年求学路，国家和学校的资助贯穿始终——助学金的按时到账、学费减免的落实、生活补助的发放，这些看似程序性的安排，对一个贫困家庭的孩子而言，意味着不必在每一个开学季为学费发愁，不必在课堂与生计之间反复权衡。我深知，能安安稳稳坐在教室里念完这十八年书，背后是太多人托举的力量。这份恩情，我铭记于心。

感谢我的父母。你们文化不高，讲不出什么大道理，但从小到大，你们从未在我面前说过一句“别念了”。家里最难的那几年，你们把压力都扛在自己身上，留给我的只有一句“你只管读书”。如今我即将走出校门，回望来路才渐渐懂得，那些年你们咽下去的苦、藏起来的难，远比我能想象的多得多。这份恩情太重，我无以为报，唯有走好往后的每一步，让你们觉得这些年的付出都值得。

毕业论文的写作，于我而言是一段艰难而深刻的历练。在此，我要向我的指导教师王丽老师致以最深切的谢意与歉意。从选题到定稿，论文几经修改，每一稿交上去，回来的批注总是密密麻麻。我不止一次觉得惭愧——逻辑不够严密，表述不够精准，数据分析不够扎实。但王老师从未苛责，只是将论文推回来，平静地说一句“再改改”。如今想来，正是这一次次的“再改改”，让我渐渐理解了什么是严谨，什么是扎实。王老师，谢谢您的严格，更谢谢您的耐心。您以言传身教告诉我的，远非一篇论文的写法，而是对待学问与做事的根本态度。

感谢这十八年里每一位教过我的老师。小学的启蒙老师教会我认字算数，中学的英语老师在我次次考试倒数时仍不放弃我，反而对我特殊照顾，大学的任课老师在讲台上倾囊相授。你们或许记不得每一个学生，但学生记得你们。是你们一节一节的课、一次一次的批改、一句一句的叮嘱，把我从一个懵懂的孩子教到了今天。

五年来，我的女朋友陈姝灼始终相伴左右。这五年恰好贯穿我整个大学生涯，也恰好是我最焦灼、最迷茫的一段时光。她见过我对着电脑一筹莫展，见过我一整天因项目卡壳沉默不语，也见过我在自我怀疑中反复徘徊。她并非能解决我所有困惑，但她没有离开。她的陪伴安静而持久，像一盏不灭的灯。这样的情意，我唯有以余生认真相待。

写到这一页，意味着学生时代行将落幕。说不迷茫是假的。这个身份伴随了我十八年，一朝卸下，前路尚不明朗。但我并不因此畏惧。十八年并不容易，既然一路走到了这里，

便说明我终究还是有些东西的——或许不是天赋，而是一种无论跌倒多少次都还能站起来的韧劲。我相信，那些熬过的深夜、流过的汗、咽下去的委屈，都会在未来的某个时刻沉淀为前行的底气。

感谢这十八年途中遇见的每一位师长、同窗与朋友。是讲台上不厌其烦的讲授，是教室里并肩伏案的日夜，是走廊上不经意的几句鼓励，一点一点铺成了我脚下的路。有些人或许只是短暂地经过，但彼时的善意我都一一记得。也谢过那些在课堂上引我入门的师长，谢过那些在走廊里拍我肩膀的同窗，谢过那些不经意间给过我善意的陌生人。你们或许未曾察觉，但每一次微小的照亮，都让我成为今天这个更好的人。

毕业不是散场，而是把所有的光带在身上，去更远的地方。

带着这份沉甸甸的感恩，我愿意成为一个温暖而坚定、普通而不凡、对这个国家和社会真正有用的年轻人。

路还长，但感激在心，脚下的每一步，都有来处。

附　　录

附录 A 攻读学士学位期间取得的科研成果

[1] Li Wang, Bixuan Wang, Jun Zhu , Zhaoxin Yue, Xin Liu, **Kaixuan Li**. Frequency-Spatial Coupled Inference Network for Underwater Image Super-Resolution[A]. The 5th International Conference on Applied Mathematics, Modeling and Computer Simulation (AMMCS)[C]. 2025:1-7.

[2] **李凯旋**、王丽、陈姝灼、殷子航、朱俊. 一种改进的 YOLOv8 水下图像目标检测方法、装置、介质、程序[P]. 中国发明专利, 申请号: 202510291747.5, 2025-03-12.

[3] 南京工业职业技术大学；**李凯旋**、王丽、陈姝灼、朱俊、殷子航. 基于深度学习的水下图像清晰化与目标检测平台[Z]. 计算机软件著作权, 登记号: 2025SR0806055, 2025-05-16.

[4] 南京工业职业技术大学；**李凯旋**、马燕芹、陈姝灼、石骏、孙歆璇、王贝贝、孙瑾. 面向智慧城市应用场景的非机动车未戴安全帽检测系统[Z]. 计算机软件著作权, 登记号: 2024SR0749167, 2024-05-31.

附录 B 攻读学士学位期间主持或参与的科研项目

1. **主持**，《基于深度学习的水下图像清晰化与目标检测方法研究》，2024 年江苏省职业院校学生创新创业培育计划项目，项目编号：GX-2024-0017。

2. 参与，《基于模板匹配的 PCB 表面缺陷检测研究》，2022 年校级大学生创新创业训练计划一般项目。

附录 C 攻读学士学位期间获得的主要奖项

1. 第二十届全国高职院校“发明杯”大学生专利创新创业大赛三等奖,《基于深度学习的水下图像清晰化与目标检测方法研究》，**李凯旋**、陈姝灼、王博、周乔宇。

2. “国机杯”首届工业智能体大赛优秀奖,《水下图像智能处理与工业应用验证》，王丽、曾涛、郭昌瑞、殷子航、朱云希、**李凯旋**、陈姝灼。

3. 2022 年 iCAN 大学生创新创业大赛江浙赛区选拔赛三等奖，《“智慧天眼”——高空抛物智能监测识别系统》，彭旭、**李凯旋**、欧稳、胡靖浩、王健。

4. 第十七届全国高职院校“发明杯”大学生专利创新创业大赛三等奖，《一种基于单目视觉导引的移动机器人智能抓取方法》，**李凯旋**、陈姝灼、王健、李睿贤、钱飞宇。

5. 第六届江苏省智能（虚拟）仪器竞赛三等奖，《太极 AI 辅助训练系统》，欧稳、**李凯旋**、姚志凤、王洋、彭旭。

6. 2023 年南京工业职业技术大学大学生暑期社会实践活动优秀团队（“IT 实习生计划实践团队”团队负责人）。

7. 2024-2025 学年国家励志奖学金。

8. 黄炎培优秀学生学业奖学金。

9. 鹏远起航奖学金。

10. 三好学生、优秀学生干部、精神文明先进个人、社会服务先进个人、自强自立先进个人、专业学习先进个人、优秀志愿者、专业学习达人一等奖。